MAS1004 Data & AI, 2026 Fall

# Assignment 2 Long report

Name: 김서영 Student ID: 20251120

Leaderboard nickname `SoSleepy` Selected releases `track-a-2` and `track-b-3`

## 1 Scope and experimental purpose

This assignment classifies photographs as Seoul, Busan, Tokyo, Osaka, or Taipei. We first measured how much the validation score changed when the starter recipe was trained again with a different seed. After completing the baseline with seeds 0 and 1, the student reviewed mistakes from all five cities and selected 56 training photographs to exclude. With the same two seeds, the mean validation score was 50.14% with all training photographs and 49.26% after excluding the selected photographs. The student then proposed restoring all training photographs and masking small random regions during training. The mean score for that setting was 49.30%. The student later selected balanced sampling. A paired comparison on the same Mac and seed 0 scored 49.51% with the starter sampling and 50.91% with balanced sampling, an observed increase of 1.40 percentage points.

The report covers eight full Track A training runs across the recorded CUDA and MPS conditions and four full Track B training runs. The first Track B model scored 48.95% in its training-time validation. A subsequent paired comparison used the same MPS device and seed 0, with and without seven photographs supplied by the student. The scores were 48.61% and 48.74%, an observed increase of 0.13 percentage points. Each of these two conditions was run once.

On 10 November, the student selected reuse of the completed balanced Track A model for Track B. Its full ONNX/CPU validation score was 50.91%, and it was published as `track-b-2`. The leaderboard updated at 17:45 KST reported 42.03% and rank 14 among 27 scored models. Reusing this model added no training run. The final experiment trained MobileNetV3-Large at 448 × 448 with balanced sampling. Its full MPS validation score was 57.94%, compared with 50.91% for the balanced ResNet18 model. The student then chose to end experimentation and release the selected model. The planned MobileNet 224 control was cancelled. The comparison therefore measures a configuration change involving model, starting weights, resolution, and batch size. The 21:04 KST leaderboard update scored this final B release at 45.02%, rank 3 among 28 scored models. The final A recipe scored 41.06%, rank 11 among 29 scored recipes in the same update.

After training, we performed an optional occlusion analysis on ten validation photographs using the first Track B model, `track-b-1`. The student's question about an unexpected prediction change led to an additional comparison of replacement colors and blur at the same image coordinates.

| Work | Completed work or recorded status |
|---|---|
| Track A baseline | Full training with seeds 0 and 1, followed by model format checks |
| Photo review | Mistakes from all five cities reviewed, with 56 exclusions selected from 480 training candidates |
| Track A changes | Exclusion and Random Erasing with two CUDA seeds, followed by balanced sampling and a matched MPS control with seed 0 |
| Track A release | `track-a-2`, balanced sampling using the full training selection, selected and checked |
| Track B experiments | Four full training runs, including a paired comparison of seven additional photographs and the final MobileNet 448 experiment |
| Track B release | MobileNetV3-Large at 448 selected for `track-b-3`, after 57.94% MPS validation and official ONNX verification |
| Leaderboard | The 21:04 KST update on 10 November reported A at 41.06%, rank 11 of 29, and the final B model at 45.02%, rank 3 of 28 |

## 2 Data and Track A training conditions

The baseline used all starter training photographs. The following training counts come from the baseline `result.json`, and the validation counts are row totals of the saved confusion matrices. Counts for the exclusion condition are reported with that experiment.

| City | Training photographs | Validation photographs |
|---|---|---|
| Seoul | 11,274 | 2,435 |
| Busan | 5,191 | 1,390 |
| Tokyo | 13,347 | 3,881 |
| Osaka | 7,200 | 2,128 |
| Taipei | 7,245 | 2,243 |
| Total | 44,257 | 12,077 |

The model was ResNet18 initialized with ImageNet pretrained weights, with an input size of 224 × 224. Batch size 64 and 3,906 training steps resulted in 249,984 photograph presentations per run. All eight full Track A result files recorded `official_budget=true`.

The starter recipe applies random resized cropping, horizontal flipping, and color jitter. The crop area ranges from 0.35 to 1.0 of the original image area. Brightness, contrast, and saturation jitter are each 0.2. Training uses AdamW with learning rate $3 \times 10^{-4}$ and weight decay 0.05, together with OneCycleLR and label smoothing of 0.1. The recipe is preserved in `outputs/recipe_snapshot.py`.

Both baseline runs used CUDA. The recipe and photo selection were identical, and the seed changed from 0 to 1. Both recipe hashes begin with `17ac485223fa`. The recorded commits were `a23f9e6` and `0dd327b`, respectively.

The validation score is the mean of the five per-city accuracies. Each city therefore contributes equally, despite differences in the number of validation photographs.

## 3 Baseline results

| Run tag | Seed | Training time (min) | Validation (%) |
|---|---|---|---|
| `baseline` | 0 | 37.3 | 50.44 |
| `baseline` | 1 | 36.3 | 49.84 |
| Two-run mean | | | 50.14 |

The recorded training times were 2,238.2 and 2,179.5 seconds. Data preparation, validation, and model export required additional time. The per-city scores below come from these same validation runs.

| City | Seed 0 accuracy (%) | Seed 1 accuracy (%) |
|---|---|---|
| Seoul | 57.74 | 56.26 |
| Busan | 39.42 | 38.42 |
| Tokyo | 63.85 | 61.40 |
| Osaka | 36.04 | 38.91 |
| Taipei | 55.15 | 54.21 |

The absolute difference between the two overall scores was 0.60 percentage points. This illustrates variation from random choices under the same training method. Small improvements should be compared against a baseline using the same seed and checked with repeated runs when needed. Two runs provide limited information about the full distribution of training variability or statistical significance.

Tokyo had the highest accuracy in both runs. Busan and Osaka had lower accuracies than the other cities. The agent first presented mistake sheets for Busan and Osaka, and the student inspected them and recorded observations.

The Colab check outputs for both ONNX models reported 44.7 MB, 11.17 million parameters, and 1.81 billion multiply-adds for a 224 × 224 input. Both printed `format and limits: OK`. The original outputs are included in the appendix.

## 4 Photo observations and hypotheses

### 4.1 How the mistake sheets were reviewed

The command `curate.py mistakes` applied the seed 0 ONNX model to the validation photographs and selected 48 high-confidence mistakes per city. The five sheets contain 240 photographs in total. The city in a sheet's name is the ground-truth label. The city after the arrow under each photograph is the prediction, followed by its softmax output probability.

These sheets focus on high-confidence mistakes. We also examined the complete validation confusion matrices saved by `official.py`. The sheets used CPU inference in ONNX Runtime, while the validation score tables use the values recorded by the official training code.

### 4.2 Similar urban scenes in Busan and Seoul

The student noticed streetscapes that appeared common to Busan and Seoul. During the review on 7 November, the student explained this in the following statement, translated from Korean.

> Without the sea or a maritime feel, I do not think it is easy to tell whether a photograph is from Busan or Seoul.

An earlier observation pointed to cars parked along a residential street in Busan photograph 8. The student hypothesized that ordinary roads and buildings shared by the two cities could contribute to confusion.

Of the 48 mistakes on the Busan sheet, 34 were predicted as Seoul. The full validation confusion matrices showed the following pattern.

| Seed | Busan photographs | Busan errors | Predicted Seoul | Seoul share of Busan errors (%) |
|---|---|---|---|---|
| 0 | 1,390 | 842 | 442 | 52.49 |
| 1 | 1,390 | 856 | 463 | 54.09 |

More than half of the Busan errors in each run were predictions of Seoul. The causal role of visual similarity remains a hypothesis for further case review and measurement. The student's initial impression about street parking in Japanese residential areas also requires a broader set of examples.

### 4.3 Utility poles and overhead wires in Busan photograph 48

The student noticed utility poles and wires in Busan photograph 48 and thought their association with Japan might be related to the mistake. Its ground-truth label is Busan, and the model predicted Tokyo with output probability 0.85.

Overhead wires also exist in Korea. The Seoul Metropolitan Government's published undergrounding plan describes sections where electricity and telecommunications lines and poles are to be moved underground. The presence of wires should be assessed alongside other visual cues, and their actual influence on this prediction requires measurement. The source is listed in the references.

### 4.4 Similar scenes in Osaka and Tokyo

The student's initial observations on the Osaka sheet included shrines, houses, and residential streets with no visible sidewalks. On 8 November, the student explained that Osaka and Tokyo might be confused because both are Japanese cities with similar residential and shrine scenes.

Among Osaka errors in the baseline confusion matrices, Tokyo predictions accounted for 855/1,361, or approximately 62.82%, with seed 0, and 783/1,300, or approximately 60.23%, with seed 1. The relationship between the shared scenes and these mistakes was recorded as a photo-based hypothesis.

### 4.5 Food photographs in Seoul and vehicle photographs in Tokyo

The student found it difficult to identify the city from Seoul photographs 4 and 10, which mainly showed food. Subway and road scenes also appeared to share features across cities. For Seoul photograph 24, the student suggested that reflective paving blocks and an orderly street might evoke Japan. National differences in paving materials and the model's actual use of these features remained questions for verification.

For Tokyo photographs 4 and 8, the student similarly thought that a vehicle close-up could contain few city-specific cues. Subways and busy commercial streets could also resemble Osaka. The labels and predictions were checked against the sheet CSV files.

| Sheet and number | Ground truth | Prediction | Output probability |
|---|---|---|---|
| Seoul 4 | Seoul | Taipei | 0.96 |
| Seoul 10 | Seoul | Osaka | 0.91 |
| Seoul 24 | Seoul | Tokyo | 0.88 |
| Tokyo 4 | Tokyo | Seoul | 0.96 |
| Tokyo 8 | Tokyo | Osaka | 0.95 |

Seoul photographs 11 and 46 were checked again after their labels and prediction directions were initially misread. Both have Seoul labels, with Tokyo and Taipei predictions respectively. The interpretation was corrected by distinguishing people's positions on an escalator from the side of the road used by vehicles.

### 4.6 Cosplay, commercial spaces, and waterfront scenes in Taipei

The student explained that Taipei's appearance and culture were unfamiliar. The cosplay in photograph 41 looked like a Japanese manga character and might evoke Tokyo. The crowded commercial spaces in photographs 1 and 33 reminded the student of Hongdae and Seongsu in Seoul. Water and waterfront structures in photograph 10 suggested a sea and breakwater, which evoked Busan. Simple nature photographs also seemed to provide few clues for identifying a city.

| Sheet and number | Ground truth | Prediction | Output probability |
|---|---|---|---|
| Taipei 1 | Taipei | Seoul | 0.96 |
| Taipei 10 | Taipei | Busan | 0.91 |
| Taipei 33 | Taipei | Seoul | 0.85 |
| Taipei 41 | Taipei | Tokyo | 0.83 |

The character's identity, the type of waterfront, and the features used by the model require further verification. These observations motivated a review of photographs with limited city background. The student's original Korean observations and the review process are preserved in the lab notebook at the end of the report.

## 5 Excluding 56 training photographs selected by the student

### 5.1 Selection process and experimental scope

Following the observations about food in Seoul photographs and vehicles in Tokyo photographs, the student first chose to curate training photographs with food or vehicle close-ups. The agent applied the baseline seed 0 model to every fourth training photograph, a sample of 11,065. Photographs receiving

a low probability for their ground-truth city were collected into 96 candidates per city, or 480 in total. Each city had sheets 00 and 01, with photographs numbered from 1 to 48 on each sheet.

The student directly selected the numbers listed below. The actual selections also included birds, signs, sky, book covers, and flowers. We therefore recorded the experiment as curation of the photographs individually selected from the candidate sheets. The sheet names, numbers, and paths were retained without assigning an inferred reason to each photograph.

| City | Sheet | Numbers selected by the student | Count |
|---|---|---|---|
| Seoul | 00 | 5, 10, 14, 45 | 4 |
| Seoul | 01 | 2, 28, 30, 37, 39 | 5 |
| Busan | 00 | 1, 16, 31, 45 | 4 |
| Busan | 01 | 4, 24, 29, 38, 40 | 5 |
| Tokyo | 00 | 4, 11, 16, 19, 28, 34, 42 | 7 |
| Tokyo | 01 | 1, 3, 8, 10, 11, 15, 16, 21, 27, 33, 37, 42, 48 | 13 |
| Osaka | 00 | 18, 24, 28, 38, 39 | 5 |
| Osaka | 01 | 33 | 1 |
| Taipei | 00 | 2, 14, 30, 39, 41, 45, 46 | 7 |
| Taipei | 01 | 3, 11, 20, 23, 41 | 5 |
| Total | | | 56 |

The numbers and paths were checked against the sheet CSV files to create `curation_plan.csv`. Exactly these 56 photographs, approximately 0.13% of the training set, were excluded from the full training inventory on Colab. The experiment measures the effect of this selection from the low-confidence candidate sheets.

| City | Original training set | Excluded | Retained |
|---|---|---|---|
| Seoul | 11,274 | 9 | 11,265 |
| Busan | 5,191 | 9 | 5,182 |
| Tokyo | 13,347 | 20 | 13,327 |
| Osaka | 7,200 | 6 | 7,194 |
| Taipei | 7,245 | 12 | 7,233 |
| Total | 44,257 | 56 | 44,201 |

Both runs used the baseline training recipe, with hash prefix `17ac485223fa`. The selection hash prefix was `9ef44cac68cb`. The actual selection, exclusion record, original plan, and hash summary were exported from Colab and stored with the result ZIP. Checks covered duplicate paths and overlap between retained and excluded photographs. Combining both lists reproduced the original training count and inventory hash.

### 5.2 Results paired by seed

| Run | All photographs (%) | Exclude 56 (%) | Change (pp) |
|---|---|---|---|
| Seed 0 | 50.44 | 49.37 | -1.07 |
| Seed 1 | 49.84 | 49.14 | -0.70 |
| Two-run mean | 50.14 | 49.26 | -0.89 |

Before rounding, the means were 0.5014 and 0.49255. Their difference was -0.00885, or -0.885 percentage points. Values were calculated from the saved result JSON files and then rounded to two decimal places. Subtracting the displayed means can therefore differ in the last digit from the displayed change.

| City | All-photo mean (%) | Exclude-56 mean (%) | Change (pp) |
|---|---|---|---|
| Seoul | 57.00 | 57.66 | +0.66 |
| Busan | 38.92 | 36.59 | -2.34 |
| Tokyo | 62.63 | 64.49 | +1.86 |
| Osaka | 37.48 | 36.11 | -1.37 |
| Taipei | 54.68 | 51.43 | -3.26 |

Training took 2,211.8 seconds for seed 0 and 2,220.7 seconds for seed 1, approximately 36.9 and 37.0 minutes. Both ONNX models passed the format and limit checks. The run commits were `9cd86e1` and `a2ac080`.

The overall score decreased with both seeds. Mean accuracy increased for Seoul and Tokyo and decreased for Busan, Osaka, and Taipei. The measured conclusion concerns this particular set of 56 exclusions, these two seeds, and the public validation set. Further experiments would be needed to separate individual-photo effects or generalize to other curation rules. Changing the selection length also changes the official sampler's random presentation order, including when the same seed is used.

## 6 Random Erasing proposed by the student

After reviewing both exclusion runs, the student made the following request, translated from Korean.

> What about using all the photographs and masking some part of each one?

After clarification, the student chose to mask small random regions during training so that the model could learn from multiple cues. The agent implemented the following initial comparison using torchvision's `RandomErasing`.

| Item | Configuration |
|---|---|
| Experiment tag | `erase15` |
| Training photographs | All 44,257 photographs restored in the original order |
| Application probability | 0.5 each time a training photograph is presented |
| Erased area fraction | 0.02 to 0.15 of the transformed image area |
| Rectangle aspect ratio | 0.3 to 3.3 |
| Fill RGB | (0.485, 0.456, 0.406), which becomes 0 after ImageNet normalization |
| Other transformations | Random resized crop with area 0.35 to 1.0, horizontal flip, and color jitter |
| Comparison | Paired comparisons against the all-photo baseline with seeds 0 and 1 |

The student selected the masking approach. The agent chose the probability, area range, and other numerical settings for this first comparison. The hypothesis was that learning from the remaining city cues after a small region was hidden might improve validation performance. The comparison restored the baseline's complete training inventory and added the erasing augmentation.

Erasing was applied after `ToTensor`, followed by normalization in the official code. With the assignment's PyTorch 2.6.0 and torchvision 0.21.0, checks covered recipe rules, actual transformations, the official photo loader, and forward and backward passes on synthetic data. The recipe snapshot is stored in `outputs/erase15_recipe.py`. Full training and validation were then completed on Colab with seeds 0 and 1.

### 6.1 Measured effect of erasing

| Run | Baseline (%) | Random Erasing (%) | Change (pp) |
|---|---|---|---|
| Seed 0 | 50.44 | 49.16 | -1.28 |
| Seed 1 | 49.84 | 49.44 | -0.40 |
| Two-run mean | 50.14 | 49.30 | -0.84 |

| City | Baseline mean (%) | Erasing mean (%) | Change (pp) |
|---|---|---|---|
| Seoul | 57.00 | 57.09 | +0.09 |
| Busan | 38.92 | 37.77 | -1.15 |
| Tokyo | 62.63 | 63.22 | +0.59 |
| Osaka | 37.48 | 35.20 | -2.28 |
| Taipei | 54.68 | 53.24 | -1.45 |

Each seed used the same training count and inventory order as the baseline, with matching batch size, step count, presentation budget, and validation photographs. Both runs had recipe hash prefix `4c2c34345077` and all-photo selection hash prefix `1a1ca6c18823`. The overall and per-city scores were recalculated from the saved confusion matrices and checked against the original results.

Training took 2,208.3 and 2,207.2 seconds, approximately 36.8 minutes each. Both runs used commit `c6bf059`. They finished at 23:57 KST on 8 November and 00:37 KST on 9 November 2026. Both ONNX models passed the format and limit checks.

Under this probability and area range, the overall score decreased with both seeds. Mean accuracy increased for Seoul and Tokyo and decreased for Busan, Osaka, and Taipei. The comparison measures the performance of this particular configuration. Establishing which cues the model used, or the cause of the decrease, requires additional analysis. Further student interpretations can be recorded separately from these numerical comparisons.

### 6.2 Comparison of the initial CUDA conditions

| Condition | Seed 0 (%) | Seed 1 (%) | Mean (%) |
|---|---|---|---|
| Baseline recipe, all photographs | 50.44 | 49.84 | 50.14 |
| Student-selected 56-photo exclusion | 49.37 | 49.14 | 49.26 |
| All photographs with Random Erasing | 49.16 | 49.44 | 49.30 |

The baseline recipe had the highest two-seed mean among the three measured conditions. The exclusion and erasing runs are retained as measurements of the respective changes under their recorded settings.

## 7 Balanced sampling with a matched local control

### 7.1 Choice and implementation

After seeing balanced sampling among other participants' settings, the student explicitly selected it as the next experiment. The agent explained the training imbalance and the scoring rule. Tokyo has 13,347 training photographs and Busan has 5,191, so their shares in the starter selection are approximately 30.16% and 11.73%. The validation metric gives each of the five cities the same weight.

The new recipe gives each photograph a sampling weight of one divided by the number of selected photographs from its city. The weights within every city sum to one, giving every city a sampling probability of 20%. The official weighted sampler draws with replacement. The full original selection of 44,257 paths and its order were retained.

The following counts were calculated by the official sampler using seed 0 and the full budget. The total in each column is 249,984 presentations. They show how the experiment redistributed a fixed amount of training.

| City | Starter sampling | Balanced sampling |
|---|---|---|
| Seoul | 63,646 | 50,153 |
| Busan | 29,328 | 49,745 |
| Tokyo | 75,426 | 50,023 |
| Osaka | 40,670 | 49,939 |
| Taipei | 40,914 | 50,124 |

Every selected photograph appeared at least once with starter sampling. With weighted sampling and replacement, 43,818 distinct photographs appeared at least once. These counts describe the actual draws from the full selection.

### 7.2 Local execution and controlled comparison

The first MPS smoke check failed during backward computation with a tensor stride/view error. Converting the MPS input batch to contiguous memory in `recipe.mix` allowed the official training, validation, and ONNX export to complete. This operation preserves the input values and labels. Both local conditions used this same compatibility adjustment. The official training, rules, export, and submission-check source files and the pinned package versions were preserved.

Both conditions used the same MPS device, seed 0, worker count 0, $224 \times 224$ inputs, batch size 64, 3,906 steps, and 249,984 presentations. Cropping, flipping, color jitter, AdamW, OneCycleLR, and label smoothing were the same. The official MPS path used float32. The earlier CUDA runs used mixed precision, which is one reason to measure a fresh local control.

The control recipe was committed as `a108f5c`, with recipe hash `7c1cb9f0ee41`. The balanced recipe was committed as `bb6bc15`, with recipe hash `e7500546f0a5`. Both recorded the full-selection hash `1a1ca6c18823`. Saved snapshots matched their recorded commits, and each result was checked against its experiment CSV row and confusion matrix. Both conditions and the exact final recipe passed official smoke checks. Smoke checks are recorded separately from full-budget training.

| Run tag | Seed | Training time (min) | Validation (%) |
|---|---|---|---|
| `baseline_mps` | 0 | 47.2 | 49.51 |
| `balanced` | 0 | 48.0 | 50.91 |

Training took 2,829.9 and 2,881.0 seconds, respectively, with validation and export taking additional time. Both runs satisfied the official budget.

### 7.3 Results and the student's interpretation

| City | Control (%) | Balanced (%) | Difference (pp) |
|---|---|---|---|
| Seoul | 57.41 | 51.33 | -6.08 |
| Busan | 39.57 | 46.62 | +7.05 |
| Tokyo | 61.63 | 50.01 | -11.62 |
| Osaka | 35.81 | 44.97 | +9.16 |
| Taipei | 53.14 | 61.61 | +8.47 |
| Mean over cities | 49.51 | 50.91 | +1.40 |

Busan, Osaka, and Taipei increased, while Seoul and Tokyo decreased. The increases outweighed the decreases in the equally weighted city mean. After the agent explained the method and the score calculation, the student interpreted the Busan increase as more frequent exposure giving the model more opportunities to learn characteristics of Busan. The observed increase from 39.57% to 46.62% is consistent with that interpretation. Identifying the particular visual characteristics used requires further evidence.

This experiment shows that changing how frequently the existing photographs are sampled can affect the measured score, with gains and losses differing by city. Each local condition was run once with seed 0. The improvement of 1.40 percentage points describes this matched pair, and repeated-seed variability for balanced sampling remains unmeasured. The original CUDA baseline mean of 50.14% remains a separate two-seed result.

The agent selected balanced sampling for final Track A release `track-a-2`, based on its higher score in the matched local comparison. The recipe and full selection were released together. The appendix contains the sampling audit, original run logs, and comparison evidence.

## 8 Track B experiments and submission

### 8.1 First model training and release

After reviewing the erasing results, the student selected preparation of the first Track B submission as the next step. The experiment `b_baseline` used the provided `src/train_b.py`, with ResNet18 initialized from ImageNet-1k V1, 224 × 224 inputs, all starter training photographs, and four epochs. The default configuration used batch size 64, AdamW with learning rate 0.0003 and weight decay 0.05, OneCycleLR, and label smoothing 0.1.

This script trains independently of the Track A recipe and evaluates the full starter validation set. The first run used the provided script as supplied. It had no seed-setting argument, so the experiment record has an empty seed field. This difference is relevant when comparing later runs. The run presented 176,896 photographs and recorded 1,637.1 seconds of training, approximately 27.3 minutes. It ran on CUDA from commit `50530fc` and finished at 01:14 KST on 9 November.

| City | Validation accuracy (%) |
|---|---|
| Seoul | 55.40 |
| Busan | 37.55 |
| Tokyo | 63.77 |
| Osaka | 34.87 |
| Taipei | 53.14 |
| Mean across cities | 48.95 |

The `--submit` option generated `submission/model.onnx` and `submission/submission.json`. The model passed the official format and Track B size-limit checks on Colab and locally. Local measurements were 11,174,283 parameters, 1.813563904 GMACs, and 44.707595 MB, with ONNX opset 17. CPU inference at batch sizes 1 and 3 returned five finite logits for each photograph. The validation score above is the value recorded during Colab training.

The release `track-b-1` was published at 01:22:42 KST on 9 November. Its title was `Starter ResNet18 at 224, 4 epochs`. Release publication, both completed asset uploads, and the agreement between the GitHub asset SHA-256 values and the checked files were verified. The release commit was `d4f7ce3`, and the training commit was `50530fc`. Full hashes and asset sizes are retained in the appendix evidence and release-query JSON.

### 8.2 Scope and preparation of the student's additional photographs

The student said that Seoul and Busan photographs were available in Downloads. When the agent initially proposed processing all IMG photographs, the student restricted the scope to files downloaded that day. Finder's date-added metadata, converted to Korean time, identified seven files added at 01:27:30 KST on 9 November. The student confirmed that `IMG_0549.HEIC` was Seoul and the other six photographs were Busan.

| City | Original photograph numbers | Count |
|---|---|---|
| Seoul | 0549 | 1 |
| Busan | 0237, 0240, 0276, 0286, 1403, 1413 | 6 |

The HEIC images were converted into orientation-corrected RGB copies with 512 pixels on the shorter side. The provided photo-preparation code saved city-organized JPEGs, and checks confirmed empty EXIF metadata. All seven files had distinct file hashes and decoded-pixel hashes. The SHA-256 of each copy was recorded in a manifest. The collection scope was the student's one Seoul photograph and six Busan photographs supplied on 9 November.

Because the first Track B run had an unspecified seed, the agent added an optional `--seed` argument for the data comparison. Both new conditions used seed 0, ImageNet V1 ResNet18, 224 × 224 inputs,

four epochs, and batch size 64. They used 44,257 and 44,264 training photographs, respectively. Both yielded 691 complete batches per epoch and 176,896 photograph presentations per run.

A photo-inventory check verified file paths and hashes before training. Synthetic-data checks covered repeatability with seed 0, experiment recording, and compatibility with the original unspecified-seed behavior. Both full runs also passed the exact seven-file inventory and hash checks before training began.

### 8.3 Paired local comparison on the Mac

Colab's GPU usage limit prevented a new GPU connection, so the work moved to the student's Mac at the student's request. The environment was an Apple M1 Pro with 16 GiB memory and macOS 15.6, running PyTorch 2.6.0 and torchvision 0.21.0 with MPS operations verified. The 44,257 starter training photographs and 12,077 validation photographs were copied into the local working folder. The training paths and order matched the existing all-photo selection.

Both conditions ran the same `src/train_b.py` with seed 0 and zero loader workers. They used ImageNet V1 ResNet18, 224 × 224 inputs, four epochs, batch size 64, AdamW, OneCycleLR, and the original training augmentations. Both full runs used commit `500ed72`.

An initial short check with two workers was delayed during process shutdown after saving its outputs. With zero workers, training, export, checking, and normal shutdown were verified before full training began. These short checks were recorded separately from the twelve full experiments.

The control tag was `b_control_seed0`, and the added-photo tag was `b_own_sb_seed0`. Seoul training photographs increased from 11,274 to 11,275, and Busan photographs from 5,191 to 5,197. The other three cities and the validation set had the same inventories in both conditions.

| Condition | Training photographs | Photograph presentations | Validation (%) |
|---|---|---|---|
| Starter photographs | 44,257 | 176,896 | 48.61 |
| Add 7 photos | 44,264 | 176,896 | 48.74 |

The recorded training times were 2,091.5 seconds, approximately 34.9 minutes, for the control and 2,098.4 seconds, approximately 35.0 minutes, for the added-photo condition. Validation and ONNX export took additional time. The runs finished at 03:16:31 and 03:52:58 KST on 9 November, respectively.

### 8.4 Added-photo results and interpretation

| City | Starter photos (%) | Add seven (%) | Change (pp) |
|---|---|---|---|
| Seoul | 61.44 | 56.34 | -5.10 |
| Busan | 36.91 | 37.19 | +0.28 |
| Tokyo | 59.86 | 61.63 | +1.77 |
| Osaka | 34.02 | 35.43 | +1.41 |
| Taipei | 50.82 | 53.10 | +2.28 |
| Mean across cities | 48.61 | 48.74 | +0.13 |

These figures use the scores stored to four decimal places in `experiments.csv`. Among the cities receiving additional photographs, Seoul accuracy decreased and Busan accuracy increased slightly. Tokyo, Osaka, and Taipei accuracies also changed. The overall observed increase was 0.13 percentage points. One run per condition at one seed provides limited information about persistent improvement and training variability.

Adding photographs changes the dataset length and shuffled order. Connecting each per-city change directly to an individual added photograph requires further verification. The appropriate control for

this paired data experiment is the 48.61% result from the same device and seed. A comparison with the first Colab model's 48.95% also includes device and seed-setting differences.

The seven photographs represent approximately 0.016% of the starter training set. Generalizing from this small addition to the effect of collecting many more photographs requires experiments with greater numbers and diversity. The numerical comparisons and limitations in this section are the agent's analysis of the records. Additional student interpretations can be recorded with their authorship identified.

Both ONNX models passed the official Track B format and limit checks. Each had 11,174,283 parameters, 1.813563904 GMACs, a file size of 44,707,595 bytes, and opset 17. Full ONNX checking and CPU inference at batch sizes 1 and 3 also confirmed five finite outputs per photograph.

Each model and its metadata were stored in a separate result folder. The queued `--submit` command initially placed the seven-photo model in the local `submission/` folder after training. The submission review on 9 November selected the first model and restored it to the submission folder. The selection was revised on 10 November as described below. Model hashes, original run outputs, and check results are included in the appendix evidence.

### 8.5 Using the balanced Track A model for Track B

The leaderboard snapshot updated at 17:04 KST on 10 November reported 38.26% for `track-b-1`, rank 26 among 27 scored models. After expressing concern about that result, the student selected the agent's proposal to validate and submit the already trained balanced model.

The source was `results/balanced_seed0/model.onnx`, trained from commit `bb6bc15` on MPS with seed 0, batch size 64, 3,906 steps, and 249,984 presentations. We evaluated all 12,077 starter validation photographs with the official Track B checker using ONNX Runtime on CPU. The exact mean city accuracy was 0.509104010051048, or 50.91%. Its confusion matrix matched the original balanced MPS validation result.

| City | First B model, ONNX/CPU (%) | Balanced, ONNX/CPU (%) |
|---|---:|---:|
| Seoul | 55.40 | 51.33 |
| Busan | 37.55 | 46.62 |
| Tokyo | 63.75 | 50.01 |
| Osaka | 34.87 | 44.97 |
| Taipei | 53.14 | 61.61 |
| Mean across cities | 48.94 | 50.91 |

The increase of 1.97 percentage points supports selecting the balanced model from these available candidates. The two models also differ in training budget, device, and seed-setting conditions. The paired sampling comparison in Section 7 provides the controlled evidence for the sampling change, with 49.51% and 50.91% under the same MPS and seed-0 conditions. Reusing a completed model added no training run to the eleven full experiments recorded at that stage.

The checked model was published as `track-b-2` at 17:32:25 KST on 10 November, titled `ResNet18 at 224, balanced sampling, seed 0`. Both release assets were downloaded without authentication and matched the validated local files byte for byte. The model has 11,174,283 parameters, 1.813563904 GMACs, and a size of 44,707,595 bytes. The complete model and metadata hashes and the official full check are reproduced in the appendix.

The subsequent leaderboard update at 17:45 KST reported 42.03% for this release, rank 14 among 27 scored models. Compared with the first release's 38.26%, the public score increased by 3.77 percentage points. It also exceeded the displayed starter-model reference of 40.3% by approximately 1.7 percentage points. The leaderboard and local validation use different photographs, so their absolute scores describe separate evaluation sets.

| City | First B leaderboard (%) | Balanced B leaderboard (%) |
|---|---|---|
| Seoul | 58.0 | 62.3 |
| Busan | 15.9 | 30.9 |
| Tokyo | 70.5 | 61.8 |
| Osaka | 23.7 | 30.0 |
| Taipei | 23.2 | 25.1 |
| Published overall score | 38.26 | 42.03 |

The per-city public values are rounded in the source data. The overall row uses each published score, retaining its provided precision.

### 8.6 Final MobileNetV3-Large experiment at 448

After selecting the balanced B model, the student asked for an additional improvement that might increase the leaderboard rank. The student chose the proposed MobileNetV3-Large comparison at 224 and 448 pixels. An initial 448 execution check with batch size 64 was too slow on the 16 GiB Mac, and the student chose the same smaller batch for both planned resolutions. The full 448 run was executed first to allow more time for the longer run. The student later chose to end experimentation after 448 and proceed with release and the final report. The 224 full run was consequently cancelled.

The new model used torchvision's MobileNetV3-Large initialized with ImageNet-1k V2 weights. It used all 44,257 starter training photographs, balanced sampling, seed 0, batch size 32, and 7,812 steps, giving the same 249,984 presentations as the balanced Track A run. Cropping at area 0.35–1.0, horizontal flipping, color jitter, AdamW at $3 \times 10^{-4}$, weight decay 0.05, OneCycleLR, and label smoothing 0.1 were retained.

The optional fixed-step mode added to `src/train_b.py` reused the official sampler's draw order and a dedicated loader generator. Python, NumPy, and torch seeds were reset after model initialization. The epoch-based entry point retained its existing defaults. Quick checks were logged separately from the full training table. The completed full run used commit `49346fe` and tag `b_mnv3_448_seed0`.

Training took 7,931.0 seconds, approximately 132.2 minutes. The final mean training loss was 0.886. Full validation and export required approximately another 51 minutes. During validation, the script used batches of 128, and a process sample recorded a physical memory footprint of approximately 13.5 GB. This larger evaluation batch made the final stage much slower than the training-only runtime estimate suggested. The model and result files were saved at 20:53:40 KST on 10 November. The ONNX export gap recorded by the supplied exporter was `3.64e-6`.

| City | Balanced ResNet18 (%) | MobileNet 448 (%) | Change (pp) |
|---|---|---|---|
| Seoul | 51.33 | 57.21 | +5.88 |
| Busan | 46.62 | 50.58 | +3.96 |
| Tokyo | 50.01 | 62.17 | +12.16 |
| Osaka | 44.97 | 52.54 | +7.57 |
| Taipei | 61.61 | 67.19 | +5.58 |
| Mean across cities | 50.91 | 57.94 | +7.03 |

These are the recorded training-time MPS validation scores, rounded to two decimal places. The same public validation photographs, MPS device, seed, and number of training presentations were used. Accuracy increased for all five cities, with the largest observed gain for Tokyo. The configuration improved the measured city-mean accuracy by 7.03 percentage points in this single-seed comparison.

Several factors changed together. ResNet18 used ImageNet V1 weights, 224 inputs, batch size 64, and 3,906 optimizer steps. MobileNetV3-Large used ImageNet V2 weights, 448 inputs, batch size 32, and 7,812 optimizer steps. The cancelled MobileNet 224 run leaves the isolated resolution effect unmeasured. The observed gain supports model selection among the completed candidates. A separate

matched comparison would be required to attribute a particular share of the gain to resolution or architecture. This interpretation is the agent's analysis.

The exported MobileNet has approximately 4.20 million parameters, 0.85 GMACs per input, and a 16.8 MB file. It passed the official Track B format and limit checks. Full ONNX/CPU validation, release verification, and the selected submission files are recorded in Section 11 and the appendix.

The 21:04 KST leaderboard update scored `track-b-3` at 45.02%, rank 3 among 28 scored models. This exceeded the balanced B release's 42.03% by 2.99 percentage points. The following values come from the published per-city scores, with their displayed precision.

| City | Balanced B leaderboard (%) | MobileNet 448 (%) | Change (pp) |
|---|---|---|---|
| Seoul | 62.3 | 63.8 | +1.5 |
| Busan | 30.9 | 30.4 | -0.5 |
| Tokyo | 61.8 | 76.3 | +14.5 |
| Osaka | 30.0 | 34.8 | +4.8 |
| Taipei | 25.1 | 19.8 | -5.3 |
| Published overall score | 42.03 | 45.02 | +2.99 |

All five local validation accuracies increased, while the public leaderboard showed increases for Seoul, Tokyo, and Osaka and decreases for Busan and Taipei. The largest public increase was for Tokyo. The overall gain therefore combines different per-city changes on this separate set of street scenes. This observation limits a claim that the new configuration improves every city across data sources. The final private photographs remain a separate evaluation after the deadline.

## 9 Post-training occlusion analysis and interpretation checks

### 9.1 Case selection and measurement

The student requested an optional analysis of which image regions affected the model's outputs. This analysis was completed on 9 November with the first release, `track-b-1`, which was selected at that time. The later balanced-model submission uses a different ONNX file. The agent shuffled each city's validation list with seed 0 and evaluated the first 32 photographs per city, 160 in total. In that order, the first correctly classified and first incorrectly classified photograph from each city were selected, producing ten cases. This sampling supports a comparison of correct and incorrect cases. Overall accuracy is reported from the full validation set.

The official `rules.grader_input` produced a $224 \times 224$ center crop. Each input was partitioned into 49 non-overlapping $32 \times 32$ regions. One region at a time was filled with RGB $(0.5, 0.5, 0.5)$, followed by inference. For each photograph, the original predicted city was fixed as the target, and we measured the change in that target's logit after masking. A logit is the output score before conversion to a softmax probability.

Red indicates a decrease in the original predicted city's logit after masking, and blue indicates an increase. All ten heatmaps use the same color scale. The probability columns below also refer to the original predicted city.

| City | Original case | Original prediction | Original prob. (%) | Masked prob. (%) | Prediction changes /49 |
|---|---|---|---|---|---|
| Seoul | Correct | Seoul | 65.0 | 42.9 | 1 |
| Seoul | Incorrect | Busan | 55.1 | 41.1 | 0 |
| Busan | Correct | Busan | 40.6 | 31.1 | 1 |
| Busan | Incorrect | Tokyo | 34.9 | 29.0 | 9 |
| Tokyo | Correct | Tokyo | 85.1 | 78.4 | 0 |
| Tokyo | Incorrect | Seoul | 64.8 | 48.7 | 0 |
| Osaka | Correct | Osaka | 93.0 | 90.6 | 0 |
| Osaka | Incorrect | Tokyo | 45.4 | 32.2 | 4 |
| Taipei | Correct | Taipei | 39.0 | 28.4 | 0 |
| Taipei | Incorrect | Seoul | 55.5 | 38.1 | 0 |

The masked probability is measured at the region giving the largest decrease in the original predicted city's logit. The final column counts how many of the 49 masks changed the predicted city. Maximum logit decrease and a change in the final predicted city were recorded as separate measures.

Across 490 masked inputs, 15 predictions changed, occurring in four of the ten photographs. One mask changed each of the correctly classified Seoul and Busan cases to an incorrect prediction. Four masks changed the incorrect Osaka case to the correct city, Osaka.

The numerical results, original logits, case list, analysis code, and figures were retained. Checks covered the fixed original target, complete input coverage by the 49 regions, model and photograph hashes, and agreement between the stored arrays and CSV files.

### 9.2 The student's question and replacement controls

In the incorrectly classified Osaka photograph, masking a sky region changed the prediction to Osaka. The student questioned this result in the following statement, translated from Korean.

> Masking a completely unexpected area changes the prediction, so I really do not understand why.

In response, we compared different replacement methods in the same photograph at the same coordinates. The region was `x [64,96)` and `y [96,128)` in the model input crop. The conditions included the mean color of the original sky patch, Gaussian blur with radius 8 pixels applied only to that patch, and grayscale fills at different brightness levels.

| Replacement | Tokyo prob. (%) | Osaka prob. (%) | Prediction |
|---|---|---|---|
| Original | 45.4 | 19.9 | Tokyo |
| Middle gray 0.50 | 32.2 | 34.7 | Osaka |
| Original sky patch mean | 43.8 | 21.2 | Tokyo |
| Blur, radius 8 pixels | 45.6 | 19.9 | Tokyo |
| Dark gray 0.25 | 36.1 | 29.9 | Tokyo |
| Light gray 0.75 | 32.5 | 36.8 | Osaka |

The predicted city depended on how the same sky region was replaced. The initial gray-mask result combined a change to the original information with the introduction of a new patch color and boundary. This case demonstrates output sensitivity to particular masking conditions. Interpreting semantic or cultural city cues requires considering this dependence on the analysis method. We also consulted Section 4.3 of Fong and Vedaldi's ICCV 2017 paper, which discusses artifacts introduced by sharp color contrasts from constant perturbations.

This diagnostic changed the inputs to a completed model. Its case-level outputs and replacement controls are stored separately from the twelve full training experiments. The report distinguishes training changes, diagnostic input changes, observed output sensitivity, and hypotheses about semantic causes.

## 10 Conclusions from the measurements and further work

Among the three initial CUDA Track A conditions, the highest mean validation score was 50.14%, obtained with the baseline recipe and all training photographs. The student's 56-photo exclusion scored 49.26%, and the student-proposed erasing experiment scored 49.30%. Both changes scored lower than the baseline with the same two seeds. These conclusions apply to the particular selection and augmentation settings tested.

The later matched MPS comparison improved from 49.51% with starter sampling to 50.91% with balanced sampling. Redistributing training appearances increased accuracy for Busan, Osaka, and Taipei and reduced it for Seoul and Tokyo. The student interpreted more frequent exposure as giving the model more opportunities to learn Busan characteristics. The measured score improvement applies to the one completed seed-0 pair. Balanced sampling was selected for the final Track A release.

Photographs that seem difficult for a person to identify can still affect training. The intended benefit of encouraging multiple cues through augmentation also required measurement. Further analysis is needed to identify the specific causes of the decreases and the model's use of visual features. The post-training diagnostic demonstrated sensitivity both to which region was masked and to how it was replaced, illustrating the importance of the analysis conditions when interpreting a model.

In Track B, the student's decision to supply one Seoul photograph and six Busan photographs was evaluated against a control on the same MPS device and seed. The observed change was +0.13 percentage points. Repeated measurements are needed to interpret this small difference from a single pair of runs. On 10 November, the student selected reuse of the balanced Track A model for Track B. Full ONNX/CPU validation increased from 48.94% for the first B model to 50.91%. The subsequent public leaderboard score increased from 38.26% to 42.03%. Differences in training budget, device, and seed-setting conditions also contribute to this model-selection comparison. The controlled evidence for balanced sampling comes from the matched Track A pair.

The last MobileNetV3-Large 448 configuration scored 57.94% on the full MPS validation set, exceeding the balanced ResNet18's 50.91% by 7.03 percentage points. All five city accuracies increased. This result comes from one seed and a combined change in model, starting weights, resolution, and batch size. The student ended experimentation after this run, so the planned MobileNet 224 comparison was cancelled. Its public score increased from the balanced model's 42.03% to 45.02%, reaching rank 3 of 28 in the recorded update. Public gains varied by city, including decreases for Busan and Taipei despite their local validation increases. Evaluation across the two photo sources therefore provides additional information beyond the overall local validation gain.

With one more week, the agent would propose additional seeds under matching conditions and a larger, more varied collection of street, residential, and transport scenes from each city. Gradually increasing the collection would allow a comparison of the effect of data quantity. The 56-photo exclusion could also be divided into more specific reason-based groups to investigate which groups relate to score changes. Specific choices of additional collection and experiments would be made by the student and recorded with their rationale.

## 11 Final submission and validation checks

The selected releases use the balanced ResNet18 recipe for Track A and MobileNetV3-Large at 448 for Track B. Twelve full training runs were completed, eight in Track A and four in Track B. Their comparison conditions and measurement limitations are reported above.

### 11.1 Validation and leaderboard scores

| Track | Release | Validation (%) | Leaderboard |
|---|---|---|---|
| A | `track-a-2` | 50.91, MPS seed 0 | 41.06% |
| B, earlier | `track-b-2` | 50.91, ONNX/CPU | 42.03% |
| B, final | `track-b-3` | 57.94, ONNX/CPU | 45.02% |

The public data checked at 21:07:33 KST on 10 November showed an update time of 21:04 KST. It contained `SoSleepy` with the selected final release in each track. Track A ranked 11 among 29 scored recipes, with mean public accuracy of 41.06%. Its three-seed public scores ranged from 40.19% to 42.22%, and its server-side mean starter-validation score was 50.22%. The final MobileNet B release ranked 3 among 28 scored models with 45.02%. The earlier balanced release scored 42.03% before replacement. The latest snapshot and extracted status are retained in `outputs/leaderboard_status.json` and `outputs/leaderboard_b3_scored.json`. Earlier snapshots are retained separately for the historical comparisons above.

The displayed starter-recipe reference was 40.1%, and the starter-model reference was 40.3%. The final A and B releases exceeded these rounded references by approximately 0.96 and 4.72 percentage points, respectively. These comparisons describe the public leaderboard split available before the deadline. The assignment also evaluates the last releases on a separate final set after the deadline.

The leaderboard uses YouTube street-video frames from sources separate from starter validation. Track A averages three grader-trained seeds, while local balanced validation used MPS seed 0. The final B model's local ONNX/CPU score of 57.94% and public score of 45.02% also refer to different photographs.

### 11.2 Submission file checks

The final Track A recipe passed official rules and the 20-step MPS `--quick` check, including validation and export. The 44,257-photo selection retained all original paths and their order. The downloaded release files matched the checked local files.

The selected MobileNet Track B ONNX file passed official format and size-limit checks and full CPU evaluation on all 12,077 photographs. Its exact score was 0.5793640527634617, or 57.94%, and its confusion matrix matched MPS validation. The CPU evaluation took 209 seconds. The earlier balanced model's exact ONNX/CPU score was 0.509104010051048, or 50.91%, making the increase 7.03 percentage points.

The selected exported model contains 4,196,243 parameters and requires 0.85303744 GMACs per photograph. Its file size is 16,825,941 bytes, with ONNX opset 17. The submitted files match the full-check candidates. Release `track-b-3` was published at 21:00:46 KST on 10 November, before the 22:00 deadline, with title `MobileNetV3-Large at 448, balanced sampling`. The public release files were retrieved anonymously and matched those same bytes and SHA-256 values. Full hashes and release timing are reproduced in the appendix.

## References


1. Assignment README and official training code, GitHub.
2. Student repository, final Track A release.
3. Student repository, final MobileNet Track B release.
4. Student repository, earlier balanced Track B release.
5. Student repository, first Track B release used for the occlusion analysis.
6. Public leaderboard data.
7. Seoul Metropolitan Government, overhead-line undergrounding plan update, 28 October 2024.
8. torchvision 0.21 documentation for RandomErasing.
9. Captum documentation for Occlusion.
10. Fong and Vedaldi, Interpretable Explanations of Black Boxes by Meaningful Perturbation, ICCV 2017.

# A Photo review material

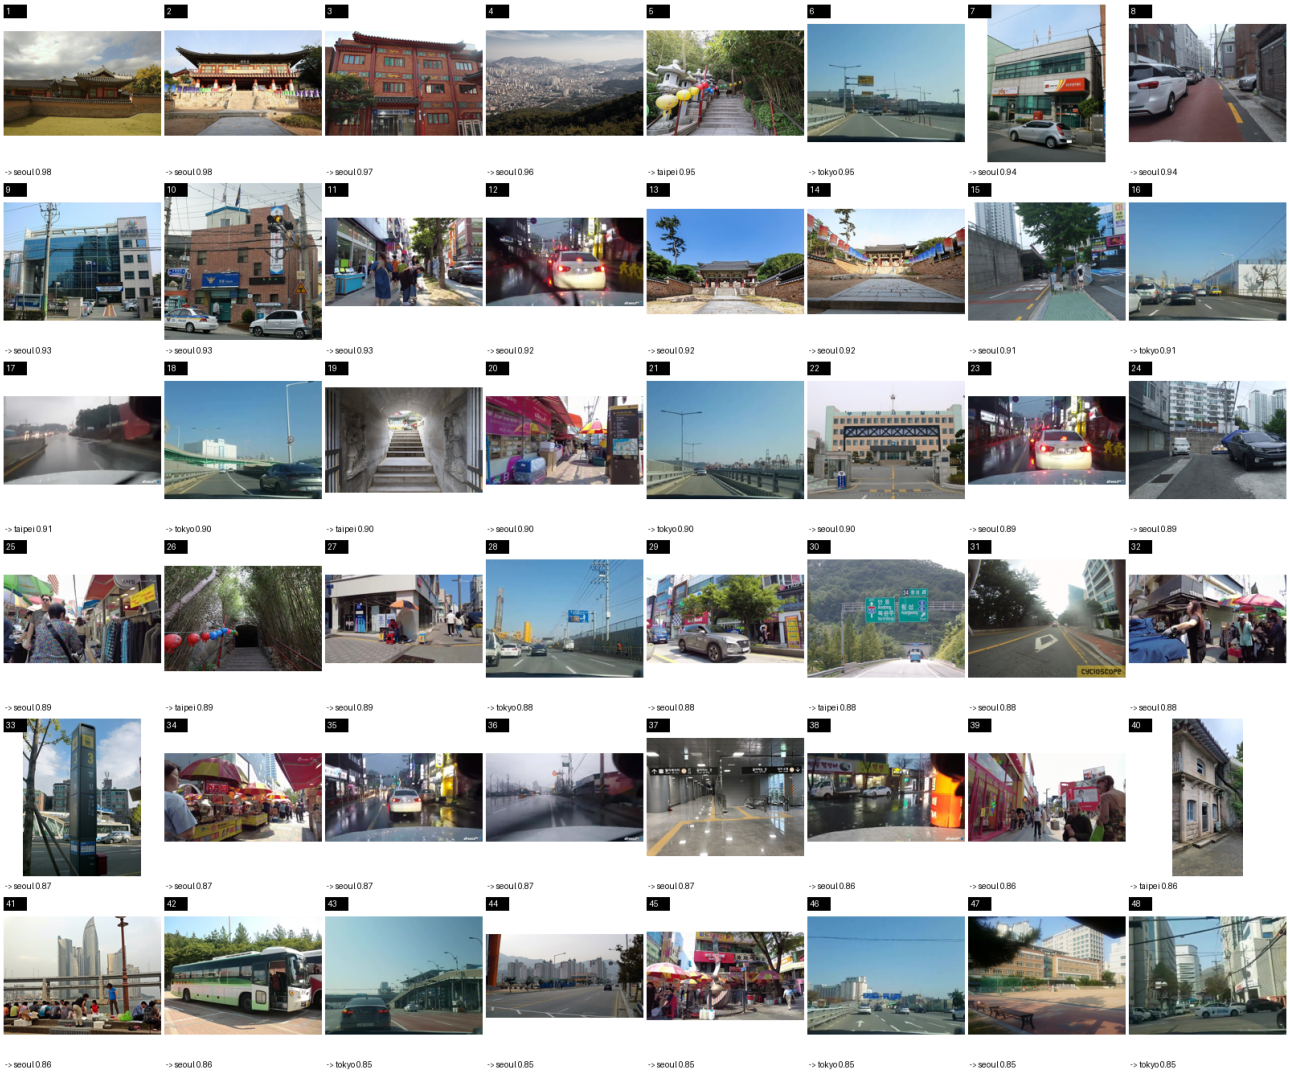



Figure 1: Forty-eight high-confidence mistakes among photographs labeled Busan under the seed 0 model. Predictions and output probabilities appear below the photographs. The student specifically identified roadside parking in photograph 8 and utility poles and wires in photograph 48.

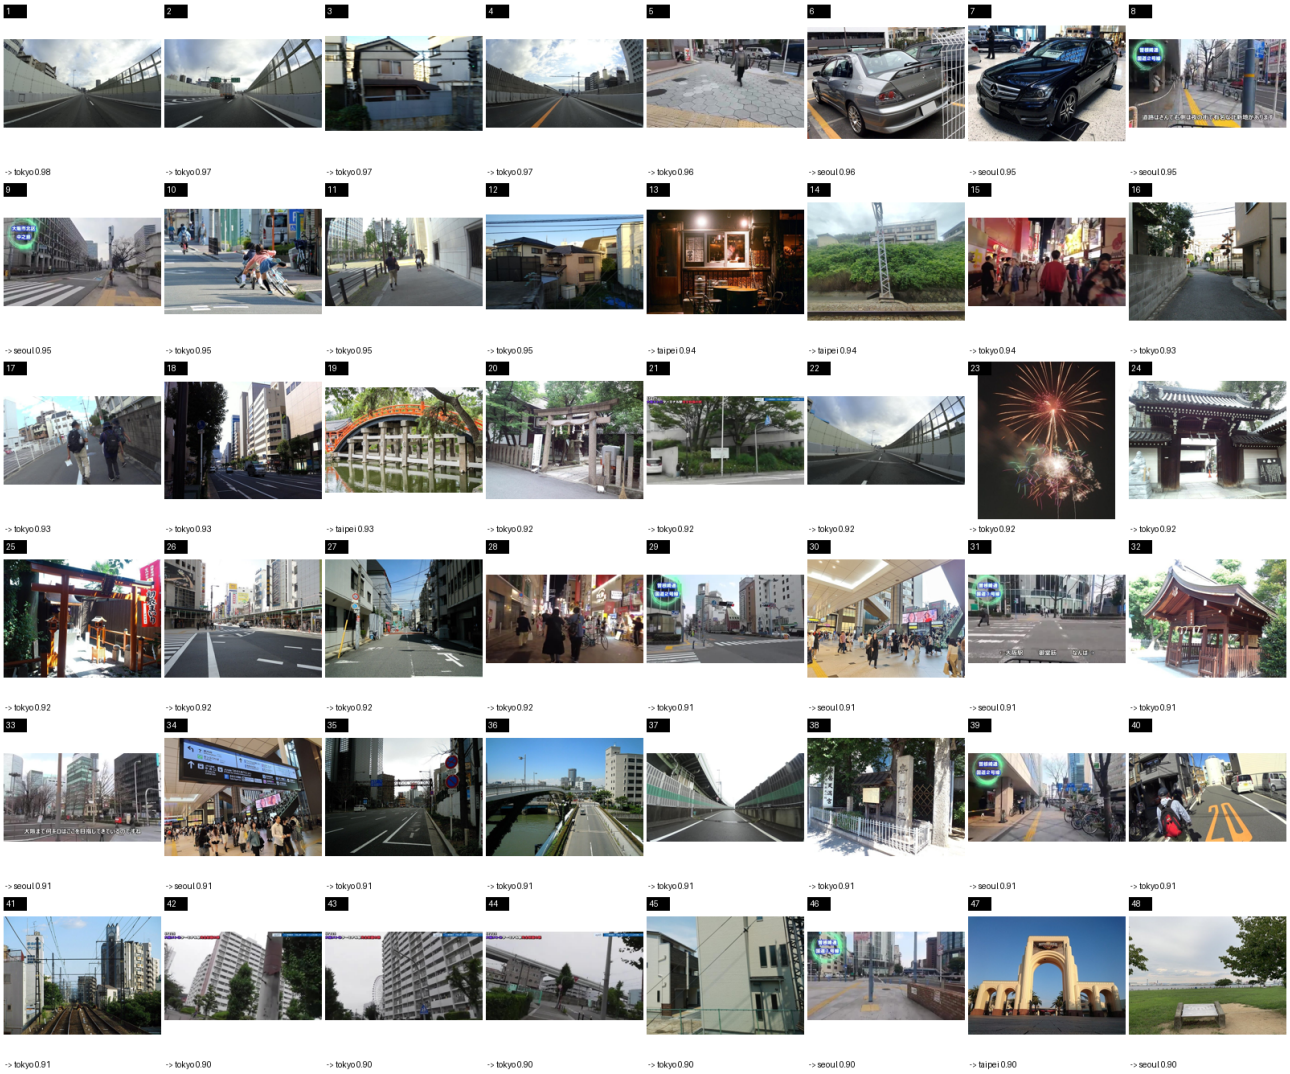



Figure 2: Forty-eight high-confidence mistakes among photographs labeled Osaka under the seed 0 model. The student's initial observations concerned shrines, houses, and residential streets with no visible sidewalks.

## B Occlusion analysis figures

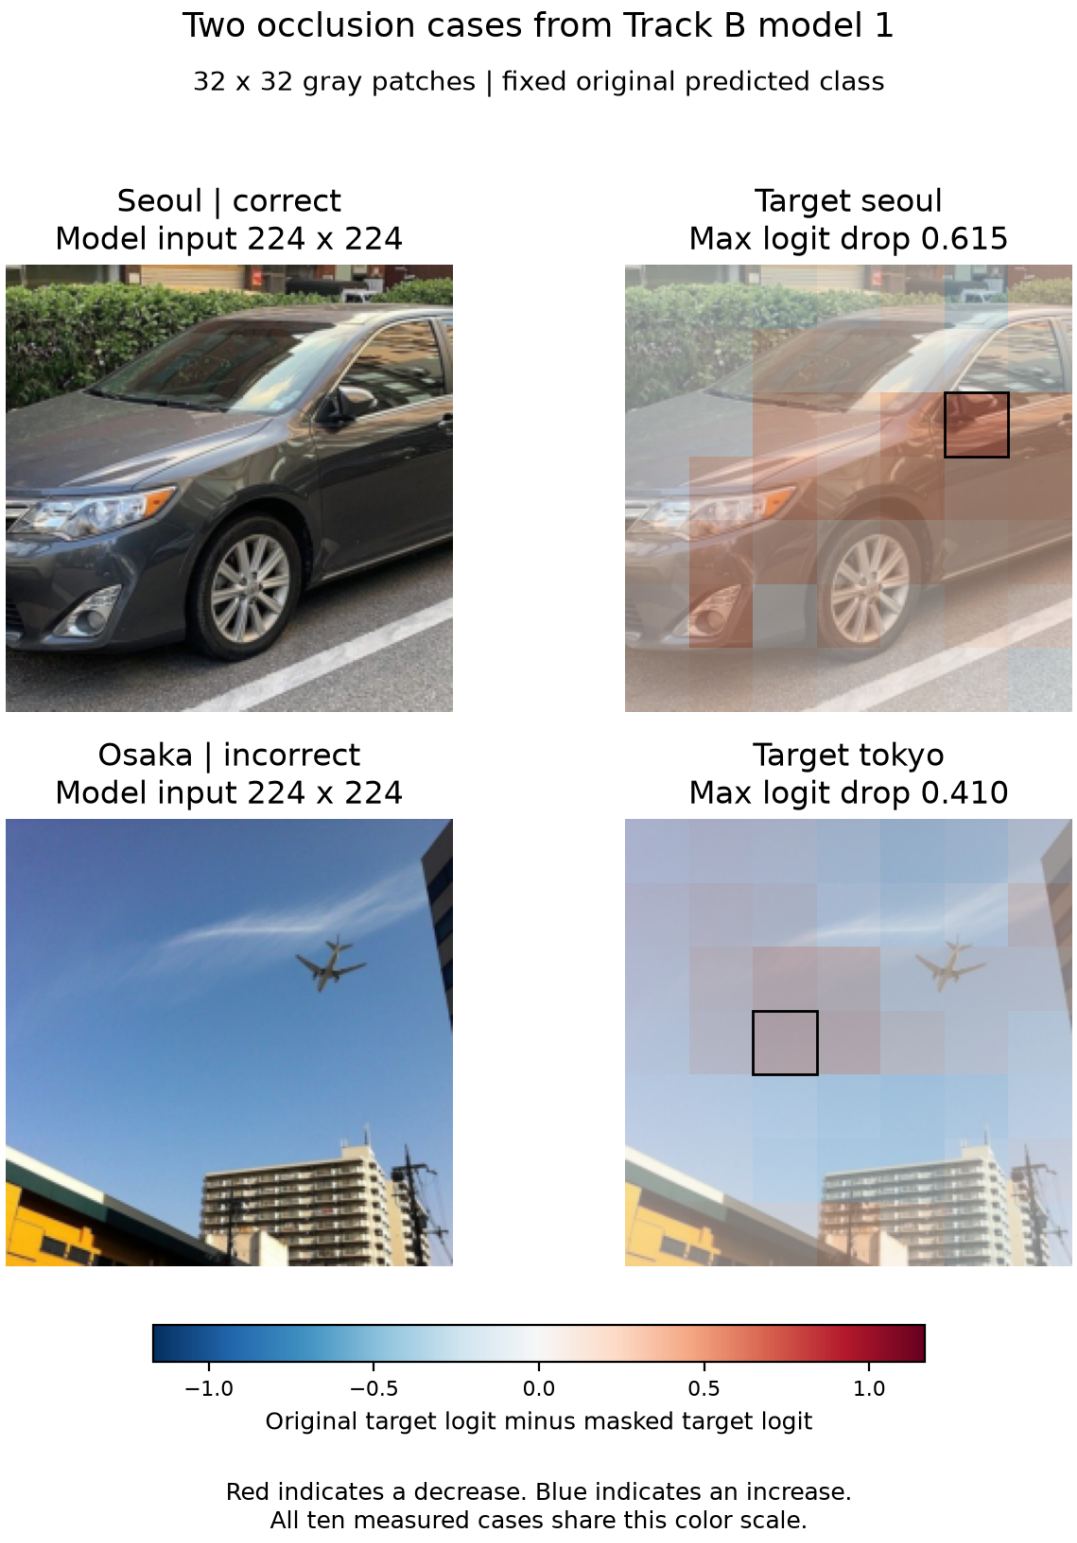



Figure 3: A correctly classified Seoul case and an incorrectly classified Osaka case from the first Track B model, `track-b-1`. The original predicted city is fixed as the target. Black outlines indicate the regions with the largest target-logit decrease. Red indicates a logit decrease after masking and blue an increase. All ten cases use the same color scale.

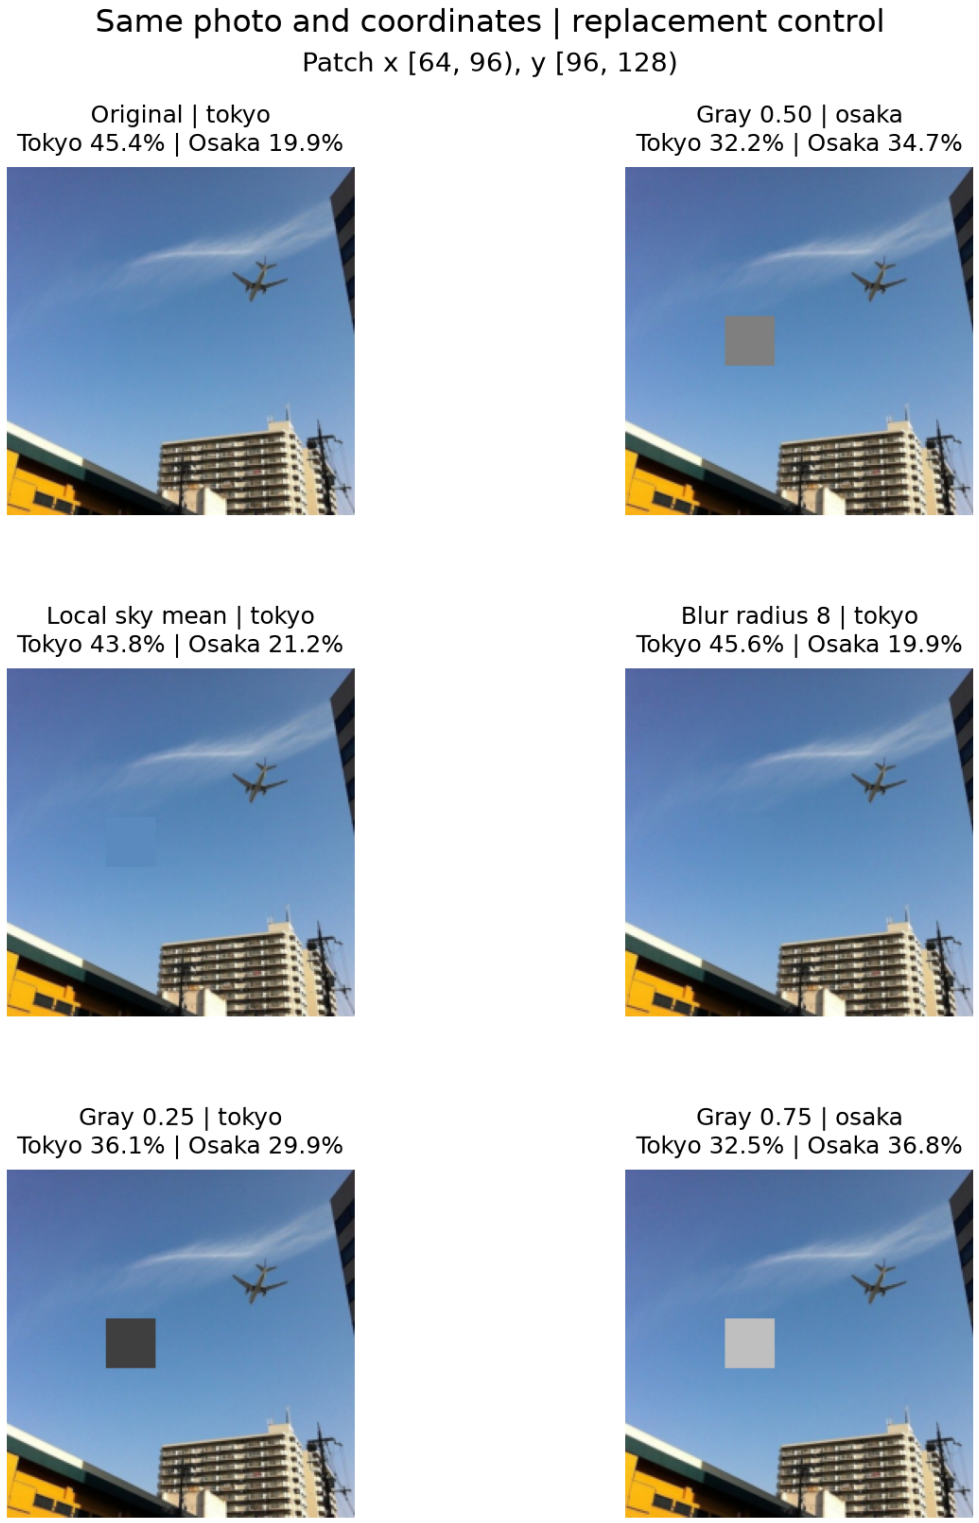



Figure 4: Replacement controls for the first Track B model on the same sky region of the incorrectly classified Osaka photograph. Middle and light gray produced Osaka predictions. The original sky patch mean and blur produced Tokyo predictions. This case demonstrates output sensitivity to the replacement method.

## C Recorded outputs and numerical evidence

Original machine outputs are reproduced in their recorded form. The evidence files support the numerical tables in the main report.

### All full training runs

```
finished,track,tag,seed,official_budget,budget,val_score,seoul,busan,tokyo,osaka,taipei,train_seco
↪  nds,device,selection,recipe_sha,selection_sha,commit
2026-11-05T15:58:13,A,baseline,0,True,249984,0.5044,0.5774,0.3942,0.6385,0.3604,0.5515,2238.2,cuda
↪  ,all training
↪  photos,17ac485223fa,,a23f9e6
2026-11-05T16:53:23,A,baseline,1,True,249984,0.4984,0.5626,0.3842,0.614,0.3891,0.5421,2179.5,cuda,
↪  all training
↪  photos,17ac485223fa,,0dd327b
2026-11-08T21:51:51,A,curated56,0,True,249984,0.4937,0.5848,0.3727,0.6339,0.3604,0.5167,2211.8,cud
↪  a,"selection.csv, 44201
↪  rows",17ac485223fa,9ef44cac68cb,9cd86e1
2026-11-08T22:39:04,A,curated56,1,True,249984,0.4914,0.5684,0.359,0.6558,0.3618,0.5118,2220.7,cuda
↪  ,"selection.csv, 44201
↪  rows",17ac485223fa,9ef44cac68cb,a2ac080
2026-11-08T23:57:00,A,erase15,0,True,249984,0.4916,0.5589,0.3698,0.6583,0.3496,0.5212,2208.3,cuda,
↪  "selection.csv, 44257
↪  rows",4c2c34345077,1a1ca6c18823,c6bf059
2026-11-09T00:37:52,A,erase15,1,True,249984,0.4944,0.5828,0.3856,0.606,0.3543,0.5435,2207.2,cuda,"
↪  selection.csv, 44257
↪  rows",4c2c34345077,1a1ca6c18823,c6bf059
2026-11-09T01:14:53,B,b_baseline,,,176896,0.4895,0.554,0.3755,0.6377,0.3487,0.5314,1637.1,cuda,res
↪  net18 224px;
↪  data/starter/train,,,50530fc
2026-11-09T03:16:31,B,b_control_seed0,0,,176896,0.4861,0.6144,0.3691,0.5986,0.3402,0.5082,2091.5,m
↪  ps,resnet18 224px;
↪  data/starter/train,,,500ed72
2026-11-09T03:52:58,B,b_own_sb_seed0,0,,176896,0.4874,0.5634,0.3719,0.6163,0.3543,0.531,2098.4,mps
↪  ,resnet18 224px; data/starter/train +
↪  data/mine,,,500ed72
2026-11-10T02:05:41,A,baseline_mps,0,True,249984,0.4951,0.5741,0.3957,0.6163,0.3581,0.5314,2829.9,
↪  mps,"selection.csv, 44257
↪  rows",7c1cb9f0ee41,1a1ca6c18823,a108f5c
2026-11-10T02:59:54,A,balanced,0,True,249984,0.5091,0.5133,0.4662,0.5001,0.4497,0.6161,2881.0,mps,
↪  "selection.csv, 44257
↪  rows",e7500546f0a5,1a1ca6c18823,bb6bc15
2026-11-10T20:53:40,B,b_mnv3_448_seed0,0,,249984,0.5794,0.5721,0.5058,0.6217,0.5254,0.6719,7931.0,
↪  mps,mobilenet_v3_large 448px;
↪  data/starter/train,,,49346fe
```

### Original format checks for the six Track A models

```
$ python src/check_submission.py --onnx results/baseline_seed0/model.onnx --size 224 --no-val
# commit a23f9e6
results/baseline_seed0/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  format and limits: OK
```

```
$ python src/check_submission.py --onnx results/baseline_seed1/model.onnx --size 224 --no-val
# commit 0dd327b
results/baseline_seed1/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  format and limits: OK
```

```
$ python src/check_submission.py --onnx results/curated56_seed0/model.onnx --size 224 --no-val
```

```
# commit 9cd86e1
results/curated56_seed0/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  format and limits: OK
```

```
$ python src/check_submission.py --onnx results/curated56_seed1/model.onnx --size 224 --no-val
# commit a2ac080
results/curated56_seed1/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  format and limits: OK
```

```
$ python src/check_submission.py --onnx results/erase15_seed0/model.onnx --size 224 --no-val
# commit c6bf059
results/erase15_seed0/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  format and limits: OK
```

```
$ python src/check_submission.py --onnx results/erase15_seed1/model.onnx --size 224 --no-val
# commit c6bf059
results/erase15_seed1/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  format and limits: OK
```

### Per-city summary lines from mistake-sheet generation

```
seoul: 1029 of 2435 wrong; the 48 most confident on mistakes_baseline_seed0_seoul_00
busan: 843 of 1390 wrong; the 48 most confident on mistakes_baseline_seed0_busan_00
tokyo: 1402 of 3881 wrong; the 48 most confident on mistakes_baseline_seed0_tokyo_00
osaka: 1361 of 2128 wrong; the 48 most confident on mistakes_baseline_seed0_osaka_00
taipei: 1003 of 2243 wrong; the 48 most confident on mistakes_baseline_seed0_taipei_00
```

### Values calculated from the original baseline results

The supplied `make_evidence.py` calculated these values from result JSON files, sheet CSV files, and the baseline recipe. Input files and full run logs are retained in the project's `outputs/` folder.

```
Report evidence calculated from the saved Colab outputs
Recipe SHA-256 = 17ac485223fa61741f2c63aeb1c91bc283c88c6b7aaa8f02fdb3e86924ff29c9
Train photos = 44257
Validation photos = 12077
city,train_photos,validation_photos
seoul,11274,2435
busan,5191,1390
tokyo,13347,3881
osaka,7200,2128
taipei,7245,2243

seed,score,score_percent,training_seconds,training_minutes,commit
0,0.5044,50.44,2238.2,37.3,a23f9e6
1,0.4984,49.84,2179.5,36.3,0dd327b
Mean score = 0.5014 = 50.14%
Absolute score difference = 0.0060 = 0.60 percentage points
batch_size = 64 steps = 3906 presentations = 249984 official_budget = True

city,seed0_percent,seed1_percent
seoul,57.74,56.26
busan,39.42,38.42
tokyo,63.85,61.40
osaka,36.04,38.91
taipei,55.15,54.21

seed,busan_total,busan_errors,predicted_seoul,share_of_errors_percent
0,1390,842,442,52.49
1,1390,856,463,54.09
Busan high-confidence mistake sheet photos = 48
Busan sheet predicted Seoul = 34
Generated city sheets = 5, photos per city = 48, total displayed photos = 240
true_city = busan photo_number = 8 prediction = -> seoul 0.94
true_city = busan photo_number = 48 prediction = -> tokyo 0.85
true_city = seoul photo_number = 11 prediction = -> tokyo 0.90
true_city = seoul photo_number = 46 prediction = -> taipei 0.81

Recorded recipe functions
function = train_transform
return T.Compose([
        T.RandomResizedCrop(224, scale=(0.35, 1.0)),
        T.RandomHorizontalFlip(),
        T.ColorJitter(0.2, 0.2, 0.2),
    ])
function = make_optimizer
return torch.optim.AdamW(model.parameters(), lr=3e-4, weight_decay=0.05)
function = make_scheduler
return torch.optim.lr_scheduler.OneCycleLR(
        optimizer, max_lr=3e-4, total_steps=total_steps, pct_start=0.15)
function = loss_fn
return F.cross_entropy(logits, targets, label_smoothing=0.1)

Leaderboard updated = 2026-11-09 02:41 KST
SoSleepy leaderboard matches = {'A': [], 'B': []}
SoSleepy total matching entries = 0
Track A release = track-a-1
Track A release published = 2026-11-03 14:58:45 KST
Track B release = track-b-1
```

### Evidence for the exclusions and erasing configuration

The evidence script used four full training results, the selection lists, the candidate CSV files, and the new recipe.

Selected training paths are recorded in the following file.

`outputs/curated56_selection.csv`

The exclusion plan is recorded in the following file.

`outputs/curated56_curation_plan.csv`

```
Curation evidence from the baseline and curated56 full Colab runs
Original / removed / retained = 44257 56 44201
Removed percent = 0.12653365569288474
Every-fourth training sample = 11065
Candidate sheets = 10, candidate photos = 480
city,before,removed,after
seoul,11274,9,11265
busan,5191,9,5182
tokyo,13347,20,13327
osaka,7200,6,7194
taipei,7245,12,7233
sheet,selected_numbers
suspects_baseline_seed0_seoul_00,5 10 14 45
suspects_baseline_seed0_seoul_01,2 28 30 37 39
suspects_baseline_seed0_busan_00,1 16 31 45
suspects_baseline_seed0_busan_01,4 24 29 38 40
suspects_baseline_seed0_tokyo_00,4 11 16 19 28 34 42
suspects_baseline_seed0_tokyo_01,1 3 8 10 11 15 16 21 27 33 37 42 48
suspects_baseline_seed0_osaka_00,18 24 28 38 39
suspects_baseline_seed0_osaka_01,33
suspects_baseline_seed0_taipei_00,2 14 30 39 41 45 46
suspects_baseline_seed0_taipei_01,3 11 20 23 41
seed,baseline_percent,curated_percent,delta_pp,train_seconds,commit
0,50.44,49.37,-1.07,2211.8,9cd86e1
1,49.84,49.14,-0.70,2220.7,a2ac080
Mean scores = 0.5014 0.49255 delta = -0.00885
Mean percentages = 50.14 49.26 delta_pp = -0.89
city,baseline_mean_percent,curated_mean_percent,delta_pp
seoul,57.00,57.66,0.66
busan,38.92,36.59,-2.34
tokyo,62.63,64.49,1.86
osaka,37.48,36.11,-1.37
taipei,54.68,51.43,-3.26
Plan SHA-256 = 51af86b1f032400cde628cb33d9fd76252f7f1385ba8985df540603f57018351
Curated selection SHA-256 = 9ef44cac68cb392a341d4a9ec59bea7645e5b3df2757cf189eebe4f5f6c9de55
Restored full selection SHA-256 = 1a1ca6c1882356b84701446e495973c375535d9d64b3cb3d3397c3dfd640f9e4
Random Erasing transform settings used by erase15
return T.Compose([
        T.RandomResizedCrop(224, scale=(0.35, 1.0)),
        T.RandomHorizontalFlip(),
        T.ColorJitter(0.2, 0.2, 0.2),
        T.ToTensor(),
        T.RandomErasing(p=0.5, scale=(0.02, 0.15), ratio=(0.3, 3.3),
                        value=(0.485, 0.456, 0.406)),
    ])
```

### Erasing results and comparison of the three conditions

These values were calculated from the six original Track A results, run records, recipes, and full-photo selection.

```
Random Erasing evidence from the completed Colab runs
seed,baseline_percent,erase15_percent,delta_pp,train_seconds,finished,commit
0,50.44,49.16,-1.28,2208.3,2026-11-08T23:57:00,c6bf059
1,49.84,49.44,-0.40,2207.2,2026-11-09T00:37:52,c6bf059
city,baseline_mean_percent,erase15_mean_percent,delta_pp
seoul,57.00,57.09,0.09
busan,38.92,37.77,-1.15
tokyo,62.63,63.22,0.59
osaka,37.48,35.20,-2.28
taipei,54.68,53.24,-1.45
tag,seed0_percent,seed1_percent,mean_percent,delta_from_baseline_pp
baseline,50.44,49.84,50.14,0.00
curated56,49.37,49.14,49.26,-0.89
erase15,49.16,49.44,49.30,-0.84
Erasing recipe SHA-256 = 4c2c343450775b1250263dc042874317484e9eb9b4262ecbd11c2c28d7fd9b01
Full selection SHA-256 = 1a1ca6c1882356b84701446e495973c375535d9d64b3cb3d3397c3dfd640f9e4
The six Track A full runs are shown above. Track B is reported separately.
```

### Original first Track B training and format-check outputs

```
$ python src/train_b.py --tag b_baseline --model resnet18 --size 224 --epochs 4 --submit
# commit 50530fc
44257 photos (seoul 11274, busan 5191, tokyo 13347, osaka 7200, taipei 7245) on cuda
epoch 1/4: loss 1.362 (412s)
epoch 2/4: loss 1.163 (821s)
epoch 3/4: loss 1.019 (1226s)
epoch 4/4: loss 0.890 (1637s)
validation score 0.489 (seoul 0.554, busan 0.376, tokyo 0.638, osaka 0.349, taipei 0.531)
wrote /content/drive/MyDrive/mas1004/assignment2/results/b_baseline/model.onnx: 11.17 million
↪  parameters, 1.81 billion multiply-adds
copied to submission/. Check it with: python src/check_submission.py
```

```
$ python src/check_submission.py --no-val
# commit 50530fc
/content/drive/MyDrive/mas1004/assignment2/submission/model.onnx: 44.7 MB, 11.17 million
↪  parameters, 1.81 billion multiply-adds per 224 x 224 photo
  limits: 12 million parameters, 2.0 billion multiply-adds
  format and limits: OK
```

### Track B records and public release verification

This summary was calculated from the Colab experiment row, submission metadata, local measurements, and public release and tag query results.

```
Track B evidence from the Colab experiment row, checks and public release
tag,score,training_seconds,presentations,seed,commit,finished
b_baseline,0.4895,1637.1,176896,,50530fc,2026-11-09T01:14:53
city,validation_percent
seoul,55.40
busan,37.55
tokyo,63.77
osaka,34.87
taipei,53.14
Metadata = {'image_size': 224, 'starting_weights': 'torchvision resnet18 IMAGENET1K_V1', 'data':
↪  'data/starter/train', 'summary': 'resnet18 at 224, 4 epochs'}
Measurements = {'parameters': 11174283, 'gmacs': 1.813563904, 'file_mb': 44.707595, 'opset': 17,
↪  'ops': ['Add', 'Conv', 'Div', 'Flatten', 'Gemm', 'GlobalAveragePool', 'MaxPool', 'Relu',
↪  'Sub'], 'problems': []}
Release = track-b-1
Title = Starter ResNet18 at 224, 4 epochs
Published UTC = 2026-11-08T16:22:42Z
Published KST = 2026-11-09 01:22:42 KST
Release URL = https://github.com/jellykeeng/mas1004-assignment2/releases/tag/track-b-1
Tag commit = d4f7ce375856c9d22642cfad265743b57183b1a3
asset = model.onnx bytes = 44707595 SHA-256 =
↪  sha256:5f530de70645fc15d855e2547619ba2e7708e938b6d8eee6b1c6309de52de572
asset = submission.json bytes = 157 SHA-256 =
↪  sha256:5fada1911b259d5d8145d2d26b1b1810ee94bb7b8f3f178a1e4cd96b661982c0
```

### Student-photo preparation and paired-comparison evidence

This summary used the date metadata of the files supplied on 9 November, the city labels confirmed by the student, the actual prepared inventory, and local verification results. Both paired full training runs were completed.

```
Personal photos prepared from the student-confirmed download batch
Scope date = 2026-11-09
Scope date basis = Finder kMDItemDateAdded converted to Asia/Seoul
filename,student_city,date_added_kst
IMG_0237.HEIC,busan,2026-11-09T01:27:30+09:00
IMG_0240.HEIC,busan,2026-11-09T01:27:30+09:00
IMG_0276.HEIC,busan,2026-11-09T01:27:30+09:00
IMG_0286.HEIC,busan,2026-11-09T01:27:30+09:00
IMG_0549.HEIC,seoul,2026-11-09T01:27:30+09:00
IMG_1403.HEIC,busan,2026-11-09T01:27:30+09:00
IMG_1413.HEIC,busan,2026-11-09T01:27:30+09:00
Counts = {'seoul': 1, 'busan': 6} total = 7
Completed control / added-data photos = 44257 44264
Both completed runs use MPS, seed 0, ResNet18 V1 at 224, 4 epochs, batch size 64, workers 0.
Presentations = 176896 176896
Extra photos / starter training photos percent = 0.015816706961610593
Manifest SHA-256 = c885e760cf70bd5ee6757e42487549ade7c61adcaafde8d5c31dbfc413c2450f
Local prepared-photo checks and both full paired runs completed.
Executed commands
python src/check_extra_photos.py --manifest-sha
↪  c885e760cf70bd5ee6757e42487549ade7c61adcaafde8d5c31dbfc413c2450f
python src/train_b.py --tag b_control_seed0 --seed 0 --model resnet18 --size 224 --epochs 4
↪  --workers 0
python src/check_submission.py --submission results/b_control_seed0 --no-val
python src/train_b.py --tag b_own_sb_seed0 --seed 0 --model resnet18 --size 224 --epochs 4
↪  --workers 0 --folders data/starter/train data/mine --submit
python src/check_submission.py --no-val
```

### Original local MPS training and format-check output

```
[1/5] python src/check_extra_photos.py --manifest-sha
↪  c885e760cf70bd5ee6757e42487549ade7c61adcaafde8d5c31dbfc413c2450f
{
  "manifest_sha256": "c885e760cf70bd5ee6757e42487549ade7c61adcaafde8d5c31dbfc413c2450f",
  "total": 7,
  "counts": {
    "seoul": 1,
    "busan": 6
  }
}

[2/5] python src/train_b.py --tag b_control_seed0 --seed 0 --model resnet18 --size 224 --epochs 4
↪  --workers 0
44257 photos (seoul 11274, busan 5191, tokyo 13347, osaka 7200, taipei 7245) on mps
epoch 1/4: loss 1.369 (524s)
epoch 2/4: loss 1.164 (1046s)
epoch 3/4: loss 1.019 (1570s)
epoch 4/4: loss 0.891 (2092s)
validation score 0.486 (seoul 0.614, busan 0.369, tokyo 0.599, osaka 0.340, taipei 0.508)
wrote /Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assign
↪  ment2-work/mas1004-assignment2/results/b_control_seed0/model.onnx: 11.17 million parameters,
↪  1.81 billion multiply-adds

[3/5] python src/check_submission.py --submission results/b_control_seed0 --no-val
results/b_control_seed0/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion multiply-adds
↪  per 224 x 224 photo
  limits: 12 million parameters, 2.0 billion multiply-adds
  format and limits: OK

[4/5] python src/train_b.py --tag b_own_sb_seed0 --seed 0 --model resnet18 --size 224 --epochs 4
↪  --workers 0 --folders data/starter/train data/mine --submit
44264 photos (seoul 11275, busan 5197, tokyo 13347, osaka 7200, taipei 7245) on mps
epoch 1/4: loss 1.366 (517s)
epoch 2/4: loss 1.159 (1033s)
epoch 3/4: loss 1.014 (1563s)
epoch 4/4: loss 0.886 (2098s)
validation score 0.487 (seoul 0.563, busan 0.372, tokyo 0.616, osaka 0.354, taipei 0.531)
wrote /Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assign
↪  ment2-work/mas1004-assignment2/results/b_own_sb_seed0/model.onnx: 11.17 million parameters,
↪  1.81 billion multiply-adds
copied to submission/. Check it with: python src/check_submission.py

[5/5] python src/check_submission.py --no-val
/Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assignment2-
↪  work/mas1004-assignment2/submission/model.onnx: 44.7 MB, 11.17 million parameters, 1.81
↪  billion multiply-adds per 224 x 224 photo
  limits: 12 million parameters, 2.0 billion multiply-adds
  format and limits: OK

All queued runs are done.
```

### MPS scores and verification evidence

This summary cross-checked the two experiment CSV rows, comparison result JSON, both submission metadata files, actual run log, and photo-inventory checks. The original JSON is retained in `outputs/local_mps_comparison_seed0.json`.

```
Completed local MPS comparison, one seed per condition
Common conditions = {'seed': 0, 'model': 'resnet18', 'image_size': 224, 'epochs': 4, 'batch_size':
↪  64, 'workers': 0, 'presentations_per_run': 176896, 'validation_photos': 12077}
```

```
Train photos = 44257 44264
tag,score_percent,train_seconds,train_minutes,finished_kst,commit
b_control_seed0,48.61,2091.5,34.9,2026-11-09T03:16:31,500ed72
b_own_sb_seed0,48.74,2098.4,35.0,2026-11-09T03:52:58,500ed72
metric,control_percent,extra_percent,extra_minus_control_pp
val_score,48.61,48.74,0.13
seoul,61.44,56.34,-5.10
busan,36.91,37.19,0.28
tokyo,59.86,61.63,1.77
osaka,34.02,35.43,1.41
taipei,50.82,53.10,2.28
Model = b_control_seed0
SHA-256 = 82d6396475d1343a8e24ca17597cc9a37d3b66d304c0989367c7d42bbcc3d632
File bytes = 44707595
Measurements = {'parameters': 11174283, 'gmacs': 1.813563904, 'file_mb': 44.707595, 'opset': 17,
↪  'ops': ['Add', 'Conv', 'Div', 'Flatten', 'Gemm', 'GlobalAveragePool', 'MaxPool', 'Relu',
↪  'Sub'], 'problems': []}
Full ONNX check and batch 1 / 3 CPU inference passed.
Model = b_own_sb_seed0
SHA-256 = 5a5d6a95bd853c531031412de841665012d232085c1bec07ae33abf09d22c3e4
File bytes = 44707595
Measurements = {'parameters': 11174283, 'gmacs': 1.813563904, 'file_mb': 44.707595, 'opset': 17,
↪  'ops': ['Add', 'Conv', 'Div', 'Flatten', 'Gemm', 'GlobalAveragePool', 'MaxPool', 'Relu',
↪  'Sub'], 'problems': []}
Full ONNX check and batch 1 / 3 CPU inference passed.
Local submission = b_own_sb_seed0
Both local models are retained separately.
One seed per condition; the observed +0.13 pp is insufficient to establish a consistent benefit.
The earlier CUDA baseline used an unspecified seed. The data-effect comparison uses the matched
↪  MPS control.
Recorded commands verified in the combined execution log = 5
```

### Submission checks and selection recorded on 9 November

These checks preceded the balanced-sampling release. The earlier MPS smoke-check error is retained in `outputs/final_track_a_quick_mps_failed.txt`.

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
Track A, seed 0, on cpu: selection.csv, 44257 rows (seoul 11274, busan 5191, tokyo 13347, osaka
↪  7200, taipei 7245)
20 steps of 64 photos = 1,280 photos through the network
  step     2/20  loss 1.751  (18s)
  step     4/20  loss 1.722  (37s)
  step     6/20  loss 1.666  (55s)
  step     8/20  loss 1.522  (74s)
  step    10/20  loss 1.533  (94s)
  step    12/20  loss 1.590  (112s)
  step    14/20  loss 1.595  (131s)
  step    16/20  loss 1.657  (151s)
  step    18/20  loss 1.622  (170s)
  step    20/20  loss 1.616  (188s)

validation score 0.229  (seoul 0.293, busan 0.000, tokyo 0.692, osaka 0.057, taipei 0.105)
training took 3.1 min; wrote
↪  results/final_submission_check/track_a_quick/final_check_seed0/model.onnx
This was not an official run (--quick or a different --budget). The grader's numbers will differ.
A full run on this computer (cpu) would take about 625 minutes: 611 for training and 14 for the
↪  validation photos.
```

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
/Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assignment2-⌋
↪  work/mas1004-assignment2/submission/model.onnx: 44.7 MB, 11.17 million parameters, 1.81
↪  billion multiply-adds per 224 x 224 photo
  limits: 12 million parameters, 2.0 billion multiply-adds
  format and limits: OK

/Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assignment2-⌋
↪  work/mas1004-assignment2/data/starter/val: score 0.489 on 12077 photos
↪  (238s)
  seoul 0.554, busan 0.376, tokyo 0.637, osaka 0.349, taipei 0.531
  confusion (rows: true city, columns: answer):
    seoul    1349   177   440   156   313
    busan     436   522   235    69   128
    tokyo     557    94  2474   498   258
    osaka     257    73   901   742   155
    taipei    352    77   482   140  1192
```

```
Final selection from all nine recorded full training runs
Track A = track-a-1 baseline, all 44257 photos, mean 50.14 percent
Track A quick check = passed on CPU, 20 steps / 1280 presentations
Track B = track-b-1 b_baseline
Track B training / ONNX CPU scores = 0.4895 / 0.48942471513433666
Track B ONNX CPU validation photos = 12077
Track B ONNX CPU validation percent = 48.94
Published record commit = b8b87fa93dbde8e0ca19ab51dbe993187a6714e9
Published assets match the selected local files. Both later models are retained.
Leaderboard updated = 2026-11-09 02:41 KST
SoSleepy matches = {'A': [], 'B': []}
Saved registration response exact field matches = {'student_number': True, 'repository_url': True,
↪  'nickname': True}
Registration read-only check KST = 2026-11-09T10:41:11+09:00
Registration verification record commit = 6918fdbddd4899508fd980a37925388227fdf036
```

### Balanced sampling, matched local comparison, and final release

```
Matched Track A comparison on local MPS, seed 0
Full training photos = 44257; validation photos = 12077
Both runs = 3906 steps x 64 photos = 249984 presentations
Shared MPS input-layout workaround; pinned torch 2.6.0
Baseline control = 49.51 percent, 2829.9 seconds
Balanced sampling = 50.91 percent, 2881.0 seconds
Difference = +1.40 percentage points

City       Control (%)  Balanced (%)  Difference (pp)
seoul            57.41         51.33            -6.08
busan            39.57         46.62            +7.05
tokyo            61.63         50.01           -11.62
osaka            35.81         44.97            +9.16
taipei           53.14         61.61            +8.47

One run per local condition. Repeated-seed effect is unmeasured.
The earlier CUDA baseline (50.44% seed 0; 50.14% two-seed mean) used a different execution path.
Full training records = 11 total, 8 Track A, 3 Track B.
Both recipe snapshots match the committed source recorded in their result JSON.
CSV rows match result JSON; scores were checked against the confusion matrices.
Official protected sources match the repository state before this experiment.
Final recipe SHA-256 = e7500546f0a59a23f9bb7757b404c87ff61010c9f3d1b634d6c164a6335ecfe4
Full selection SHA-256 = 1a1ca6c1882356b84701446e495973c375535d9d64b3cb3d3397c3dfd640f9e4
```

```
Sampling audit using official.draw_order, seed 0
Full original selection and order = verified (44257 rows)
Weight for each photo = 1 / selected photo count of its city
Total weight per city = 1.0; sampling probability per city = 0.2
Balanced sampling uses replacement.

City       Training photos  Control draws  Balanced draws
seoul                11274          63646           50153
busan                 5191          29328           49745
tokyo                13347          75426           50023
osaka                 7200          40670           49939
taipei                7245          40914           50124

Total draws in each condition = 249984
Unique photos drawn in control = 44257
Unique photos drawn with balanced sampling = 43818
Recipe rules = OK
```

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
Track A, seed 0, on mps: selection.csv, 44257 rows (seoul 11274, busan 5191, tokyo 13347, osaka
↪  7200, taipei 7245)
3906 steps of 64 photos = 249,984 photos through the network
  step   390/3906  loss 1.435  (284s)
  step   780/3906  loss 1.294  (568s)
  step  1170/3906  loss 1.188  (850s)
  step  1560/3906  loss 1.130  (1132s)
  step  1950/3906  loss 1.071  (1416s)
  step  2340/3906  loss 0.995  (1697s)
  step  2730/3906  loss 0.943  (1975s)
  step  3120/3906  loss 0.859  (2255s)
  step  3510/3906  loss 0.821  (2540s)
  step  3900/3906  loss 0.779  (2826s)
  step  3906/3906  loss 0.771  (2830s)

validation score 0.495  (seoul 0.574, busan 0.396, tokyo 0.616, osaka 0.358, taipei 0.531)
```

```
training took 47.2 min; wrote /Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-
↪  bc77-bab34c8f2a3f/assignment2-work/mas1004-assignment2/results/baseline_mps_seed0/model.onnx
```

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
Track A, seed 0, on mps: selection.csv, 44257 rows (seoul 11274, busan 5191, tokyo 13347, osaka
↪  7200, taipei 7245)
3906 steps of 64 photos = 249,984 photos through the network
  step   390/3906  loss 1.435  (286s)
  step   780/3906  loss 1.261  (584s)
  step  1170/3906  loss 1.156  (867s)
  step  1560/3906  loss 1.086  (1153s)
  step  1950/3906  loss 1.025  (1436s)
  step  2340/3906  loss 0.953  (1721s)
  step  2730/3906  loss 0.884  (2013s)
  step  3120/3906  loss 0.827  (2303s)
  step  3510/3906  loss 0.788  (2591s)
  step  3900/3906  loss 0.765  (2877s)
  step  3906/3906  loss 0.784  (2881s)

validation score 0.509  (seoul 0.513, busan 0.466, tokyo 0.500, osaka 0.450, taipei 0.616)
training took 48.0 min; wrote /Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-
↪  bc77-bab34c8f2a3f/assignment2-work/mas1004-assignment2/results/balanced_seed0/model.onnx
```

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
Track A, seed 0, on mps: selection.csv, 44257 rows (seoul 11274, busan 5191, tokyo 13347, osaka
↪  7200, taipei 7245)
20 steps of 64 photos = 1,280 photos through the network
  step     2/20  loss 1.776  (2s)
  step     4/20  loss 1.672  (3s)
  step     6/20  loss 1.658  (5s)
  step     8/20  loss 1.640  (6s)
  step    10/20  loss 1.735  (7s)
  step    12/20  loss 1.551  (9s)
  step    14/20  loss 1.516  (10s)
  step    16/20  loss 1.620  (12s)
  step    18/20  loss 1.630  (13s)
  step    20/20  loss 1.549  (14s)

validation score 0.208  (seoul 0.146, busan 0.217, tokyo 0.292, osaka 0.171, taipei 0.211)
training took 0.2 min; wrote
↪  results/balanced_20261110_checks/quick_mps_release/balanced_release_quick_seed0/model.onnx
This was not an official run (--quick or a different --budget). The grader's numbers will differ.
A full run on this computer (mps) would take about 49 minutes: 47 for training and 2 for the
↪  validation photos.
```

```
Final public release verification
Checked at 2026-11-10T03:07:14+09:00
Track A = track-a-2, Balanced sampling
Published at 2026-11-10T03:05:01+09:00
Draft = false; prerelease = false; both assets uploaded
Recipe and full selection downloaded anonymously with HTTP 200.
Downloaded bytes and SHA-256 match the checked local files.
recipe.py bytes = 3237
recipe.py SHA-256 = e7500546f0a59a23f9bb7757b404c87ff61010c9f3d1b634d6c164a6335ecfe4
selection.csv bytes = 1345856
selection.csv SHA-256 = 1a1ca6c1882356b84701446e495973c375535d9d64b3cb3d3397c3dfd640f9e4
Track B = track-b-1, first model previously checked and selected
Current model and metadata hashes match the published asset digests.
Track A and Track B publication dates are before 2026-11-10 22:00 KST.
```

### Balanced-model reuse and the second Track B release

The official checker evaluated all 12,077 validation photographs. The public release files were retrieved anonymously and matched the checked candidates.

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
results/balanced_track_b_candidate/model.onnx: 44.7 MB, 11.17 million parameters, 1.81 billion
↪  multiply-adds per 224 x 224 photo
  limits: 12 million parameters, 2.0 billion multiply-adds
  format and limits: OK

/Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assignment2-
↪  work/mas1004-assignment2/data/starter/val: score 0.509 on 12077 photos
↪  (274s)
  seoul 0.513, busan 0.466, tokyo 0.500, osaka 0.450, taipei 0.616
  confusion (rows: true city, columns: answer):
    seoul    1250   268   304   202   411
    busan     364   648   122    93   163
    tokyo     569   170  1941   687   514
    osaka     256   122   548   957   245
    taipei    314   100   273   174  1382
```

```
Track B final selection by reusing the completed balanced Track A model
Source training = balanced_seed0, commit bb6bc15
MPS seed 0; 3906 steps x 64 = 249984 presentations
Evaluation = official check_submission.py, ONNX Runtime CPU, all 12077 validation photos
Previous B1 validation = 48.94 percent
Balanced candidate validation = 50.91 percent
Difference in validation = +1.97 percentage points
B1 leaderboard = 38.26 percent, rank 26 of 27, snapshot 2026-11-10 17:04 KST

City       B1 ONNX CPU (%)  Balanced ONNX CPU (%)
seoul                55.40                  51.33
busan                37.55                  46.62
tokyo                63.75                  50.01
osaka                34.87                  44.97
taipei               53.14                  61.61

Format and Track B limits = OK
Parameters = 11174283
GMACs = 1.813563904
Model bytes = 44707595
New model SHA-256 = ea94e4de284f9e685ba3736214871542069943c210bddade7287c0f13ffbefd5
The candidate predictions match the original MPS validation confusion matrix.
Model reuse added no training run. Full training record count = 11.
B1 and the reused model have different training budgets, devices, and seed settings.
Their validation comparison supports model selection and does not isolate the sampling effect.
A leaderboard score for the new model requires a new grading result.
```

```
Track B balanced-model public release verification
Tag = track-b-2
Title = ResNet18 at 224, balanced sampling, seed 0
Published at 2026-11-10T17:32:25+09:00
Target commit = 8a8245dc5a147f567a72d1d5d205cddce5fb1e2b
Both assets uploaded and downloaded anonymously with HTTP 200.
model.onnx bytes = 44707595
model.onnx SHA-256 = ea94e4de284f9e685ba3736214871542069943c210bddade7287c0f13ffbefd5
submission.json bytes = 197
submission.json SHA-256 = d1f5eca299ace908479ffae7f05ba16a9498029ca0f001640b09b2581e621897
Published bytes match the fully validated local candidate.
```

```
Public leaderboard after the second Track B release
Source = https://jdasam.github.io/mas1004-leaderboard/board.json
Updated = 2026-11-10 17:45 KST
Checked = 2026-11-10T17:54:05+09:00
Nickname = SoSleepy
Track B tag = track-b-2
Previous B1 published score = 0.3826 (38.26 percent)
New B2 published score = 0.4203 (42.03 percent)
Score increase = 3.77 percentage points
Rank = 14 of 27 scored models
Displayed starter-model reference = 40.3 percent
Published per-city values are rounded in the source data.
seoul = 62.3 percent
busan = 30.9 percent
tokyo = 61.8 percent
osaka = 30.0 percent
taipei = 25.1 percent
No matching nickname in Track A. The official Track A score remains unavailable.
The local balanced seed-0 validation score of 50.91 percent uses the starter validation set.
These leaderboard results refer specifically to track-b-2.
```

```
Public leaderboard after Track A grading
Source = https://jdasam.github.io/mas1004-leaderboard/board.json
Updated = 2026-11-10 20:33 KST
Checked = 2026-11-10T20:42:31+09:00
Nickname = SoSleepy
Track A = track-a-2, score 41.06 percent, rank 11 of 28
Track A three-seed public range = 40.19 to 42.22 percent
Track A three-seed starter-validation mean = 50.2233 percent
Track B = track-b-2, score 42.03 percent, rank 15 of 28
Displayed starter-recipe reference = 40.1 percent
Displayed starter-model reference = 40.3 percent
A gain over the rounded reference = 0.96 percentage points
B2 gain over the rounded reference = 1.73 percentage points
A seoul = 58.6000 percent
A busan = 28.3667 percent
A tokyo = 62.1667 percent
A osaka = 29.4667 percent
A taipei = 26.7000 percent
B seoul = 62.3000 percent
B busan = 30.9000 percent
B tokyo = 61.8000 percent
B osaka = 30.0000 percent
B taipei = 25.1000 percent
The final private evaluation split has not been reported.
References are rounded as displayed on the public page.
```

### Final MobileNet 448 training, validation, and release evidence

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
44257 photos (seoul 11274, busan 5191, tokyo 13347, osaka 7200, taipei 7245) on mps
step 781/7812: loss 1.417 (810s)
step 1562/7812: loss 1.270 (1588s)
step 2343/7812: loss 1.179 (2361s)
step 3124/7812: loss 1.116 (3154s)
step 3905/7812: loss 1.064 (3948s)
step 4686/7812: loss 1.018 (4747s)
step 5467/7812: loss 0.979 (5544s)
step 6248/7812: loss 0.943 (6333s)
step 7029/7812: loss 0.912 (7137s)
step 7810/7812: loss 0.886 (7928s)
step 7812/7812: loss 0.886 (7931s)
epoch 1/1: loss 0.886 (7931s)
validation score 0.579 (seoul 0.572, busan 0.506, tokyo 0.622, osaka 0.525, taipei 0.672)
wrote /Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assign
↪  ment2-work/mas1004-assignment2/results/b_mnv3_448_seed0/model.onnx: 4.20 million parameters,
↪  0.85 billion multiply-adds
```

```
Final MobileNetV3-Large 448 experiment
Tag = b_mnv3_448_seed0
Training source commit = 49346fe
Training script SHA-256 = 2644cbf3f0b04f2dfb4315dda1a70230b8617b250017763558b5f4ab45d65093
Training device = MPS, seed = 0, workers = 0
Starting weights = torchvision mobilenet_v3_large IMAGENET1K_V2
Training data = all 44257 starter photographs, balanced sampling
Batch size = 32, steps = 7812, presentations = 249984
Training seconds = 7931.0, minutes = 132.18
Final mean training loss printed by train_b.py = 0.886
Full training-time validation = 0.579364052763462 (57.94 percent), 12077 photographs
Validation inference batch size in train_b.py = 128
Finished and exported = 2026-11-10T20:53:40 KST
Recorded ONNX export gap = 3.6358833313e-06
Model bytes = 16825941
Model SHA-256 = e18718be94887a770658f32c5af64f84b9a43018ae601bd6ad7a0b7d6e999dd0

City       Balanced MPS (%)  MobileNet 448 MPS (%)  Change (pp)
seoul                 51.33                  57.21         5.88
busan                 46.62                  50.58         3.96
tokyo                 50.01                  62.17        12.16
osaka                 44.97                  52.54         7.57
taipei                61.61                  67.19         5.58
Overall mean = 50.91 to 57.94 percent, an increase of 7.03 percentage points.
The comparison changes architecture, pretrained weights, resolution, and batch size.
Optimizer updates change from 3906 to 7812 with the same presentation budget.
Both conditions use MPS, seed 0, full starter training data, balanced sampling, and full
↪  validation.
Only one full run was completed per new condition. The student cancelled MobileNet 224.
Full training count = 12, including 8 Track A and 4 Track B runs.
Quick checks are stored in a separate CSV and are excluded from this count.

Full official ONNX/CPU submission verification
Command = uv run python src/check_submission.py --submission results/b_mnv3_448_seed0
CPU score = 0.5793640527634617 (57.94 percent)
CPU confusion matrix matches the complete MPS validation result.
CPU validation = 12077 photographs, 209 seconds
Official exported-model parameters = 4196243
Official GMACs = 0.85303744
Training command = uv run python src/train_b.py --tag b_mnv3_448_seed0 --model mobilenet_v3_large
↪  --size 448 --batch-size 32 --steps 7812 --seed 0 --balance --workers 0
```

```
warning: Using incompatible environment (`.venv`) due to `--no-sync` (The project environment's
↪  Python interpreter does not meet the Python preference: `only managed`)
results/b_mnv3_448_seed0/model.onnx: 16.8 MB, 4.20 million parameters, 0.85 billion multiply-adds
↪  per 448 x 448 photo
  limits: 12 million parameters, 2.0 billion multiply-adds
  format and limits: OK

/Users/seoyoung/.codex/visualizations/2026/10/24/01a16bf5-3269-7541-bc77-bab34c8f2a3f/assignment2-
↪  work/mas1004-assignment2/data/starter/val: score 0.579 on 12077 photos
↪  (209s)
  seoul 0.572, busan 0.506, tokyo 0.622, osaka 0.525, taipei 0.672
  confusion (rows: true city, columns: answer):
    seoul    1393   308   281   151   302
    busan     409   703   101    82    95
    tokyo     383    93  2413   677   315
    osaka     164    78   587  1118   181
    taipei    315    60   232   129  1507
```

```
Final MobileNet 448 public release verification
Tag = track-b-3
Title = MobileNetV3-Large at 448, balanced sampling
URL = https://github.com/jellykeeng/mas1004-assignment2/releases/tag/track-b-3
Published = 2026-11-10T21:00:46+09:00
Target commit = 595003fe99618621e28181bf2a176dd5be6e54a1
Both assets uploaded and retrieved anonymously with HTTP 200.
model.onnx bytes = 16825941
model.onnx SHA-256 = e18718be94887a770658f32c5af64f84b9a43018ae601bd6ad7a0b7d6e999dd0
submission.json bytes = 257
submission.json SHA-256 = fef09ffebc7e6386435ac730873f884704b7a10ea0fd6d4bb43494b3e9d9ed0a
Published files match the fully validated local model and metadata.
```

```
Final public leaderboard scores for the selected releases
Source = https://jdasam.github.io/mas1004-leaderboard/board.json
Updated = 2026-11-10 21:04 KST
Checked = 2026-11-10T21:07:33+09:00
Track A = track-a-2, 41.06 percent, rank 11 of 29
Track A server-side three-seed validation mean = 50.2233 percent
Track B = track-b-3, 45.02 percent, rank 3 of 28
Previous B2 public score = 42.03 percent
Public B improvement = 2.99 percentage points
Displayed starter references = A 40.1 percent, B 40.3 percent
Final A gain over its rounded reference = 0.96 percentage points
Final B gain over its rounded reference = 4.72 percentage points
B3 ONNX/CPU validation = 57.94 percent on the separate starter-validation set

City       Previous B2 public (%)  Final B3 public (%)  Change (pp)
seoul                        62.3                 63.8          1.5
busan                        30.9                 30.4         -0.5
tokyo                        61.8                 76.3         14.5
osaka                        30.0                 34.8          4.8
taipei                       25.1                 19.8         -5.3
Local validation increased for all five cities.
Public accuracy increased for Seoul, Tokyo, and Osaka, and decreased for Busan and Taipei.
This is a one-seed configuration comparison with multiple training factors changed.
The private final evaluation after the deadline remains a separate evaluation set.
```

### Occlusion measurements and replacement-control evidence

This summary cross-checked the analysis JSON, case-level and region-level CSV files, and original logit arrays. The original arrays are retained in `outputs/occlusion_raw_outputs.npz`.

```
Occlusion analysis of the selected final Track B model
Model SHA-256 = 5f530de70645fc15d855e2547619ba2e7708e938b6d8eee6b1c6309de52de572
Selection = seed 0, 32 validation photos per city, first correct / incorrect
Cases = 10, masked inputs = 490, patch = 32 by 32, gray RGB = 0.5
Target = each photo's original predicted class, fixed across all masks
case,original_prediction,original_percent,masked_target_percent,changed_masks
seoul_correct,seoul,65.0,42.9,1
seoul_incorrect,busan,55.1,41.1,0
busan_correct,busan,40.6,31.1,1
busan_incorrect,tokyo,34.9,29.0,9
tokyo_correct,tokyo,85.1,78.4,0
tokyo_incorrect,seoul,64.8,48.7,0
osaka_correct,osaka,93.0,90.6,0
osaka_incorrect,tokyo,45.4,32.2,4
taipei_correct,taipei,39.0,28.4,0
taipei_incorrect,seoul,55.5,38.1,0
Prediction changes = 15 of 490 masks, in 4 of 10 selected cases
Replacement controls at the same Osaka patch x [64,96), y [96,128)
replacement,tokyo_percent,osaka_percent,prediction
Original,45.4,19.9,tokyo
Gray 0.50,32.2,34.7,osaka
Local sky mean,43.8,21.2,tokyo
Blur radius 8,45.6,19.9,tokyo
Gray 0.25,36.1,29.9,tokyo
Gray 0.75,32.5,36.8,osaka
Interpretation is conditional on these photos and replacement choices.
The original model information and inserted patch appearance both change.
Recorded full training runs = 9. This is post-training input perturbation analysis.
```

## D Lab notebook in its original language

The complete dated entries of `LOG.md` are reproduced below in their original language, including the student's Korean statements. English translations of the relevant observations appear in the main report. The original file including template guidance is retained in `outputs/LOG_original.md`.

```
## 2026-11-05 baseline (Track A, seed 0)

- 목적: 변경 전 스타터 레시피의 전체 학습 결과를 비교 기준으로 기록한다.
- 조건: 스타터 레시피 그대로, 전체 훈련 사진 44,257장, ResNet18, 입력 224 x 224,
  batch size 64, seed 0, CUDA. 3,906 steps로 249,984회 사진을 제시했다.
- 코드: commit `a23f9e6`, recipe SHA-256
  `17ac485223fa61741f2c63aeb1c91bc283c88c6b7aaa8f02fdb3e86924ff29c9`.
  결과 파일의 recipe hash가 `track-a-1`에 게시한 레시피와 일치한다.
- 검증: 사진 12,077장에 대한 도시별 정확도의 평균 **0.5044**.

| 도시 | 검증 정확도 |
| --- | ---: |
| Seoul | 0.5774 |
| Busan | 0.3942 |
| Tokyo | 0.6385 |
| Osaka | 0.3604 |
| Taipei | 0.5515 |

- 학습 시간: 2,238.2초 (약 37.3분). 데이터 준비, 검증, 내보내기 시간은 별도다.
- Colab의 ONNX 검사 출력: 44.7 MB, 11.17 million parameters,
  1.81 billion multiply-adds at 224 x 224; `format and limits: OK`.
- 수치 관찰: 오사카의 정확도가 가장 낮다. 혼동행렬에서 실제 오사카 2,128장 중
  855장을 도쿄로 예측했다 (약 40.18%, 결과 JSON에서 계산).
- 해석의 범위: seed 0 한 번의 검증 결과다. 리더보드 점수와는 다른 데이터에서
  측정한 값이며, 아직 개선 실험의 결과나 seed 간 변동 폭은 없다.
- 학생이 사진을 직접 보고 내린 판단: 아직 기록되지 않았다.
- 원본: 2026-11-05에 받은 `from_colab.zip`의
  `results/baseline_seed0/result.json`, `results/colab_experiments.csv`,
  `results/colab_logs/1105_151903_official_baseline_seed0.txt`,
  `results/colab_logs/1105_155816_check_submission.txt`.
  Track A 모델은 ZIP에 포함하지 않는 노트북의 기본 동작에 따라 Colab Drive에 남아 있다.

### 다음 계획

1. 레시피와 훈련 사진은 유지하고 seed 1로 같은 기준 실험을 실행한다.
2. 두 실행의 점수 차이를 확인한 후, 오답 사진을 직접 살펴본다.
3. 사진에서 관찰한 내용을 바탕으로 변경할 항목을 하나 정하고 그 효과를 측정한다.

## 2026-11-05 baseline (Track A, seed 1)

- 변경: seed 0에서 seed 1로만 변경했다. 레시피, 전체 훈련 사진, batch size,
  steps, 예산, 모델과 입력 크기는 첫 기준 실험과 동일하다.
- 목적: 같은 학습 방법에서 난수 선택에 따른 점수 차이를 관찰한다.
- 코드: commit `0dd327b`, recipe hash `17ac485223fa` (seed 0과 동일).
- 검증: 사진 12,077장에 대한 도시별 정확도의 평균 **0.4984**.

| 도시 | seed 0 | seed 1 |
| --- | ---: | ---: |
| Seoul | 0.5774 | 0.5626 |
| Busan | 0.3942 | 0.3842 |
| Tokyo | 0.6385 | 0.6140 |
| Osaka | 0.3604 | 0.3891 |
| Taipei | 0.5515 | 0.5421 |
| 도시별 정확도의 평균 | 0.5044 | 0.4984 |

- 두 실행의 검증 점수 평균: **0.5014**. 절대 차이: **0.0060 (0.60%p)**.
  `result.json` 두 개의 `val_score`에서 계산했다.
- 해석의 범위: 방법을 바꾸지 않아도 이번 두 실행에서 0.60%p 차이가 났다.
  작은 점수 상승 한 번만으로 개선 효과를 단정하지 않는다. 두 번의 실행으로
```

  전체 변동 범위나 통계적 유의성을 추정한 것은 아니다.
- 학습 시간: 2,179.5초 (약 36.3분). 준비, 검증, 내보내기 시간은 별도다.
- Colab의 ONNX 검사 출력: 44.7 MB, 11.17 million parameters,
  1.81 billion multiply-adds at 224 x 224; `format and limits: OK`.
- 학생이 사진을 직접 보고 내린 판단: 아직 기록되지 않았다.
- 원본: `from_colab-2.zip`의 `results/baseline_seed1/result.json`,
  `results/colab_experiments.csv`,
  `results/colab_logs/1105_161517_official_baseline_seed1.txt`,
  `results/colab_logs/1105_165326_check_submission.txt`.

### 다음 계획

1. Colab에서 seed 0 모델이 검증 사진을 확신하면서 틀린 사례를 도시별 48장씩
   모은다 (`curate.py mistakes`, `results/curate/`). 이 모음은 전체 사진의
   무작위 표본이 아니라 확신이 높은 오답을 골라 본 자료다.
2. 학생이 사진 모음을 직접 보고 공통점을 적는다.
3. 학생의 관찰을 바탕으로 변경할 항목을 하나 정한 뒤, 같은 seed와 예산으로
   변경 전후를 비교한다. 아직 사진 제외나 레시피 변경은 하지 않았다.

## 2026-11-05 baseline 오답 사진 모음

- 실행: `python src/curate.py mistakes results/baseline_seed0/model.onnx --n 48`
  (commit `7e8ccc8`).
- 결과: 검증 사진 12,077장에 seed 0 ONNX 모델을 적용한 후, 도시별로 확신이 높은
  오답 48장씩을 골라 총 240장의 사진을 5개 모음으로 저장했다.
- 파일: `results/curate/mistakes_baseline_seed0_<city>_00.png`와 같은 이름의 CSV.
  `<city>`는 seoul, busan, tokyo, osaka, taipei다.
- 모음의 도시 이름은 정답 라벨이고, 사진 아래 화살표 뒤의 도시는 모델의 예측이다.
  숫자는 softmax 출력 확률이다. 번호는 같은 이름의 CSV에 있는 사진 경로와 대응한다.
- 이 모음은 확신이 높은 오답을 살펴보는 자료이며, 전체 검증 사진의 무작위 표본은
  아니다. 기존의 기준 실험 점수는 `official.py`의 `result.json` 값을 유지한다.
- 원본: `from_colab-3.zip`과
  `results/colab_logs/1105_165739_curate_mistakes.txt`.
- 이 단계는 사진 검토 준비이므로 `experiments.csv`에 새 학습 행을 추가하지 않았다.
- 학생의 사진 관찰과 개선 결정: 응답 대기.

### 다음 계획

1. 학생이 도시별 사진 모음을 직접 보고 공통적인 특징 두 가지를 설명한다.
2. 관찰에서 나온 개선 가설을 하나 정하고, 훈련 사진 선택 또는 학습 방법 중
   해당 항목 하나를 변경해 기준 실험과 비교한다.

## 2026-11-05 학생의 사진 관찰: 오사카와 부산

학생이 오답 사진 모음을 직접 보고 남긴 말:

> 오사카 - 신사, 주택, 주택가 같은 경우 인도가 없음
>
> 부산 - 좀 더 어지럽고 왁자직껄, 부산스러움, 8번 같은 경우 주택가인데 차가 세워져 있음 (일본은 주택가에
↪  도로에 차가 안 세워져 있는듯)

- 검토한 모음: `mistakes_baseline_seed0_osaka_00`와
  `mistakes_baseline_seed0_busan_00`. 부산의 구체적인 사례로 8번을 지목했다.
- 일본 주택가의 노상 주차에 대한 말은 학생이 이번 사진에서 세운 비교 가설이다.
  도시 전체에 적용되는 사실이나 모델이 실제로 사용한 단서로 확정하지 않는다.
- 다음 단계에 대한 학생의 선택: **다른 도시의 오답 사진도 먼저 보기**.
  서울, 도쿄, 타이베이 모음을 추가로 검토한 다음 첫 개선 실험을 정한다.

### 다음 계획

1. 서울, 도쿄, 타이베이 오답 사진 모음을 학생에게 보여준다.
2. 학생의 추가 관찰을 기록하고, 학생이 선택한 변경 항목 하나의 효과를 측정한다.

## 2026-11-05 학생의 추가 관찰: 부산과 서울

학생의 말 (발췌):

> 부산은 바다가 있는 것을 제외하고는 많은 부분이 서울이랑 비슷한 것 같아 그래서 오답이 서울이 많은 것 같아
↪ 부산에

- 학생의 가설: 서울과 부산에 공통적인 대도시 풍경이 있어서 모델이 둘을 혼동할 수 있다.
- 확인한 오답 패턴: 부산 오답 모음 48장의 CSV에서 34장이 서울 예측이다.
  이 모음은 확신이 높은 오답만 골라 놓은 자료다.
- 전체 검증 결과의 혼동행렬로도 확인했다. 아래 값은 각 실행의 `result.json`에서
  실제 부산 행을 읽어 계산한 값이다.

| 실행 | 부산 검증 사진 | 부산 오답 수 | 서울로 예측한 수 | 부산 오답 중 서울 예측 비율 |
| --- | ---: | ---: | ---: | ---: |
| seed 0 | 1390 | 842 | 442 | 52.49% |
| seed 1 | 1390 | 856 | 463 | 54.09% |

- 두 기준 실험 모두 부산 오답의 절반 이상이 서울 예측이다. 학생이 지적한 혼동
  패턴은 수치에서도 나타난다. 풍경의 유사성이 그 원인인지는 아직 검증할 가설이다.

### 다음 계획

서울, 도쿄, 타이베이 사진을 더 살펴본 뒤 학생이 첫 개선 실험의 항목을 선택한다.

## 2026-11-05 서울 사진 11번과 46번 검토

- 학생이 지목한 시각적 단서: 11번의 대한항공 비행기, 46번에서 좌측으로 통행하는
  것처럼 보이는 모습.
- 모음 CSV의 정답 라벨과 예측을 다시 대조했다. 서울 모음의 정답 라벨은 모두
  서울이며, 화살표 뒤의 도시는 모델 예측이다.

| 번호 | 정답 라벨 | 모델 예측 | 출력 확률 |
| --- | --- | --- | ---: |
| 11 | seoul | tokyo | 0.90 |
| 46 | seoul | taipei | 0.81 |

- 11번의 정답이 도쿄이고 모델이 서울로 오인했다는 해석은 모음의 표시 방향과
  반대임을 설명한다. 모델이 항공사 로고를 실제 판단 근거로 사용했는지는 확인되지 않았다.
- 46번은 에스컬레이터 장면으로 보인다. 사람의 좌우 위치를 차량의 도로 통행
  방향으로 해석하지 않고, 학생의 최종 해석을 추가로 확인한다.

### 다음 계획

정답 라벨과 예측 표시를 구분해 나머지 사진 관찰을 이어간 뒤, 첫 개선 실험을 정한다.

## 2026-11-07 부산 오답 사진 재검토

학생이 사진의 정답 라벨과 모델 예측을 구분해 다시 검토하며 남긴 말이다.

> 일단 부산 서울 둘을 헷갈리는 건 한국의 문화 자체가 지역따라 바뀌는 건 아니기 때문에 바다나 해양 느낌이
↪ 나지 않으면 그게 부산인지 서울인지 알기 쉽지 않을 것 같다. 48번 같은 경우는 일본은 아직 전봇대를
↪ 사용하고 우리나라는 땅 속에 숨겨놓는데 48번은 전봇대 전선이 있어서 일본으로 헷갈린거같다

- 학생은 부산과 서울의 공통적인 시가지 풍경이 두 도시의 혼동과 관련될 수 있다고
  보았다. 해양 풍경이 없는 사진에서 구분 단서가 부족할 수 있다는 가설이다.
- 부산 모음 48번의 정답 라벨은 `busan`, 모델 예측은 `tokyo`, 출력 확률은 0.85다.
  같은 이름의 모음 CSV에서 확인했다.
- 48번에 전봇대와 가공전선이 보이는 시각적 관찰을 기록했다. 이 특징이 도쿄
  오분류에 영향을 주었을 수 있다는 학생의 설명을 검증할 가설로 남긴다.
- 국내에도 지상 전선 구간이 있다. 서울시의 2024년 공중선 지중화 계획에도
  전기·통신선과 전신주를 지하로 매설할 대상 구간이 설명되어 있다.
  [서울시 공중선 지중화 기본계획 정비 안내](https://news.seoul.go.kr/safe/archives/515090)
- 전선이 모델의 실제 판단 근거였는지는 추가 사례나 실험으로 확인한다.

### 다음 계획

오사카를 비롯한 나머지 도시의 오답 사진을 같은 표시 기준으로 검토하고,
학생의 관찰을 바탕으로 첫 개선 실험을 선택한다.

## 2026-11-08 오사카 오답 사진 재검토

학생이 오사카 모음을 다시 살펴보고 남긴 말이다.

> 오사카도 도쿄랑 같은 일본이라 주택가나 신사 같은 풍경이 비슷해서 헷갈리는 것 같아

- 학생은 주택가와 신사처럼 두 도시에서 비슷하게 보이는 풍경이 혼동과 관련될 수
  있다고 보았다. 사진에서 관찰한 유사성과 모델이 사용한 특징의 관계를 가설로 기록한다.
- 두 기준 실험의 `result.json`에서 실제 오사카에 해당하는 혼동행렬 행을 읽어
  도쿄 예측 비율을 계산했다.

| seed | 오사카 검증 사진 | 오사카 오답 수 | 도쿄 예측 수 | 오사카 오답 중 도쿄 예측 비율 |
| --- | ---: | ---: | ---: | ---: |
| 0 | 2128 | 1361 | 855 | 62.82% |
| 1 | 2128 | 1300 | 783 | 60.23% |

- 두 실행에서 오사카 오답의 약 6할이 도쿄 예측이었다. 학생이 설명한 혼동 방향을
  수치로 확인했다. 주택가나 신사의 유사성이 원인인지 추가 사례와 실험으로 살펴본다.

### 다음 계획

서울, 도쿄, 타이베이 모음을 같은 표시 기준으로 검토한 뒤 첫 개선 실험을 선택한다.

## 2026-11-08 서울 오답 사진 재검토

학생이 서울 모음을 다시 살펴보고 남긴 말이다.

> 서울은 4번이나 10번처럼 음식만 나온 사진은 어느 도시인지 알기 어렵고, 지하철이나 도로도 다른 도시랑
↪ 비슷해서 헷갈리는 것 같아 그리고 24ㅈ번 같은 경우 내가 알기론 일본이 뭔가 무광 인데 빛이 좀 반사되는
↪ 블록을많이쓰고 또 길가가 깨끗해서 그런지 서울인데 일본으로 헷갈린거같아

- 학생은 4번과 10번에서 음식만 보이는 사진의 도시 식별 단서가 부족할 수 있다고
  보았다. 지하철과 도로 등 여러 도시가 공유하는 장면도 혼동의 원인일 수 있다고 설명했다.
- 24번에서는 포장 블록의 표면과 반사감, 정돈된 거리의 모습에서 일본을 연상했다.
  이 시각적 인상과 모델의 도쿄 예측 사이의 관계를 가설로 기록한다.
- 같은 이름의 모음 CSV에서 확인한 정답 라벨과 모델 예측은 다음과 같다.

| 사진 번호 | 정답 라벨 | 모델 예측 | 출력 확률 |
| --- | --- | --- | ---: |
| 4 | seoul | taipei | 0.96 |
| 10 | seoul | osaka | 0.91 |
| 24 | seoul | tokyo | 0.88 |

- 국가별 포장재의 특성과 모델이 실제 활용한 단서는 추가로 확인할 가설로 남긴다.
- 에이전트는 음식만 보이는 훈련 사진을 제외하는 방법을 데이터 정리 실험의
  후보로 연결할 수 있다고 제안한다. 구체적인 변경 규칙은 사진 검토 후 학생이 선택한다.

### 다음 계획

도쿄와 타이베이 모음을 검토한 뒤 첫 개선 실험의 항목과 적용 규칙을 정한다.

## 2026-11-08 도쿄 오답 사진 재검토

학생이 도쿄 모음을 살펴보고 남긴 말이다.

> 도쿄도 4번이나 8번처럼 차만 나온 사진은 어느 도시인지 알기 어렵고, 지하철이나 번화가는 오사카랑 비슷해서
↪ 헷갈리는 것 같아

- 학생은 차량 위주로 보이는 4번과 8번에서 도시를 구분할 정보가 부족할 수 있다고
  보았다. 지하철과 번화가의 모습이 오사카와 비슷해 혼동할 수 있다는 가설도 남겼다.
- 같은 이름의 모음 CSV에서 확인한 정답 라벨과 모델 예측은 다음과 같다.

| 사진 번호 | 정답 라벨 | 모델 예측 | 출력 확률 |
| --- | --- | --- | ---: |
| 4 | tokyo | seoul | 0.96 |

| 8 | tokyo | osaka | 0.95 |

- 서울의 음식 사진 관찰과 연결하면, 도시 배경보다 물체가 중심에 있는 사진에서
  식별 단서가 부족할 수 있다는 공통 가설로 정리할 수 있다.
- 에이전트는 이 관찰을 훈련 사진 정리 기준의 후보로 제안한다.
  적용할 규칙과 사진은 학생의 선택을 거쳐 비교 실험으로 측정한다.

### 다음 계획

타이베이 오답 사진까지 검토한 뒤 학생이 첫 개선 실험의 항목을 선택한다.

## 2026-11-08 타이베이 오답 사진 검토

학생은 타이베이의 모습과 문화에 익숙하지 않다고 밝히고, 다음과 같이 관찰했다.

> 사실 타이페이 같은 경우 어떻게 생겼고 어떤 문화를 가지고 있는지 잘 몰르기는 한데 41번은 코스프레 캐릭터가
↪ 일본 만화 캐릭터라 도쿄로 오해한 것 같고, 1번 33번 같은 건 홍대, 성수나 그런 곳이 유명하고 사람
↪ 바글바글하다보니 서울로 오답을 낸 것 같아. 10번은 바다랑 방파제?가 있는 것 같아서 부산인것같고 나머지는
↪ 사실 자연이 너무 단순한 사진이나 뭘 제대로 판별할 기준이 없다보니 오답을 내지 않았으까 시페

- 41번에서는 일본 만화 캐릭터처럼 보이는 코스프레가 도쿄를 연상시켰을 수 있다고
  보았다. 캐릭터의 정체와 모델의 실제 판단 근거는 추가로 확인할 가설로 남긴다.
- 1번과 33번의 붐비는 상업 공간을 서울의 홍대 · 성수와 연결해 해석했다.
- 10번에서는 수면과 물가 구조물을 바다 · 방파제처럼 보고 부산을 연상했다.
  사진에서 직접 보이는 물가의 모습과 수역의 종류에 대한 추정을 구분해 기록한다.
- 단순한 자연 풍경에서도 도시를 식별할 단서가 부족할 수 있다고 보았다.
- 모음 CSV에서 확인한 정답 라벨과 모델 예측은 다음과 같다.

| 사진 번호 | 정답 라벨 | 모델 예측 | 출력 확률 |
| --- | --- | --- | ---: |
| 1 | taipei | seoul | 0.96 |
| 10 | taipei | busan | 0.91 |
| 33 | taipei | seoul | 0.85 |
| 41 | taipei | tokyo | 0.83 |

## 2026-11-08 첫 개선 실험 선택과 검토 준비

- 다섯 도시의 오답 모음을 살펴본 뒤 학생은 **음식 · 차량 클로즈업 사진 정리**를
  첫 개선 실험으로 선택했다.
- 학생이 검토할 정리 기준은 도시를 식별할 배경이 거의 보이지 않고 음식이나
  차량이 화면의 중심을 차지하는 훈련 사진이다. 앞서 서울 4 · 10번과 도쿄 4 · 8번을
  보며 도시 식별 정보가 부족하다고 판단한 관찰에서 출발한다.
- 에이전트는 검토 후보를 모을 때 훈련 목록의 4장마다 1장을 추론하고,
  각 도시 라벨의 출력 확률이 낮은 사진을 도시별 96장씩 모으도록 준비했다.
  후보 모음은 학생이 선택한 내용 기준과 대조해 살펴볼 자료다.
- Colab 실행 목록에 훈련 사진 수 확인과 후보 모음 생성 명령을 넣었다.
  사진 모음과 번호별 경로 CSV는 `results/curate/suspects_baseline_seed0_*`에 저장된다.

### 다음 계획

1. Colab에서 훈련 사진 후보 모음을 생성하고 결과 ZIP을 가져온다.
2. 학생이 음식 · 차량 클로즈업 제외 기준에 맞는 훈련 사진을 선택한다.
3. 선택한 사진을 `selection.csv`에 반영하고, seed 0의 전체 학습 결과를
   기준 점수 0.5044와 비교해 사진 정리의 효과를 측정한다.

## 2026-11-08 훈련 사진 검토 후보 생성 완료

- `from_colab-4.zip`에서 훈련 사진 수 확인과 후보 모음 생성 결과를 가져왔다.
  실행 로그에 기록된 커밋은 `2b1c37e`다.
- 훈련 사진 수는 서울 11,274장, 부산 5,191장, 도쿄 13,347장,
  오사카 7,200장, 타이베이 7,245장으로 총 44,257장이다.
- 훈련 목록에서 4장마다 1장을 사용해 11,065장을 추론했다.
  각 도시 라벨의 출력 확률이 낮은 사진을 96장씩 모았고,
  서로 다른 훈련 사진 480장이 도시별 두 모음씩 총 10개 모음에 들어 있다.
- 모음 파일은 `results/curate/suspects_baseline_seed0_<city>_00.png`와
  `_01.png`다. 같은 이름의 CSV가 번호와 훈련 사진 경로를 연결한다.

  각 모음의 사진 번호는 1부터 48까지다.
- 추론한 사진 전체의 확률 표는 `results/curate/suspects_baseline_seed0.csv`에 있다.
- `experiments.csv`에는 기준 학습 두 행이 기록되어 있다.
  이번 단계는 훈련 사진 검토 자료를 생성한 것이다.

### 다음 계획

1. 서울부터 도시별 두 모음을 살펴보고, 학생이 음식 · 차량 클로즈업 기준에 맞는
   사진 번호를 모음 이름과 함께 선택한다.
2. 선택한 훈련 사진을 반영한 목록을 만들고, seed 0으로 사진 정리 효과를 측정한다.

## 2026-11-08 서울 훈련 사진 제외 대상 선택

학생이 모음에서 직접 지정한 번호다.

> 서울 00: 5, 10, 14, 45 서울01: 2, 28, 30, 37, 39

| 모음 | 학생이 선택한 번호 | 사진 수 |
| --- | --- | ---: |
| suspects_baseline_seed0_seoul_00 | 5, 10, 14, 45 | 4 |
| suspects_baseline_seed0_seoul_01 | 2, 28, 30, 37, 39 | 5 |

- 모음 CSV에서 번호에 대응하는 훈련 사진 경로를 확인해 서로 다른 9장을
  `track_a/curation_plan.csv`에 기록했다.
- 실제 선택 대상에는 새, 안내판, 작은 물체, 하늘, 책 표지, 꽃과 음식이 포함되어
  있다. 에이전트는 실험을 **학생이 검토 모음에서 직접 선택한 사진 정리**로
  기술해 선택 대상의 범위를 드러낸다. 학생의 개별 선택 사유는 추가 설명을 받는 대로 기록한다.
- 제외 계획의 공통 사유에는 학생이 모음에서 직접 지정했다는 사실을 적었다.
  사진 경로와 모음 번호를 함께 보관해 이후 선택 목록에 정확히 반영한다.

### 다음 계획

부산, 도쿄, 오사카, 타이베이의 제외 대상을 모은 뒤 전체 훈련 사진 선택 목록을
만들어 비교 실험을 실행한다.

## 2026-11-08 부산 훈련 사진 제외 대상 선택

학생이 모음에서 직접 지정한 번호다.

> 부산00: 1 16 31 45 부산01: 4 24 29 38 40

| 모음 | 학생이 선택한 번호 | 사진 수 |
| --- | --- | ---: |
| suspects_baseline_seed0_busan_00 | 1, 16, 31, 45 | 4 |
| suspects_baseline_seed0_busan_01 | 4, 24, 29, 38, 40 | 5 |

- 모음 CSV에서 번호와 경로를 대조해 부산 훈련 사진 9장을 제외 계획에 추가했다.
- `track_a/curation_plan.csv`에 기록된 누적 선택은 서울 9장과 부산 9장으로 총 18장이다.
  각 행에 학생이 지정한 모음 이름과 번호, 훈련 사진 경로를 보관했다.

### 다음 계획

도쿄, 오사카, 타이베이의 제외 대상을 선택한 뒤 비교 실험에 사용할 훈련 목록을 만든다.

## 2026-11-08 도쿄 훈련 사진 제외 대상 선택

학생이 모음에서 직접 지정한 번호다.

> 도쿄 00 4, 11, 16, 19, 28, 34, 42
>
> 도쿄 01 1, 3, 8, 10, 11, 15, 16, 21, 27, 33, 37, 42, 48

| 모음 | 학생이 선택한 번호 | 사진 수 |
| --- | --- | ---: |
| suspects_baseline_seed0_tokyo_00 | 4, 11, 16, 19, 28, 34, 42 | 7 |
| suspects_baseline_seed0_tokyo_01 | 1, 3, 8, 10, 11, 15, 16, 21, 27, 33, 37, 42, 48 | 13 |

- 모음 CSV에서 번호와 경로를 대조해 도쿄 훈련 사진 20장을 제외 계획에 추가했다.
- 누적 선택은 서울 9장, 부산 9장, 도쿄 20장으로 총 38장이다.
  `track_a/curation_plan.csv`의 각 행에 모음 이름과 번호, 훈련 사진 경로를 기록했다.

### 다음 계획

오사카와 타이베이의 제외 대상을 선택한 뒤 비교 실험에 사용할 훈련 목록을 만든다.

## 2026-11-08 오사카 훈련 사진 제외 대상 선택

학생이 모음에서 직접 지정한 번호다.

> 오사카 00: 18, 24, 28, 38, 39
>
> 오사카 01: 33

| 모음 | 학생이 선택한 번호 | 사진 수 |
| --- | --- | ---: |
| suspects_baseline_seed0_osaka_00 | 18, 24, 28, 38, 39 | 5 |
| suspects_baseline_seed0_osaka_01 | 33 | 1 |

- 모음 CSV에서 번호와 경로를 대조해 오사카 훈련 사진 6장을 제외 계획에 추가했다.
- 누적 선택은 서울 9장, 부산 9장, 도쿄 20장, 오사카 6장으로 총 44장이다.
  `track_a/curation_plan.csv`에 모음 이름과 번호, 훈련 사진 경로를 기록했다.

### 다음 계획

타이베이의 제외 대상을 선택한 뒤 비교 실험에 사용할 훈련 목록을 만든다.

## 2026-11-08 타이베이 선택 완료와 첫 사진 정리 실험 준비

학생이 모음에서 직접 지정한 번호다.

> 타이베이00: 2, 14, 30, 39, 41, 45, 46
>
> 타이베이01: 3, 11, 20, 23, 41

| 모음 | 학생이 선택한 번호 | 사진 수 |
| --- | --- | ---: |
| suspects_baseline_seed0_taipei_00 | 2, 14, 30, 39, 41, 45, 46 | 7 |
| suspects_baseline_seed0_taipei_01 | 3, 11, 20, 23, 41 | 5 |

- 모음 CSV와 대조해 타이베이 훈련 사진 12장의 경로를 제외 계획에 추가했다.
  다섯 도시에서 선택한 서로 다른 56장의 모음 번호와 훈련 사진 경로를 모두 대조했다.
- 계획 파일 `track_a/curation_plan.csv`의 SHA-256은
  `51af86b1f032400cde628cb33d9fd76252f7f1385ba8985df540603f57018351`이다.
- 후보는 전체 훈련 사진에서 매 네 번째 사진을 뽑은 11,065장 중,
  기준 모델이 정답 도시에 낮은 확률을 준 도시별 96장, 총 480장의 모음이다.
  학생은 이 모음에서 56장을 지정했다. 전체 훈련 사진의 약 0.13%에 해당한다.
  후보 모음을 살펴본 범위를 전체 데이터 정리로 확대해 해석하지 않는다.
- 실험 이름은 `curated56`, seed는 0으로 정했다. 비교 기준은 같은 seed의
  `baseline_seed0` 검증 점수 0.5044다. 기준 seed 1의 점수는 0.4984였고,
  두 실행 사이에는 0.0060의 차이가 있었다. 정리 후 결과는 아직 측정 전이다.

| 도시 | 기준 훈련 사진 | 제외 예정 | 정리 후 예정 |
| --- | ---: | ---: | ---: |
| Seoul | 11,274 | 9 | 11,265 |
| Busan | 5,191 | 9 | 5,182 |
| Tokyo | 13,347 | 20 | 13,327 |
| Osaka | 7,200 | 6 | 7,194 |
| Taipei | 7,245 | 12 | 7,233 |
| 합계 | 44,257 | 56 | 44,201 |

- 스타터 레시피의 SHA-256은
  `17ac485223fa61741f2c63aeb1c91bc283c88c6b7aaa8f02fdb3e86924ff29c9`다.

  이 비교는 학생이 선택한 사진의 제외만 변경한다. ResNet18, 224 x 224,
  batch size 64, 3,906 steps와 249,984회 사진 제시를 기준 실행과 맞춘다.
- 전체 훈련 데이터가 있는 Colab에서 `src/prepare_curation.py`가 원본 전체 목록을
  읽고 56장을 제외한 `track_a/selection.csv`를 만든다. 계획 해시, 중복과 경로,
  사진 존재 여부, 기준 실행의 도시별 전체 사진 수와 레시피 해시를 확인한다.
  선택 목록과 제외 기록, 계획 원본, 전후 사진 수와 해시 요약을
  `results/curation_curated56/`에도 저장해 결과 ZIP으로 가져온다.
- 작은 임시 사진 데이터로 스크립트의 CLI, 공식 선택 목록 읽기 함수와의 호환,
  반복 실행, 잘못된 해시 · 중복 · 없는 사진 · 경로 · 사유 · 전체 사진 수 · 레시피의 거부를
  확인했다. 기존 Colab ZIP 포장에 선택 목록과 기록이 포함되는 것도 확인했다.
  이 점검에서는 실제 전체 학습을 수행하지 않았다.

### 다음 계획

1. Colab에서 목록 생성, 도시별 사진 수 확인, `curated56` seed 0 전체 학습과
   ONNX 형식 검사를 차례로 실행한다.
2. 결과 ZIP의 실제 선택 목록과 요약, 학습 결과를 대조해 가져오고,
   기준 seed 0과 전체 검증 점수 및 도시별 정확도의 차이를 계산한다.
3. 결과를 보고 다음 실험을 정한다. 주변 단서를 보존하는 crop 조정과
   Track B용 추가 사진 수집도 이후 비교할 후보로 남아 있다.

## 2026-11-08 curated56 (Track A, seed 0)

- 학생이 직접 선택한 훈련 사진 56장을 제외하고 전체 학습을 완료했다.
  실제 선택 목록은 44,201행이며, 모음별 번호에 대응하는 승인 경로 56장과
  겹치지 않는다. 선택 목록과 제외 경로를 합쳐 원래 훈련 목록 44,257장을
  복원했을 때 준비 단계에서 저장한 전체 목록 해시와 일치했다.
- 전체 목록과 계획, 선택 목록, 제외 기록의 해시 및 도시별 사진 수를 대조했다.
  결과 파일의 선택 목록 해시 `9ef44cac68cb`도 실제 CSV의 SHA-256 앞부분과 일치한다.
  전체 SHA-256은
  `9ef44cac68cb392a341d4a9ec59bea7645e5b3df2757cf189eebe4f5f6c9de55`다.
- 기준 seed 0과 같은 스타터 레시피, ResNet18, 입력 224 x 224, batch size 64,
  seed 0, CUDA와 공식 예산 3,906 steps, 249,984회 사진 제시를 사용했다.
  두 결과의 검증 혼동행렬에서 도시별 사진 수가 같고, 합계는 12,077장이다.
- 검증 점수는 **0.4937**, 기준 seed 0의 0.5044보다 **0.0107 낮았다**.
  퍼센트로 표시하면 50.44%에서 49.37%로, 1.07%p 하락했다.

| 도시 | 기준 seed 0 | 56장 제외 seed 0 | 차이 (%p) |
| --- | ---: | ---: | ---: |
| Seoul | 57.74% | 58.48% | +0.74 |
| Busan | 39.42% | 37.27% | -2.15 |
| Tokyo | 63.85% | 63.39% | -0.46 |
| Osaka | 36.04% | 36.04% | 0.00 |
| Taipei | 55.15% | 51.67% | -3.48 |
| 도시별 정확도의 평균 | 50.44% | 49.37% | -1.07 |

- 가장 크게 내려간 도시는 타이베이이고, 서울은 올랐다. 이 표는 결과 JSON에
  기록된 소수 넷째 자리의 정확도를 변환한 값이다.
- 학습 시간은 2,211.8초, 약 36.9분이다. 데이터 준비, 검증과 내보내기 시간은 별도다.
  ONNX 출력은 44.7 MB, 11.17 million parameters, 입력 224 x 224에서
  1.81 billion multiply-adds이며 형식과 한도 검사를 통과했다.
- 실행 commit은 `9cd86e1`, 완료 시각은 2026-11-08 21:51:51 KST다.
  원본은 `from_colab-5.zip`의 `results/curated56_seed0/result.json`,
  `results/curation_curated56/`의 네 기록 파일,
  `results/colab_logs/1108_211047_official_curated56_seed0.txt`,
  `results/colab_logs/1108_215154_check_submission.txt`다.
  새 실행 한 행을 중복 없이 `experiments.csv`에 가져왔고,
  실제 선택 목록과 제외 기록을 `track_a/`에 보관했다.
- 해석은 이 선택과 seed 0에서 점수가 내려갔다는 관찰로 한정한다.
  제외한 개별 사진의 영향이나 사진 정리 일반의 효과는 여기서 확정할 수 없다.
  `official.py`는 선택 목록의 길이에 따라 `randperm`으로 학습 순서를 만들므로
  사진 수가 바뀌면 같은 seed에서도 제시되는 사진 순서가 달라진다.
  학생이 이 결과에 대해 내린 추가 해석은 아직 받지 않았다.

### 다음 계획

1. 같은 56장 제외 목록과 같은 레시피를 유지하고 seed 1 실행을 준비했다.
   새 실행은 아직 수행 전이다. 기존 기준 seed 1 점수 0.4984와 짝지어 비교한다.
2. 두 seed 각각의 차이와 평균을 확인한 뒤 제외 목록의 채택 여부와
   crop 조정 등 다음 변경을 결정한다.

## 2026-11-08 curated56 (Track A, seed 1)와 두 seed 비교

- 같은 56장 제외 목록으로 두 번째 전체 학습을 완료했다. 검증 점수는
  **0.4914**이며, 같은 seed의 기준 점수 0.4984보다 **0.0070 낮았다**.
- 실제 선택 목록 44,201행, 도시별 선택 사진 수, 레시피와 선택 목록 해시는
  `curated56` seed 0과 일치한다. 공식 예산 249,984회 사진 제시,
  batch size 64, 3,906 steps, CUDA를 사용했다. 기준 seed 1과도 레시피,
  seed, 예산과 검증 혼동행렬의 도시별 사진 수를 대조했다.
- 결과 JSON의 점수와 도시별 정확도가 혼동행렬에서 다시 계산한 값과
  소수 넷째 자리에서 일치한다. 전체 검증 사진 수는 12,077장이다.
- 학습 시간은 2,220.7초, 약 37.0분이다. 데이터 준비, 검증과 내보내기는 별도다.
  ONNX는 44.7 MB, 11.17 million parameters, 입력 224 x 224에서
  1.81 billion multiply-adds이며 형식과 한도 검사를 통과했다.
- 실행 commit은 `a2ac080`, 완료 시각은 2026-11-08 22:39:04 KST다.
  원본은 `from_colab-6.zip`의 `results/curated56_seed1/result.json`,
  `results/colab_logs/1108_215749_official_curated56_seed1.txt`,
  `results/colab_logs/1108_223906_check_submission.txt`다.
  이전 세 실행의 결과와 선택 목록이 기존 기록과 같음을 확인하고,
  새 실행 한 행을 중복 없이 가져왔다. `experiments.csv`에는 전체 실행 네 행이 있다.

| 실행 | 전체 훈련 사진 | 56장 제외 | 차이 (%p) |
| --- | ---: | ---: | ---: |
| seed 0 | 50.44% | 49.37% | -1.07 |
| seed 1 | 49.84% | 49.14% | -0.70 |
| 두 실행 평균 | 50.14% | 49.26% | -0.89 |

- 평균과 차이는 JSON에 기록된 소수 넷째 자리 점수에서 계산한 뒤 표시했다.
  반올림 전 평균은 각각 0.5014와 0.49255이고, 차이는 -0.00885다.
  퍼센트로는 50.140%와 49.255%, 차이는 -0.885%p다.

| 도시 | 전체 사진 두 seed 평균 | 56장 제외 두 seed 평균 | 차이 (%p) |
| --- | ---: | ---: | ---: |
| Seoul | 57.00% | 57.66% | +0.66 |
| Busan | 38.92% | 36.59% | -2.34 |
| Tokyo | 62.63% | 64.49% | +1.86 |
| Osaka | 37.48% | 36.11% | -1.37 |
| Taipei | 54.68% | 51.43% | -3.26 |

- 이번 선택은 두 seed 모두에서 전체 검증 점수가 내려갔다. 평균에서는
  서울과 도쿄가 올랐고, 부산과 오사카, 타이베이가 내려갔다.
  결론은 학생이 이 후보 모음에서 지정한 56장의 제외와 공개 검증 데이터에서
  관찰한 결과로 한정한다. 두 seed의 실행은 원인이나 통계적 유의성을 확정하지 않는다.
- 학생의 추가 결과 해석은 아직 받지 않았다. 에이전트는 다음 후보로
  전체 사진을 다시 사용하고 `RandomResizedCrop`의 최소 면적을 0.35에서
  0.70으로 높여 주변 단서를 더 남기는 비교를 제안했다. 이 후보는 도로,
  주택가, 도시 풍경의 단서를 살피던 학생의 관찰에서 이어진 제안이다.

### 다음 계획

1. 첫 제외 실험은 두 seed의 결과를 보관하며 마무리한다.
2. 다음 실험에 대한 학생의 선택을 받는다. 전체 사진 복원 후 crop 변경,
   현재 제외 목록 유지 후 crop 변경, 현재까지 결과 정리를 선택지로 제시했다.
3. 다음 조건이 정해지면 사진 목록과 레시피를 명확히 기록하고
   해당 조건에 맞는 비교 실행을 준비한다.

## 2026-11-08 전체 사진 복원과 Random Erasing 실험 준비

학생이 다음 실험으로 제안한 말이다.

> 전체 사진 사용하고 어느 부분을 가려보는 형식은 어때 그리고 일단 Long report 지금까지 한 거 추가로 넣어줘

가리기의 의도를 확인한 질문에 학생은 다음 방식을 선택했다.

> 학습할 때 임의의 작은 영역을 가려서 여러 단서를 배우게 하기

- 이 요청에 따라 실험 이름을 `erase15`로 정했다. 한 단서가 가려져도
  나머지 단서로 도시를 구분하는 학습을 시도한다는 목적이다.
  그 효과는 아직 전체 학습으로 측정 전이다.
- 학생이 지정한 56장을 다시 포함해 전체 훈련 사진 44,257장을 사용한다.
  이전 선택 목록과 제외 계획에서 원래 목록을 복원하고, 도시별 · 파일명별 순서의
  CSV 해시가 사진 정리 전 전체 목록 해시와 같음을 확인했다.
  전체 선택 목록의 SHA-256은
  `1a1ca6c1882356b84701446e495973c375535d9d64b3cb3d3397c3dfd640f9e4`다.
  56장 제외 실험의 목록과 제외 기록은 `results/curation_curated56/`에 보관한다.
- 에이전트가 첫 실행의 수치로 적용 확률 0.5, 가릴 면적 비율 0.02~0.15,
  직사각형 종횡비 0.3~3.3을 정했다. 가린 RGB 값은 ImageNet 정규화 평균인
  (0.485, 0.456, 0.406)으로 채워 정규화 후 0이 되게 한다.
  학습 때 사진을 제시할 때마다 적용 여부와 가리는 위치 · 크기를 다시 뽑는다.
- 기존 자르기 면적 0.35~1.0, 좌우 반전, 색 변화는 유지한다.
  `ToTensor` 뒤에 `RandomErasing`을 추가했다. 모델, 입력 크기와 학습 예산,
  optimizer, scheduler, loss 및 나머지 레시피 함수는 기준 실험과 같다.
  검증은 기존 공식 전처리를 사용한다.
- 새 레시피의 SHA-256은
  `4c2c343450775b1250263dc042874317484e9eb9b4262ecbd11c2c28d7fd9b01`이다.
  torchvision 0.21의 공식 문서에서 텐서 입력과 인자 정의를 확인했다.
  https://docs.pytorch.org/vision/0.21/generated/torchvision.transforms.RandomErasing.html
- PyTorch 2.6.0과 torchvision 0.21.0에서 공식 레시피 규칙 검사를 통과했다.
  가리기를 끄면 기준 변환과 같은 픽셀이 나오는 것을 확인했다.
  고정 seed로 합성 사진을 100번 제시했을 때 58번 가려졌고,
  가린 면적 비율은 약 0.021~0.146이었다. RGB, 회색조와 RGBA 입력을 공식
  `TrainPhotos`로 읽고 정규화한 텐서와 라벨을 확인했다.
  합성 데이터로 ResNet18의 순전파, loss, 역전파와 optimizer step도 확인했다.
  이 사전 점검의 수치는 실제 도시 분류 검증 점수와 구분해 기록한다.

### 다음 계획

1. Colab에서 전체 사진 수를 확인하고 `erase15`를 seed 0과 1로 전체 학습한다.
   각각 ONNX 형식과 한도를 검사한다.
2. 전체 사진을 사용한 기존 `baseline`의 같은 seed 결과와 비교해
   가리기 증강의 효과를 측정한다.
3. Long report에 다섯 도시의 사진 관찰과 56장 제외 실험의 두 seed 결과를
   추가하고, 가리기 실험은 준비 단계로 구분해 기록한다.

## 2026-11-09 erase15 (Track A, seed 0과 1)

- 학생이 제안한 학습 중 임의 영역 가리기를 전체 훈련 사진 44,257장으로
  두 번 전체 학습했다. 적용 확률 0.5, 면적 비율 0.02~0.15,
  종횡비 0.3~3.3과 정규화 평균색 채우기를 사용했다.
- 두 실행의 레시피 해시는 `4c2c34345077`, 선택 목록 해시는 `1a1ca6c18823`다.
  실제 레시피와 전체 선택 목록의 SHA-256 앞부분과 일치한다.
  기존 네 결과 파일이 이전 기록과 같음을 확인했다.
- 기준 실행과 같은 seed, 도시별 훈련 사진 수, batch size 64,
  3,906 steps와 249,984회 사진 제시, CUDA를 사용했다.
  검증 사진 수는 두 실행 모두 12,077장이고 도시별 사진 수가 기준과 같다.
  검증 점수와 도시별 정확도는 혼동행렬에서 다시 계산한 값과
  소수 넷째 자리에서 일치했다.

| 실행 | 기준 전체 사진 | Random Erasing | 차이 (%p) |
| --- | ---: | ---: | ---: |
| seed 0 | 50.44% | 49.16% | -1.28 |
| seed 1 | 49.84% | 49.44% | -0.40 |
| 두 실행 평균 | 50.14% | 49.30% | -0.84 |

| 도시 | 기준 두 seed 평균 | 가리기 두 seed 평균 | 차이 (%p) |
| --- | ---: | ---: | ---: |
| Seoul | 57.00% | 57.09% | +0.09 |
| Busan | 38.92% | 37.77% | -1.15 |

| Tokyo | 62.63% | 63.22% | +0.59 |
| Osaka | 37.48% | 35.20% | -2.28 |
| Taipei | 54.68% | 53.24% | -1.45 |

- 표의 평균과 차이는 결과 JSON에 기록된 점수로 계산한 뒤 반올림했다.
  도시별 평균에서는 서울과 도쿄가 올랐고, 부산, 오사카와 타이베이가 내려갔다.
  이번 가리기 조건은 두 seed 모두에서 전체 검증 점수가 내려갔다.
  이 조건과 데이터에서 관찰한 범위로 결론을 한정한다.
  모델이 실제로 어떤 단서를 사용했는지와 하락의 원인은 추가 확인이 필요하다.
  학생이 이 결과에 대해 내린 추가 해석은 아직 받지 않았다.
- 학습 시간은 seed 0에서 2,208.3초, seed 1에서 2,207.2초로 각각 약 36.8분이다.
  두 ONNX 모델은 각각 44.7 MB, 11.17 million parameters,
  입력 224 x 224당 1.81 billion multiply-adds로 형식과 한도 검사를 통과했다.
- 실행 commit은 두 번 모두 `c6bf059`다. 완료 시각은 seed 0이
  2026-11-08 23:57:00 KST, seed 1이 2026-11-09 00:37:52 KST다.
  원본은 `from_colab-7.zip`의 `results/erase15_seed0/result.json`,
  `results/erase15_seed1/result.json`과 `results/colab_logs/`의
  `1108_231605_official_erase15_seed0.txt`, `1108_235701_check_submission.txt`,
  `1108_235702_official_erase15_seed1.txt`, `1109_003754_check_submission.txt`다.
  새 실행 두 행을 중복 없이 가져와 전체 학습 기록은 여섯 행이다.

| 조건 | seed 0 | seed 1 | 평균 |
| --- | ---: | ---: | ---: |
| 기준 레시피, 전체 사진 | 50.44% | 49.84% | 50.14% |
| 학생이 선택한 56장 제외 | 49.37% | 49.14% | 49.26% |
| 전체 사진과 Random Erasing | 49.16% | 49.44% | 49.30% |

### 다음 계획

학생은 다음 작업으로 Track B 모델의 첫 제출 준비를 선택했다.
현재 측정한 세 조건 중 기준 레시피의 두 seed 평균이 가장 높다.

## 2026-11-09 Track B 첫 모델 학습과 제출 파일 생성 준비

학생이 다음 작업 선택에 답한 내용이다.

> Track B 모델의 첫 제출 준비하기 (추천)

- 기존 `src/train_b.py`로 Track B의 첫 기준 모델을 학습하도록 준비했다.
  실험 tag는 `b_baseline`, 모델은 ImageNet-1k V1에서 시작하는 ResNet18,
  입력 크기 224 x 224, 전체 스타터 훈련 사진과 4 epochs다.
  batch size 64, AdamW 학습률 0.0003과 weight decay 0.05,
  OneCycleLR, label smoothing 0.1 등 제공된 기본 설정을 사용한다.
- Track B 학습은 `track_a/recipe.py`와 별도로 정의된 제공 코드를 사용한다.
  검증은 전체 스타터 검증 사진을 사용하고, 추가 데이터는 첫 실행에 포함하지 않는다.
  제공된 Track B 스크립트는 seed를 고정하거나 기록하는 인자가 없어 첫 실행의
  seed 필드는 비어 있게 된다. 후속 비교 조건을 정할 때 이 실행 조건을 함께 검토한다.
- `--submit` 옵션으로 학습된 ONNX와 메타데이터를 `submission/`에 생성하고,
  `check_submission.py --no-val`로 Track B의 형식과 크기 한도를 확인한다.
  모델 파일은 기존 Colab 포장 기능에 따라 `submission/model.onnx`로 ZIP에 포함된다.
  이 학습과 검사는 아직 실행 전이다.

### 다음 계획

1. Colab에서 `b_baseline` 학습, 검증, ONNX 내보내기와 제출 파일 검사를 실행한다.
2. 결과 ZIP의 모델과 메타데이터, 검증 점수와 검사 출력을 확인한 뒤
   Track B의 첫 릴리스를 준비한다.
3. Long report에 가리기 실험의 두 seed 결과와 첫 Track B 실행의 준비 상태를 추가한다.

## 2026-11-09 b_baseline (Track B)

- 학생이 선택한 Track B 첫 제출 준비에 따라 제공된 `train_b.py`를 실행했다.
  ImageNet-1k V1에서 시작하는 ResNet18, 입력 224 x 224, 전체 스타터 훈련 사진
  44,257장과 4 epochs, batch size 64를 사용했다.
  실제 사진 제시 횟수는 176,896회로 기록되었다.
  제공 코드의 기본 optimizer, scheduler, augmentation과 loss를 사용했다.

- CUDA에서 학습했으며 학습 시간은 1,637.1초, 약 27.3분이다.
  실행 commit은 `50530fc`, 완료 시각은 2026-11-09 01:14:53 KST다.
  제공 스크립트는 seed를 고정하거나 기록하지 않아 seed 칸은 비어 있다.
- Colab에서 기록한 전체 검증 점수는 **0.4895**다.

| 도시 | 검증 정확도 |
| --- | ---: |
| Seoul | 55.40% |
| Busan | 37.55% |
| Tokyo | 63.77% |
| Osaka | 34.87% |
| Taipei | 53.14% |
| 도시별 정확도의 평균 | 48.95% |

- `submission/model.onnx`와 `submission/submission.json`을 결과 ZIP에서 가져왔다.
  두 파일의 실제 바이트가 원본 ZIP과 일치하고, 메타데이터가 결과 폴더의 기록과
  같은 것을 확인했다. 새 Track B 한 행을 가져와 전체 실행 기록은 일곱 행이다.
- Colab과 로컬에서 공식 제출 검사로 `format and limits: OK`를 확인했다.
  로컬 측정값은 11,174,283 parameters, 1.813563904 GMACs, 44.707595 MB,
  ONNX opset 17이다. 한도인 12 million parameters와 2.0 GMACs를 만족한다.
  ONNX 1.19.1과 ONNX Runtime 1.23.2로 CPU 배치 1과 3의 추론을 실행해
  각 사진에 유한한 도시별 logit 다섯 개가 나오는 것도 확인했다.
- 모델 SHA-256은
  `5f530de70645fc15d855e2547619ba2e7708e938b6d8eee6b1c6309de52de572`다.
  메타데이터 SHA-256은
  `5fada1911b259d5d8145d2d26b1b1810ee94bb7b8f3f178a1e4cd96b661982c0`다.
- 원본은 `from_colab-8.zip`의 `results/colab_experiments.csv`,
  `results/colab_logs/1109_004557_train_b_b_baseline.txt`,
  `results/colab_logs/1109_011454_check_submission.txt` 및 `submission/`의 두 파일이다.
  로컬 검사 출력과 측정값은 `results/b_baseline_local_check.txt`,
  `results/b_baseline_release_check.json`에 보관했다.
- 에이전트는 실행 조건을 그대로 나타내는 첫 릴리스 제목으로
  `Starter ResNet18 at 224, 4 epochs`를 정해 `track-b-1` 게시를 준비한다.
  이 실행은 Track B 후속 비교의 첫 기준으로 보관한다.
  학생이 점수에 대해 내린 추가 해석은 아직 받지 않았다.

### 다음 계획

1. 코드와 기록, 메타데이터를 커밋하고 실제 ONNX와 메타데이터를 첫 Track B
   릴리스의 자산으로 게시한다.
2. 게시된 자산의 크기와 SHA-256을 실제 파일과 대조한다.
3. 학생이 다음 개선 실험을 선택한 뒤 조건과 비교 기준을 기록한다.
   Long report의 Track B 결과와 제출 현황, 학생이 직접 작성할 short report도
   최종 제출 전에 정리한다.

## 2026-11-09 Track B 첫 릴리스 게시 완료

- `track-b-1`을 2026-11-09 01:22:42 KST에 공개 릴리스로 게시했다.
  제목은 `Starter ResNet18 at 224, 4 epochs`다.
  초안과 prerelease 상태가 모두 false이고, 자산 두 개의 업로드가 완료되었다.
- 자산 `model.onnx`는 44,707,595 bytes,
  `submission.json`은 157 bytes다. GitHub가 제공하는 각 자산의 SHA-256을
  로컬에서 검사한 파일의 SHA-256과 대조해 모두 일치함을 확인했다.
- 릴리스 태그는 제출 기록과 메타데이터가 들어 있는 commit
  `d4f7ce375856c9d22642cfad265743b57183b1a3`을 가리킨다.
  모델을 학습한 commit은 앞서 기록한 `50530fc`다.
- 공개 릴리스 주소는
  https://github.com/jellykeeng/mas1004-assignment2/releases/tag/track-b-1
  이다. 원본 릴리스와 태그 조회 결과는 `results/track_b_1_release.json`,
  `results/track_b_1_tag.json`에 보관했다.
- 두 트랙의 공개 릴리스는 `track-a-1`과 `track-b-1`이다.
  2026-11-09 조회한 리더보드의 마지막 갱신은 2026-11-08 02:27 KST이며,
  `SoSleepy`의 항목은 두 트랙 모두 0건이었다. 게시 완료와 리더보드 채점 결과를
  구분해 기록하며 다음 정기 채점 후 반영 여부를 확인한다.

### 다음 계획

1. Long report에 Track B 검증 점수 0.4895, 모델 크기, 학습 조건과
   두 트랙의 실제 릴리스 현황을 반영한다.
2. 추가 데이터 실험의 가능성을 확인하기 위해 학생에게 직접 찍었거나
   지인에게 받을 수 있는 다섯 도시의 사진이 있는지 질문했다.
3. 다음 변경을 학생이 선택하면 적용 범위와 비교 기준을 정한다.
   최종 보고서와 학생이 직접 쓸 short report를 마감 전에 제출한다.

## 2026-11-09 다음 데이터 실험을 위한 사진 보유 확인

추가 사진의 보유 여부를 질문한 뒤 학생은 서울 · 부산 사진이 있다고 정정했다.

> 서울이랑 부산은 있어

- 학생이 보유한 두 도시 사진을 추가하는 실험의 가능성을 확인했다.
  사진 폴더 경로 또는 도시를 구분한 ZIP을 요청한 상태다.
  실제 파일을 받으면 도시별 개수와 중복 여부를 확인하고 추가 목록을 기록한다.
- 추가 사진의 학습 적용과 효과 측정은 아직 수행 전이다.
  다음 비교에서는 사용 데이터와 학습 조건, seed 기록을 함께 정리한다.

### 다음 계획

서울 · 부산 사진을 받아 정답 도시를 확인하고, 추가 데이터 실험의 조건을 준비한다.

## 2026-11-09 오늘 다운로드한 개인 사진 7장 정리와 비교 준비

학생이 사진의 위치와 도시를 설명했다.

> 0549 빼고 전부 부산다운로드 폴더에있어

에이전트가 Downloads의 IMG 사진 전체를 대상으로 제안하자 학생이 범위를 바로잡았다.

> 엥 아니 오늘 다운 한 것중에서만이야

`IMG_0549.HEIC`의 도시는 서울이라고 학생이 별도로 확인했다.

- macOS Finder의 `kMDItemDateAdded`를 한국 시간으로 변환해 11월 9일에
  다운로드 폴더에 추가된 사진 7장을 확인했다. 파일에 남아 있는 촬영일과
  파일 생성 시각은 이 수집 범위를 판단하는 기준과 구분했다.
  7장의 추가 시각은 모두 2026-11-09 01:27:30 KST였다.

| 원본 파일 | 학생이 확인한 도시 |
| --- | --- |
| IMG_0549.HEIC | seoul |
| IMG_0237.HEIC | busan |
| IMG_0240.HEIC | busan |
| IMG_0276.HEIC | busan |
| IMG_0286.HEIC | busan |
| IMG_1403.HEIC | busan |
| IMG_1413.HEIC | busan |

- 초기 34장 제안은 전체 IMG 목록을 넓게 잡은 것이었다.
  실제 데이터 준비 범위는 오늘 받은 서울 1장과 부산 6장으로 바로잡았다.
  준비한 데이터에는 이 7장이 들어 있다.
- macOS 변환기로 HEIC를 읽고 방향을 바로잡아 RGB로 변환했다.
  스타터 사진과 맞추어 짧은 변을 최대 512픽셀로 조정하고,
  제공된 `gps_sort.py --city`로 학생이 확인한 도시의 JPEG 사본을 만들었다.
  실제 사본 7장은 EXIF가 비어 있고 파일 및 디코딩 픽셀 해시가 각각 서로 다르다.
  JPEG 합계는 766,495 bytes, 업로드용 ZIP은 766,119 bytes다.
- 원본 파일명과 해시, 날짜 메타데이터 및 준비한 사본의 크기는
  `data/student_photo_inventory.json`에 보관했다.
  Colab에서 사용할 사본의 경로와 SHA-256은 `extra_photos_manifest.csv`에 기록했다.
  이 manifest의 SHA-256은
  `c885e760cf70bd5ee6757e42487549ade7c61adcaafde8d5c31dbfc413c2450f`다.
- 추가 사진의 효과를 같은 조건에서 비교하도록 `train_b.py`에 선택적
  `--seed` 인자를 추가했다. 기존처럼 인자를 생략하면 seed를 고정하지 않는 동작과

  메타데이터 형식을 유지한다. 지정한 seed는 사진 및 모델의 난수 설정과
  실행 CSV, 제출 메타데이터에 반영한다.
- 비교는 `b_control_seed0`과 `b_own_sb_seed0`으로 준비했다.
  두 조건 모두 seed 0, ResNet18 V1, 입력 224 x 224, 4 epochs, batch size 64다.
  훈련 사진 수는 각각 44,257장과 44,264장이다. 이 두 수에서 완성되는 배치 수는
  epoch당 모두 691개여서 실제 사진 제시 횟수도 각각 176,896회로 같다.
  추가 조건의 도시별 훈련 사진 수는 서울 11,275장, 부산 5,197장,
  도쿄 13,347장, 오사카 7,200장, 타이베이 7,245장이다.
- `check_extra_photos.py`가 학습 전에 업로드한 7장의 경로, 해시와 이미지 읽기를
  검사한다. 누락이나 추가 파일, 파일 변경 또는 manifest 변경이 있으면 학습을 멈춘다.
  실제 데이터의 로컬 검사와 누락 · 변경 입력의 거부를 확인했다.
- 작은 합성 사진 데이터로 실제 `train_b.main`을 실행해 seed 0의 반복 결과가
  같고 seed가 CSV와 메타데이터에 0으로 기록되는 것을 확인했다.
  seed 미지정 동작의 호환성도 확인했다. 이 점검은 실제 도시 분류 성능 측정과
  구분한다. 추가 데이터 조건의 전체 학습은 아직 수행 전이다.

### 다음 계획

1. 준비한 `mine` 폴더를 Google Drive의 `mas1004/assignment2/data/`에 업로드한다.
2. Colab에서 7장 업로드 검사, 같은 seed의 기준 학습과 추가 사진 학습,
   각각의 제출 형식 검사를 실행한다.
3. 결과를 같은 seed 기준과 비교해 전체 및 도시별 정확도 변화를 기록한다.

## 2026-11-09 Colab GPU 한도와 Mac 로컬 실행 준비

- 학생이 Colab의 GPU 사용량 한도 화면을 보여주고 VS Code에서 실행할 수 있는지
  질문했다. 로컬 실행을 위해 기존 스타터 데이터의 복사도 요청했다.
- Mac은 Apple M1 Pro, 메모리 16 GiB, macOS 15.6이다.
  PyTorch 2.6.0과 torchvision 0.21.0에서 MPS가 지원되고 Apple GPU 연산이
  동작하는 것을 확인했다.
- Documents의 기존 과제 폴더는 명령줄 파일 접근 권한 때문에 읽기에 실패했다.
  요청한 starter 폴더를 Finder의 복사 기능으로 작업 폴더의 `data/starter`에
  복사했다. 훈련 44,257장과 검증 12,077장을 확인했고, 훈련 목록의 경로와
  순서가 기존 전체 사진 `selection.csv`와 일치했다.
- VS Code에서 선택할 수 있도록 작업 폴더의 `.venv`에 과제 버전의 실행 환경을
  준비했다. 원래 데이터와 오늘 준비한 서울 1장 · 부산 6장을 로컬에서 읽을 수 있다.
- 실제 ResNet18 V1과 기준 훈련 변환, AdamW로 MPS에서 batch size 64의
  20 step 성능 점검을 수행했다. 별도 점검용 모형은 ONNX 내보내기와
  Track B 형식 및 한도 검사도 통과했다. 이 점검을 전체 학습 실험 행에 추가하지 않았다.
- 처음 5 step을 제외한 step 시간의 중앙값은 약 0.521초였다.
  두 번의 4-epoch 훈련 시간 합계는 이 측정에서 약 48.0분으로 추산된다.
  실제 전체 학습의 검증과 내보내기 시간은 각각의 실행에서 따로 확인한다.
  원본 측정값은 `results/local_mps_smoke/smoke.json`에 보관했다.
- 준비한 기준 조건과 사진 7장 추가 조건을 같은 MPS 장치, seed 0,
  batch size 64, 4 epochs, worker 2개로 로컬에서 비교하도록 준비했다.
  두 조건의 실제 사진 제시 횟수는 각각 176,896회로 같다.

### 다음 계획

1. 같은 실행 도구로 로컬의 두 전체 학습과 제출 파일 검사를 수행한다.
2. 실제 MPS 실행의 점수, 도시별 정확도와 학습 시간을 가져와 같은 장치와
   seed의 기준 조건에 맞추어 추가 사진의 효과를 비교한다.

## 2026-11-09 MPS 로컬 전체 학습 시작 조건

- worker 2개를 사용한 성능 점검은 결과 저장과 모델 검사 후 Python 종료 단계에서
  multiprocessing resource tracker의 종료를 기다리며 멈췄다.
  완료된 점검 프로세스를 정리하고 로컬 비교는 worker 0개로 조정했다.
- worker 0개와 `OMP_NUM_THREADS=1`에서 실제 학습 코드의 20 step,
  ONNX 내보내기 및 형식 검사를 다시 확인했다. 프로세스 종료 코드도 0이었다.
  원본은 `results/local_mps_smoke_workers0/smoke.json`이다.
- 처음 5 step을 제외한 step 시간 중앙값은 약 0.782초였다.
  이 측정에 따른 두 전체 학습 시간 합계는 약 72.1분이며,
  전체 검증과 내보내기를 포함한 실제 시간은 완료 후 기록한다.
- 두 전체 실행 모두 MPS, seed 0, worker 0개, batch size 64와 4 epochs를
  사용하도록 했다. 실행 프로세스에 `TZ=Asia/Seoul`과 `OMP_NUM_THREADS=1`을

  적용하고, 학습 중 자동 유휴 잠자기를 방지하는 프로세스 한정 설정을 사용한다.
  Mac 전원이 연결되어 있고 배터리가 충전되어 있음을 확인했다.
- 기존 실행 도구 `colab.py run`으로 로컬 명령을 차례로 수행한다.
  이 실행에서 쓰는 `results/colab_logs/`와 `results/colab_experiments.csv`의
  디렉터리 이름은 도구의 기본 이름이며 실제 실행 장치는 Mac의 MPS다.

### 다음 계획

두 실행과 검사가 끝날 때까지 진행 상태를 확인하고, 기록을 가져와 같은
MPS 기준 조건에 대비한 사진 7장 추가의 효과를 계산한다.

## 2026-11-09 MPS 로컬 비교 학습 완료

- 학생이 잠들기 전 학습을 끝내 두도록 요청했다. 준비된 두 조건의 전체 학습,
  검증, ONNX 내보내기와 제출 형식 검사를 모두 완료했다.
- 두 조건은 코드 `500ed72`, MPS, seed 0, ResNet18 ImageNet V1,
  입력 224, batch size 64, worker 0개와 4 epochs를 사용했다.
  사진 제시 횟수는 각각 176,896회이고 같은 검증 사진 12,077장을 사용했다.
- 추가 사진은 학생이 지정한 오늘 다운로드 사진 7장이다.
  서울 `IMG_0549` 1장과 부산 6장이며, 실행 전 파일 목록과 해시 검사를 통과했다.
  기준 훈련 사진은 44,257장이고 추가 조건은 44,264장이다.

| 조건 | 검증 점수 | 학습 시각 | 완료 시각 KST |
| --- | --- | --- | --- |
| `b_control_seed0` 기존 사진 | 48.61% | 2,091.5초 | 11월 9일 03시 16분 31초 |
| `b_own_sb_seed0` 사진 7장 추가 | 48.74% | 2,098.4초 | 11월 9일 03시 52분 58초 |

- 검증 점수는 도시별 정확도의 평균이다. 사진 추가 조건의 차이는 +0.13%p다.
  두 조건을 seed 하나로 각각 한 번 측정했으므로 지속적인 개선을 판단하기에는
  반복 측정이 부족하다. 비교 기준은 이번에 같은 MPS 장치에서 학습한 조건이다.
- 도시별 정확도의 변화는 서울 61.44%에서 56.34%, 부산 36.91%에서 37.19%,
  도쿄 59.86%에서 61.63%, 오사카 34.02%에서 35.43%,
  타이베이 50.82%에서 53.10%다. 수치는 실험 CSV의 소수 넷째 자리 기록을 따른다.
- 두 모델 모두 Track B 형식 및 한도 검사를 통과했다.
  모델마다 파라미터 11,174,283개, 연산량 약 1.814 GMACs,
  ONNX 파일 44,707,595바이트다. 추가로 ONNX 전체 검사와 CPU 실행 환경에서
  batch 1과 3의 유한한 5개 출력값을 확인했다.
- 원본 모델과 메타데이터는 `results/b_control_seed0/`와
  `results/b_own_sb_seed0/`에 각각 저장했다. 준비된 실행 명령의 `--submit`에 따라
  로컬 `submission/`에는 사진 7장 추가 조건의 모델과 메타데이터가 들어 있다.
- 두 실험 기록을 기존 가져오기 도구로 `experiments.csv`에 합쳤고,
  중복 없이 총 9개의 기록을 확인했다. 원본 실행 출력은
  `results/local_training_mps_20261109.log`와 `results/colab_logs/`에 있다.
  조건, 점수, 모델 해시와 검사 결과를 `results/local_mps_comparison_seed0.json`에 저장했다.
- 두 모델과 원본 기록을 기존 `assignment2-baseline-20261105` 백업 폴더에 복사하고
  파일 해시를 대조했다.

## 2026-11-09 최종 제출 파일 선택과 재검사

- 학생이 최종 제출 파일과 GitHub 릴리스, 리더보드 반영 상태를 확인하는 작업을
  요청했다. 에이전트는 기존 전체 실험 9개의 검증 기록을 기준으로 제출 구성을 선택했다.
- Track A는 두 seed 평균이 가장 높았던 기준 레시피와 전체 훈련 사진을 선택했다.
  기준 평균은 50.14%, 56장 제외 평균은 49.26%, 가리기 평균은 49.30%였다.
  로컬 레시피를 `track-a-1` 공개 자산과 같은 파일로 맞췄고,
  전체 선택 목록의 44,257개 경로와 순서가 원본 훈련 목록과 일치함을 확인했다.
- Track B는 기록된 검증 점수가 가장 높았던 첫 모델 `b_baseline`을 선택해
  `submission/`에 모델과 원본 메타데이터를 맞췄다. 훈련 직후 점수는 48.95%이고,
  후속 두 MPS 실행은 48.61%, 48.74%다. 장치와 seed 지정 여부도 달라 작은 점수
  차이의 원인이나 일반적인 성능 우위를 확정하는 비교에는 한계가 있다.
  두 후속 모델은 각각의 결과 폴더에 보관했다.
- 선택한 Track A 레시피와 Track B 모델 · 메타데이터의 SHA-256이 각각 공개된
  `track-a-1`, `track-b-1` 자산의 digest와 일치했다. 두 공개 릴리스 모두
  게시 완료 상태이고 자산은 업로드 완료 상태다. 기존 두 릴리스를 최종 제출로 선택했다.
- Track A의 공식 `--quick` 검사는 MPS 역전파 중 텐서 stride/view 호환성 오류로
  종료되었다. 공식 코드를 CPU와 worker 0개로 다시 실행해 20 steps,
  사진 1,280회 제시와 검증 · ONNX 내보내기를 정상 완료했다.

  이 실행 점검은 전체 학습 실험 9개와 구분하며, 원본 오류와 성공 로그를 모두 보관했다.
- Track B는 공식 `check_submission.py`의 형식과 한도 검사를 통과했고,
  검증 사진 12,077장을 ONNX Runtime CPU에서 재검증했다.
  혼동행렬에서 계산한 도시별 정확도 평균은 0.48942471513433666, 약 48.94%다.
  원래 CUDA 훈련 직후의 48.95%는 원본 실험 행에 보존하고,
  ONNX/CPU 재검증 결과를 별도 JSON에 기록했다.
- 모델은 파라미터 11,174,283개, 연산량 1.813563904 GMACs로 Track B 한도에 맞는다.
  검사 원문과 선택 근거는 `results/final_submission_check/`에 저장했다.
  완료된 학습 명령은 보관한 뒤 `colab_runs.txt`의 실행 대기 목록을 비웠다.
- 11월 9일 10시 30분 KST에 확인한 공개 리더보드는 11월 9일 02시 41분 갱신본이다.
  `SoSleepy` 항목은 두 트랙 모두에서 0건이었다. 공개 저장소와 제출 자산은
  접근 가능한 상태이며, 등록 명단과 비공개 채점 실행 상태는 담당자 확인이 필요하다.
- 11월 9일 10시 41분 KST에 학생이 제공한 응답 수정 링크를 읽기 전용으로 조회했다.
  저장된 폼 응답의 세 필드에서 학번, 정확한 저장소 주소와 `SoSleepy`가
  학생이 알려 준 값과 일치했다. 응답의 필드 ID와 답변 레코드를 대조했다.
  이 확인은 학생 응답의 저장 상태에 대한 것이며, 담당자의 등록 명단 반영과
  비공개 채점 처리 상태는 별도 확인이 필요하다.

### 다음 계획

1. 등록 정보와 공개 릴리스 주소를 근거로 리더보드 누락에 대한 담당자 확인을 요청한다.
2. 학생이 직접 short report를 작성하고, 최종 제출 구성과 검사 결과를 반영한
   long report와 함께 마감 전에 LMS에 제출한다.

## 2026-11-09 최종 Track B 모델의 부분 가리기 분석

- 학생이 선택 사항으로 설명한 부분 가리기 분석을 실행하도록 요청했다.
- 최종 Track B 첫 모델의 ONNX 파일을 사용했다. 모델 SHA-256은
  `5f530de70645fc15d855e2547619ba2e7708e938b6d8eee6b1c6309de52de572`다.
- 검증 사진 목록을 도시별로 seed 0으로 섞고 각 도시의 첫 32장씩 총 160장을 추론했다.
  이 순서에서 처음 나온 정답과 오답을 도시마다 한 장씩 자동 선택했다. 분석 사례는 10장이다.
- 공식 `rules.grader_input`의 224 x 224 중앙 크롭에서 겹치지 않는 32 x 32 영역
  49개를 RGB (0.5, 0.5, 0.5)로 각각 가렸다. 총 490개 변형을 같은 ONNX 모델에 적용했다.
- 각 사진의 원래 예측 도시를 고정하고 원본 logit에서 가린 뒤 logit을 뺀 값을 계산했다.
  그림은 열 장 모두 같은 대칭 색상 범위를 사용한다. 빨강은 해당 도시 점수 하락, 파랑은 상승이다.
- 아래 표의 가린 뒤 확률과 예측은 원래 예측 도시의 logit을 가장 크게 내린 칸에서 얻은 값이다.
  마지막 열은 해당 사진의 전체 49개 가림 중 예측 도시가 바뀐 횟수다.

| 사례 | 원래 예측 | 원래 확률 | 가린 뒤 원래 도시 확률 | 가린 뒤 예측 | 예측 변화 |
| --- | --- | --- | --- | --- | --- |
| seoul_correct | seoul | 65.0% | 42.9% | seoul | 1/49 |
| seoul_incorrect | busan | 55.1% | 41.1% | busan | 0/49 |
| busan_correct | busan | 40.6% | 31.1% | busan | 1/49 |
| busan_incorrect | tokyo | 34.9% | 29.0% | osaka | 9/49 |
| tokyo_correct | tokyo | 85.1% | 78.4% | tokyo | 0/49 |
| tokyo_incorrect | seoul | 64.8% | 48.7% | seoul | 0/49 |
| osaka_correct | osaka | 93.0% | 90.6% | osaka | 0/49 |
| osaka_incorrect | tokyo | 45.4% | 32.2% | osaka | 4/49 |
| taipei_correct | taipei | 39.0% | 28.4% | taipei | 0/49 |
| taipei_incorrect | seoul | 55.5% | 38.1% | seoul | 0/49 |

- 10장 중 4장에서 한 개 이상의 가림 위치에 따라 예측 도시가 바뀌었고, 전체 490개 가림 중
  15개에서 원래 예측 도시와 다른 예측이 나왔다. 오사카 오답 사례는 49개 가림 중 4개에서
  정답 오사카로 바뀌었다. 서울 · 부산 정답 사례에서도 각각 한 개의 가림이 오답을 만들었다.
- 이는 선택한 열 장과 32픽셀 회색 가림 조건에서 측정한 국소적인 예측 변화다.
  특정 물체나 문화적 단서를 실제로 인식했다는 해석은 해당 결과와 구분한다.
- 분석 코드 `src/occlusion.py`, 원본 출력 `raw_outputs.npz`, 사례별 · 영역별 CSV,
  그림과 렌더링 소스는 `results/occlusion_final_b_seed0/`에 보관했다.
  최종 모델과 원본 사진의 해시, 고정된 대상 도시, 전체 입력의 가림 범위,
  예측 도시가 바뀌는 합성 사례를 검사해 수치와 CSV의 일치를 확인했다.
- 이 기록은 추론 분석이다. 전체 학습 실험 기록은 기존 9개다.

### 학생의 재검토와 가림 방식 대조

학생은 가림 결과를 보고 다음과 같이 말했다.

> 진짜 너무 뜬금 없는 영역을 가렸다고 바뀌니까 왜 그런지 잘 모르겠는데

이 질문에 따라 에이전트는 오사카 오답 사진의 같은 좌표에서 채우는 방식을 비교했다.
영역은 입력 크롭의 x [64, 96), y [96, 128)이다. 모든 조건은 같은 최종 ONNX 모델을 사용했다.

| 처리 방식 | 도쿄 출력 확률 | 오사카 출력 확률 | 예측 |
| --- | --- | --- | --- |
| 원본 | 45.4% | 19.9% | tokyo |
| 중간 회색 0.50 | 32.2% | 34.7% | osaka |
| 원래 하늘의 평균색 | 43.8% | 21.2% | tokyo |
| 흐림 반경 8픽셀 | 45.6% | 19.9% | tokyo |
| 짙은 회색 0.25 | 36.1% | 29.9% | tokyo |
| 밝은 회색 0.75 | 32.5% | 36.8% | osaka |

같은 하늘 영역에서도 중간 · 밝은 회색으로 채웠을 때 오사카로 예측했고,
원래 영역의 평균 하늘색과 흐림 처리에서는 도쿄로 예측했다.
이 사례는 가림 방식에 따른 출력 민감도를 보여준다. 처음 회색 가림 그림의 해석에는
사진 정보의 변화와 삽입한 패치의 색 · 경계 변화가 함께 포함되어 있다.
문화적 · 의미적 도시 단서를 특정하는 해석에는 이 조건 의존성을 함께 고려해야 한다.
수치와 그림, 실행 코드는 같은 결과 폴더의 `mask_control_results.json`,
`mask_control_results.csv`, `mask_replacement_control.png`, `mask_controls.py`에 저장했다.
일정한 색의 가림이 날카로운 색 대비를 통해 인공적인 반응을 만들 수 있다는 설명은
[Fong와 Vedaldi의 ICCV 2017
↪ 논문](https://robots.ox.ac.uk/~vedaldi/assets/pubs/fong17interpretable.pdf)의 4.3절과 함께
↪ 검토했다.

## 2026-11-10 baseline_mps (Track A, seed 0)

- 학생은 다른 수강생들의 balanced sampling을 보고 관심을 보였고,
  다음 실험으로 balanced sampling을 명시적으로 선택했다.
  같은 로컬 환경에서 변경 전후를 비교하기 위해 에이전트가 기준 실행을 추가했다.
- 순수한 balanced sampling 레시피의 첫 MPS 실행 검사는 역전파 중 stride/view
  오류로 종료되었다. 레시피의 `mix`에서 MPS 입력에만 `images.contiguous()`를
  적용하자 학습, 검증과 ONNX 내보내기가 모두 완료되었다.
  같은 메모리 배치 호환 수정을 기준 실행과 balanced 실행 양쪽에 적용했다.
  입력 픽셀 값과 라벨은 이 수정으로 바뀌지 않는다.
- 두 레시피 모두 공식 규칙 검사와 20-step MPS 실행 검사를 통과했다.
  이 실행 검사들은 전체 학습 횟수에 포함하지 않는다.
  공식 실행 코드와 규칙, 내보내기 코드 및 패키지 버전은 과제에서 제공한 것을 사용했다.
- 기준 실행은 스타터의 사진별 균등 순회 방식을 사용했다. 전체 사진 44,257장과
  원래 경로 순서, seed 0, batch size 64, 입력 224 x 224, 3,906 steps,
  249,984회 제시를 사용했다. 장치는 MPS, worker 수는 0이다.
- 검증 점수는 **0.4951 (49.51%)**, 학습 시간은 2,829.9초였다.
  검증과 내보내기 시간은 별도다. 실행은 11월 10일 02시 05분 KST에 완료되었다.
- 코드 commit은 `a108f5c`, recipe hash는 `7c1cb9f0ee41`,
  selection hash는 `1a1ca6c18823`이다. 공식 예산을 사용한 실행으로 기록되었다.

| 도시 | 기준 실행 검증 정확도 |
| --- | ---: |
| Seoul | 0.5741 |
| Busan | 0.3957 |
| Tokyo | 0.6163 |
| Osaka | 0.3581 |
| Taipei | 0.5314 |

- 이전 CUDA seed 0 기준 점수 50.44%와 이번 MPS 점수 49.51%는 실행 장치와
  정밀도 조건이 다르다. 새 샘플링 방법의 효과는 이번 MPS 대조군과 비교한다.
  아래 balanced 실행에서도 같은 장치와 seed, 입력 처리, 학습량을 사용한다.
- 원본 결과는 `results/baseline_mps_seed0/result.json`, 실행 로그는
  `results/balanced_20261110_checks/baseline_mps_seed0.txt`에 보관했다.
  두 레시피의 스냅샷, 첫 오류와 성공한 실행 검사 로그,
  실제 도시별 샘플링 횟수는 `results/balanced_20261110_checks/`에 보관했다.

## 2026-11-10 balanced (Track A, seed 0)

학생은 다른 수강생의 설정을 보고 다음과 같이 말했다.

> 막 다른 사람들은 balanced sampling 이 많길래

다음 실험을 확인하는 질문에 학생은 다음과 같이 선택했다.

> Balanced sampling으로 진행하기

- 전체 훈련 사진 44,257장을 사용하고, 각 사진의 가중치를 그 도시의 사진 수의
  역수로 정했다. 각 도시를 뽑을 확률의 합은 20%다. 공식 실행 코드의 가중 샘플링은
  복원 추출이며, 각 배치에 도시별 같은 수가 들어가도록 강제하는 방식은 아니다.
- 에이전트는 훈련 사진 수가 서울 11,274장, 부산 5,191장, 도쿄 13,347장,
  오사카 7,200장, 타이베이 7,245장으로 다르고, 평가 점수는 도시별 정확도를
  같은 비중으로 평균한다는 점을 설명했다. 이는 에이전트가 제공한 방법 설명이다.
- seed 0에서 실제 등장 횟수는 아래와 같았다. 두 조건의 총 학습량은 각각
  249,984회다. 기준 방식에서는 44,257장 전부가 한 번 이상 등장했고,
  복원 추출을 사용한 balanced 방식에서는 43,818장이 한 번 이상 등장했다.

| 도시 | 기준 방식 등장 횟수 | Balanced 등장 횟수 |
| --- | ---: | ---: |
| Seoul | 63,646 | 50,153 |
| Busan | 29,328 | 49,745 |
| Tokyo | 75,426 | 50,023 |
| Osaka | 40,670 | 49,939 |
| Taipei | 40,914 | 50,124 |

- seed 0, MPS, worker 0, batch size 64, 3,906 steps와 전체 선택 목록을
  기준 실행과 맞췄다. 크롭, 좌우 반전, 색상 변화, AdamW, OneCycleLR,
  label smoothing과 MPS 메모리 배치 호환 처리도 같았다.
- 검증 점수는 **0.5091 (50.91%)**로, 같은 MPS 기준의 **0.4951 (49.51%)**보다
  **1.40%p** 높았다. 학습 시간은 2,881.0초이며, 검증과 내보내기 시간은 별도다.
  실행은 11월 10일 02시 59분 KST에 완료되었다.

| 도시 | MPS 기준 정확도 | Balanced 정확도 | 차이 (%p) |
| --- | ---: | ---: | ---: |
| Seoul | 57.41% | 51.33% | -6.08 |
| Busan | 39.57% | 46.62% | +7.05 |
| Tokyo | 61.63% | 50.01% | -11.62 |
| Osaka | 35.81% | 44.97% | +9.16 |
| Taipei | 53.14% | 61.61% | +8.47 |
| 도시별 정확도의 평균 | 49.51% | 50.91% | +1.40 |

- 코드는 commit `bb6bc15`, recipe hash `e7500546f0a5`,
  selection hash `1a1ca6c18823`으로 결과 파일에 기록되었다.
  공식 예산을 충족했고, 혼동행렬에서 점수를 재계산해 원본 수치와 일치함을 확인했다.
  두 레시피 스냅샷은 각 결과 파일에 기록된 commit의 파일과도 일치했다.
- 최종 레시피 파일로 공식 규칙 검사와 20-step MPS 실행 검사를 다시 통과했다.
  전체 학습은 총 11개이며, Track A 8개와 Track B 3개다.
- 에이전트는 같은 환경의 대조군보다 점수가 높은 balanced sampling을
  최종 Track A 레시피로 선택했다. 과거 CUDA 기준의 두 seed 평균 50.14%는
  별도 조건의 기록으로 보존한다. 이번 두 MPS 조건은 seed 0에서 한 번씩 실행했다.
- 학생은 결과를 해석하기 전에 방법과 도시별 변화에 대한 설명을 요청했다.
  에이전트는 세 도시의 상승과 두 도시의 하락을 같은 비중으로 평균하면 전체 점수가
  상승한다는 계산을 설명했다. 사진의 총수와 함께 도시별 학습 등장 비중도
  이번 측정 결과에 영향을 주었으며, 이 수치 설명은 에이전트의 분석으로 기록한다.
  다른 seed에서의 효과 크기와 반복성은 이번 한 쌍의 실행에서 측정하지 않았다.
- 방법 설명을 들은 뒤 학생은 다음과 같이 해석했다.

> 아무래도 부산인 사진을 더 많이 학습하면 뭐가 부산의 특징을 가지고 있는지 더 많이 배울 수 있으니까 더
↪ 오르겠지

  학생의 해석은 부산 사진을 더 자주 보면서 해당 도시의 특징을 배울 기회가
  늘었을 것이라는 것이다. 실제 부산의 정확도는 39.57%에서 46.62%로 상승했다.
  이 설명은 학생의 해석으로 기록하며, 모델이 사용한 구체적인 특징의 확인과는 구분한다.
- 원본 결과는 `results/balanced_seed0/result.json`, 실행 로그와 비교표,
  샘플링 횟수, 최종 실행 검사 기록은 `results/balanced_20261110_checks/`에 보관했다.

```
### 다음 계획

1. 검사를 마친 balanced 레시피와 전체 선택 목록을 새 Track A 릴리스로 게시한다.
2. Long report에 비교 조건, 도시별 변화와 최종 릴리스 정보를 반영한다.
3. 최종 보고서 두 PDF를 마감 전에 LMS에 제출하고 공개 채점 결과를 확인한다.

## 2026-11-10 balanced 최종 릴리스 검증

- 최종 Track A 릴리스 `track-a-2`를 11월 10일 03시 05분 KST에
  `Balanced sampling`이라는 제목으로 게시했다. 대상 commit은 `310648d`다.
  공개 주소는 [Track A 최종
  ↪ 릴리스](https://github.com/jellykeeng/mas1004-assignment2/releases/tag/track-a-2)다.
- `recipe.py`와 전체 `selection.csv` 두 자산이 업로드 완료 상태이며,
  draft와 prerelease는 모두 false다. 두 자산을 비로그인 상태에서 HTTP 200으로
  내려받아 검사한 로컬 파일과 바이트 단위로 일치함을 확인했다.
- 레시피 SHA-256은
  `e7500546f0a59a23f9bb7757b404c87ff61010c9f3d1b634d6c164a6335ecfe4`,
  선택 목록 SHA-256은
  `1a1ca6c1882356b84701446e495973c375535d9d64b3cb3d3397c3dfd640f9e4`다.
- 최종 Track B `track-b-1`의 모델과 메타데이터도 현재 로컬 파일의 해시가
  공개 자산 digest와 일치했다. 두 트랙의 릴리스는 과제 마감 전에 게시되었다.
- 11월 10일 03시 07분 KST에 조회한 리더보드는 11월 9일 02시 41분 갱신본이며,
  `SoSleepy` 항목은 두 트랙 모두에서 0건이었다. 보고서의 공개 점수는 pending으로
  기록한다. 비공개 채점 처리 상태는 공개 자료에서 확인할 수 없다.
- 검증 원문과 공개 자산 정보는 `results/balanced_20261110_checks/`의
  `release_verification.json`, `release_verification.txt`,
  `leaderboard_status.json`에 보관했다.

### 다음 계획

1. 이번 비교와 학생의 해석, 최종 릴리스 정보를 반영한 Long report를 제출한다.
2. 최종 보고서 두 PDF를 11월 10일 22시까지 LMS에 제출한다.

## 2026-11-10 Track B 모델 선택 갱신

학생은 Track B가 리더보드에 반영된 뒤 다음과 같이 말했다.

> track b 떴는데 나 너무 등수가 낮아

에이전트는 기존에 학습한 balanced 모델의 Track B 제출을 제안했고, 학생은 다음과 같이 선택했다.

> Balanced 모델을 검증한 뒤 Track B로 제출하기

- 11월 10일 17시 04분 리더보드 갱신본에서 첫 제출 `track-b-1`은
  0.3826, 27개 채점 모델 중 26위였다. 표시된 스타터 모델 점수는 약 0.403이었다.
  해당 원본 JSON을 `results/balanced_track_b_candidate/leaderboard_before.json`에 보관했다.
- `results/balanced_seed0/model.onnx`를 재사용했다. 원본 학습은 commit `bb6bc15`,
  MPS seed 0, batch size 64, 3,906 steps, 249,984회 제시로 완료된 Track A 실행이다.
  모델 재사용은 새 학습 실행으로 계산하지 않으며, 전체 학습 기록은 기존 11개다.
- 공식 `check_submission.py`로 Track B 형식과 한도 검사를 통과했고,
  검증 사진 12,077장 전체를 ONNX Runtime CPU로 평가했다. 검증에는 274초가 걸렸다.
- 새 모델의 도시별 정확도 평균은 **0.509104010051048 (50.91%)**였다.
  기존 첫 모델의 같은 ONNX/CPU 검증 점수 0.48942471513433666 (48.94%)보다
  약 **1.97%p** 높았다. 혼동행렬은 원래 balanced MPS 검증 결과와 일치했다.

| 도시 | 첫 B 모델 ONNX/CPU | Balanced 재사용 모델 ONNX/CPU |
| --- | ---: | ---: |
| Seoul | 55.40% | 51.33% |
| Busan | 37.55% | 46.62% |
| Tokyo | 63.75% | 50.01% |
| Osaka | 34.87% | 44.97% |
| Taipei | 53.14% | 61.61% |
| 도시별 정확도의 평균 | 48.94% | 50.91% |

- 두 모델은 학습 예산, 장치와 seed 지정 조건도 다르다. 위 비교는 제출 모델을
  선택하기 위한 검증이며, 샘플링 방식 하나의 효과를 분리하는 비교는 Track A의
```

  동일 MPS 조건 49.51%와 50.91% 결과에서 확인했다.
- 재사용 모델의 파라미터는 11,174,283개, 연산량은 1.813563904 GMACs,
  크기는 44,707,595 bytes로 Track B 한도를 충족했다. 모델 SHA-256은
  `ea94e4de284f9e685ba3736214871542069943c210bddade7287c0f13ffbefd5`다.
- 검증한 모델과 메타데이터를 `submission/`에 배치하고 공식 형식 검사를 다시 통과했다.
  이전 첫 모델과 메타데이터, 49쪽 보고서는 같은 결과 폴더의 백업에 보관했다.
- 위 해석과 수치 비교는 에이전트가 기록한 분석이다. 새 모델의 리더보드 성능은
  새 채점 결과에서 확인해야 한다.

### 다음 계획

1. 검증한 balanced 모델을 새 Track B 릴리스로 게시한다.
2. 학생이 추가로 선택한 MobileNetV3-Large의 224와 448 입력 실험을 실행 검사한다.
3. 완료된 실험과 최종 제출 선택을 영어 Long report와 제출 ZIP에 반영한다.

## 2026-11-10 track-b-2 게시 확인

- 검증한 balanced 모델을 `track-b-2`로 11월 10일 17시 32분 KST에 게시했다.
  제목은 `ResNet18 at 224, balanced sampling, seed 0`, 대상 commit은 `8a8245d`다.
  공개 주소는 [Track B 두 번째
  ↪ 릴리스](https://github.com/jellykeeng/mas1004-assignment2/releases/tag/track-b-2)다.
- 두 첨부 파일을 비로그인 상태에서 HTTP 200으로 내려받아 로컬 검증 파일과
  바이트 및 SHA-256이 일치함을 확인했다. 모델은
  `ea94e4de284f9e685ba3736214871542069943c210bddade7287c0f13ffbefd5`,
  메타데이터는 `d1f5eca299ace908479ffae7f05ba16a9498029ca0f001640b09b2581e621897`이다.
- 공개 자산 확인 결과는 `results/balanced_track_b_candidate/release_verification.json`과
  같은 이름의 TXT에 보관했다. 새 모델의 공개 채점 결과는 후속 확인 대상이다.

## 2026-11-10 MobileNetV3-Large 비교 계획

학생은 balanced 모델을 제출하기로 한 뒤 추가로 다음과 같이 요청했다.

> 그리고 balance 와 별개로 좀 더 개선할 수 있으면 개선했으면 좋겠어 등수를 더 올릴 수 있을 만한

에이전트가 모델 구조와 해상도를 차례로 비교하는 계획을 제안했고, 학생은 다음과 같이 선택했다.

> MobileNetV3-Large 224→448 비교하기

- 기존 ResNet18 224 모델과 같은 전체 훈련 사진, seed 0, balanced sampling,
  batch size 64, 3,906 steps와 249,984회 제시를 사용한다.
- 첫 실행은 MobileNetV3-Large 224, 다음 실행은 같은 모델의 448 입력이다.
  모델별 ImageNet 사전학습 가중치는 ResNet18 V1, MobileNetV3-Large V2다.
  224 실행은 사전학습 모델 구성의 비교이고, 224와 448 실행은 입력 해상도의 비교다.
- `src/train_b.py`에 선택적인 `--steps` 인자를 추가해 학습량을 고정했다.
  이 모드에서는 주어진 `official.draw_order`를 재사용하고 데이터 로더의 난수
  생성기와 증강 seed를 고정한다. 기존 epoch 방식의 기본값을 지원한다.
  실행 결과에는 학습량, 검증 사진 수, 도시별 정확도와 혼동행렬을 저장한다.
- 새 코드의 commit은 `e101e80`이며, 구문 검사와 CLI 도움말 실행을 통과했다.
  20-step 검사의 결과는 별도 CSV에 기록해 전체 학습 실험 표와 구분한다.
- 가벼운 모델과 높은 입력 해상도로 작은 시각 정보를 활용할 가능성을 측정한다는
  설명은 에이전트의 제안이다. 순위 상승은 실제 검증과 공개 채점 결과로 판단한다.
- 실행 검사에서 로컬 학습 시간을 추정하고, 11월 10일 22시 마감 전에
  완료할 수 있는 범위에서 전체 비교와 제출 검증을 진행한다.

### MobileNet 실행 검사와 배치 조건 조정

- 224 입력과 배치 64의 실행 검사는 통과했다. 448 입력과 배치 64의 검사는
  4 steps에 308초가 걸려 중단했다. 작은 배치의 첫 검사를 이전 프로세스 종료 확인 전에
  시작한 구간은 시간 비교에서 제외했다. 두 프로세스 트리를 종료하고 단독 검사를 다시 했다.
- 학생은 메모리에 맞춰 두 해상도의 배치를 함께 줄이는 방안을 다음과 같이 선택했다.

> 같은 작은 배치로 두 해상도 비교하기

- 두 MobileNet 전체 실행은 batch size 32, 7,812 steps, 249,984회 제시로 맞춘다.
  224와 448의 비교에서는 batch size, seed, 가중 샘플링 순서와 학습량이 같다.
  기존 ResNet18 224 모델과 비교할 때는 모델 · 사전학습 가중치와 함께 batch size도 다르다.

- 배치 32의 단독 20-step 검사는 두 해상도에서 학습, 검증과 ONNX 내보내기를 통과했다.
  파라미터는 약 420만 개이며, 연산량은 224에서 약 0.22 GMACs,
  448에서 약 0.85 GMACs다. 448 모델은 공식 Track B 형식 검사도 통과했다.
- 초기화 이후 step 4에서 20까지의 측정 시간으로 추정한 전체 학습 시간은
  224에서 약 57분, 448에서 약 155분이다. 검증과 내보내기는 별도다.
  원본은 `results/mobilenet_20261110_checks/`의 실행 검사 로그와
  `runtime_estimates.json`에 보관했다.
- 마감 시간을 고려해 실제 실행 순서는 448 전체 학습을 먼저, 224 대조군을 다음으로
  정했다. 해상도 비교는 두 실행의 결과가 준비된 뒤 수행한다.

## 2026-11-10 17시 45분 리더보드 반영 확인

- 17시 54분 KST에 공개 JSON을 다시 받아 확인했다. 표시된 갱신 시각은
  11월 10일 17시 45분이며, `SoSleepy`의 Track B 태그는 `track-b-2`다.
- Track B 점수는 **0.4203 (42.03%)**, 채점된 27개 모델 중 **14위**다.
  첫 제출의 38.26%보다 **3.77%p** 올랐고, 표시된 스타터 모델 기준 40.3%보다
  약 **1.7%p** 높다. 각 도시 값은 공개 데이터의 반올림 정밀도를 따른다.
- 도시별 공개 정확도는 Seoul 62.3%, Busan 30.9%, Tokyo 61.8%,
  Osaka 30.0%, Taipei 25.1%다. 전체 점수는 공개된 42.03%를 사용한다.
- 같은 갱신본의 Track A에는 닉네임이 없어 공식 점수를 확인하지 못했다.
  로컬 balanced seed 0 검증 50.91%와 공개 리더보드 점수를 구분한다.
- 원본과 추출 결과는 `results/balanced_track_b_candidate/leaderboard_after.json`과
  `leaderboard_after_status.json`에 보관했다. 해석과 비교는 에이전트의 분석이다.
- 학생이 수정본을 먼저 요청해, 진행 중인 MobileNet 실험의 결과를 제외한
  영어 Long report를 우선 갱신한다. 완료된 전체 학습 수는 현재 11개다.

### 다음 계획

1. 실행 중인 MobileNetV3-Large 448 학습을 완료하고 검증한다.
2. 동일 batch size와 학습량으로 224 대조군을 실행한다.
3. 완료된 결과를 비교해 제출 모델을 선택하고 Long report와 제출 파일을 갱신한다.

## 2026-11-10 MobileNet 224 실행 시점 변경

448 전체 학습이 진행 중일 때 학생이 다음과 같이 요청했다.

> 일단 448 학습만 진행하고 내가 이어서 해달라고 할 때 224 실험 실행해줘. 잠시 와이파이가 끊길 수도 있어서

- 실행 중인 448 학습을 완료하고 결과를 로컬에 보관한다.
- 224 전체 학습은 학생이 이어서 진행해 달라고 요청한 뒤 시작한다.
  두 해상도를 비교하는 실험 계획에서 실행 시점만 변경했다.
- 현재 학습에 필요한 사진과 ImageNet 사전학습 가중치는 이미 로컬에 있다.
  학습 루프, 검증과 ONNX 내보내기는 로컬 파일을 사용한다.

### 다음 계획

1. 448 학습의 검증 점수와 저장된 결과를 확인한다.
2. 학생의 재개 요청을 받은 뒤 동일 조건의 224 대조군을 실행한다.

## 2026-11-10 마지막 실험과 최종 제출 범위 확정

448 학습 후 전체 검증이 진행 중일 때 학생이 다음과 같이 요청했다.

> 지금 실험 끝나고 224는 하지말고 그냥 릴리스 해버려 이제 그만할래 track a ㄷㅗ 11ㄷㅡㅇㅇㅣㄴㅣㄲㅏ
↪ 낫배드고 그리고 최종 Long report 만 줘 이거 다 하고

- 이번 448 실행을 마지막 전체 학습으로 정한다. MobileNet 224 대조군은 실행하지 않는다.
- 완료된 448 결과를 기존 balanced B 모델과 비교하고, 선택 모델을 공식 검증한 뒤
  릴리스한다. 최종 영어 Long report PDF를 갱신해 전달한다.
- 20시 42분에 확인한 공개 JSON은 20시 33분 갱신본이었다.
  `track-a-2`는 **41.06%, 28개 채점 결과 중 11위**로 반영됐다.
  서버의 세 seed 평균 검증 점수는 **50.2233%**, 공개 점수 범위는 **40.19~42.22%**다.
- A 도시별 공개 평균은 Seoul 58.60%, Busan 28.37%, Tokyo 62.17%,
  Osaka 29.47%, Taipei 26.70%다. 같은 갱신본에서 `track-b-2`는
  42.03%, 28개 채점 결과 중 15위였다.
- 공개 페이지에 표시된 스타터 레시피 기준은 40.1%, 스타터 B 모델 기준은 40.3%다.

  반올림된 기준값과 비교하면 A는 약 0.96%p, B2는 약 1.73%p 높다.
- 공개 원본과 상태 추출 결과는 `results/mobilenet_20261110_checks/`에 보관했다.
  위 수치 비교와 해석은 에이전트의 분석이다.

### 다음 계획

1. 진행 중인 448 검증과 모델 저장을 완료한다.
2. 제출할 모델을 공식 검사하고 릴리스한다.
3. 실제 완료 결과, 최종 태그와 공개 점수를 반영한 Long report PDF를 전달한다.

## 2026-11-10 b_mnv3_448_seed0 (Track B)

- 학생이 선택한 MobileNetV3-Large 448 전체 실행을 완료했다. 학습 commit은
  `49346fe`, 장치는 MPS, seed는 0, loader workers는 0이다.
- 전체 스타터 훈련 사진 44,257장과 balanced sampling을 사용했다.
  batch size 32, 7,812 steps로 249,984회 사진을 제시했다.
  사전학습 가중치는 torchvision `IMAGENET1K_V2`다.
- crop 0.35~1.0, 좌우 반전, color jitter 0.2, AdamW 학습률 0.0003,
  weight decay 0.05, OneCycleLR와 label smoothing 0.1을 사용했다.
- 학습에는 **7,931.0초 (약 132.2분)**가 걸렸고 마지막 평균 훈련 loss는 0.886이었다.
  검증 사진 12,077장 전체의 MPS 검증 점수는 **0.5794 (57.94%)**였다.
  기존 balanced ResNet18의 MPS 검증 50.91%보다 **7.03%p** 높았다.

| 도시 | Balanced ResNet18 MPS | MobileNet 448 MPS | 차이 |
| --- | ---: | ---: | ---: |
| Seoul | 51.33% | 57.21% | +5.88%p |
| Busan | 46.62% | 50.58% | +3.96%p |
| Tokyo | 50.01% | 62.17% | +12.16%p |
| Osaka | 44.97% | 52.54% | +7.57%p |
| Taipei | 61.61% | 67.19% | +5.58%p |
| 도시별 정확도의 평균 | 50.91% | 57.94% | +7.03%p |

- 검증은 스크립트의 배치 128로 실행됐다. macOS 프로세스 표본에서 약 13.5GB의
  physical footprint가 관찰됐고, 검증과 내보내기에 약 51분이 추가로 걸렸다.
  에이전트가 처음 안내한 검증 · 저장 5~10분 예상은 실제보다 짧았다.
  원본 학습 출력과 사진 파일 관찰 기록을 결과 폴더에 보관했다.
- 모델과 결과 파일은 20시 53분 40초 KST에 저장됐다. ONNX export gap은
  `3.635883331298828e-06`, 모델 크기는 16,825,941 bytes다.
  모델 SHA-256은 `e18718be94887a770658f32c5af64f84b9a43018ae601bd6ad7a0b7d6e999dd0`다.
- 에이전트의 분석으로는 다섯 도시의 검증 정확도가 모두 올랐다. 같은 seed,
  장치와 사진 제시 수를 사용했지만 모델, 사전학습 가중치, 해상도와 batch size가
  함께 달라졌고, optimizer update 수도 3,906회에서 7,812회로 달라졌다.
  결과는 이 전체 설정을 선택하는 근거이며, 해상도 하나의 효과를 분리한 결과는 아니다.
- 학생의 최종 요청에 따라 MobileNet 224 전체 실행은 취소했다. 최종 전체 학습
  기록은 12개이며 Track A 8개, Track B 4개다. Quick check는 별도 CSV에 있다.
- 내보낸 448 ONNX 파일이 Track B 형식과 파라미터 · 연산량 한도 검사를 통과했다.
  같은 파일의 공식 ONNX/CPU 전체 검증을 진행한 뒤 제출 릴리스로 게시한다.

### 다음 계획

1. 공식 전체 검증과 공개 릴리스 자산 확인을 완료한다.
2. 최종 영어 Long report PDF를 전달한다.

## 2026-11-10 MobileNet 448 공식 제출 검사

- 공식 `check_submission.py --submission results/b_mnv3_448_seed0`가 형식과
  Track B 한도 검사를 통과하고 검증 사진 12,077장 전체를 CPU에서 평가했다.
  CPU 검증에는 209초가 걸렸다.
- ONNX/CPU 점수는 **0.5793640527634617 (57.94%)**였다. 도시별 혼동행렬은
  MPS 검증과 정확히 일치했다. 이전 B2의 ONNX/CPU 50.91%보다 약 **7.03%p** 높다.
- 공식 파일 측정값은 **4,196,243 parameters**, **0.85303744 GMACs**,
  **16,825,941 bytes**, ONNX opset 17이다. Track B 한도를 충족한다.
- 검증한 모델과 메타데이터를 `submission/`에 복사했고 원본과 바이트가 일치했다.
  기본 제출 폴더의 공식 형식 검사도 통과했다. 이전 B2 파일은 별도로 보관했다.
- 학생이 새 릴리스를 요청했다. 에이전트는 모델과 해상도, 샘플링을 설명하는
  `MobileNetV3-Large at 448, balanced sampling`을 제목으로 사용한다.

  다음 Track B 태그는 `track-b-3`이다.
- 학생이 선택한 마지막 실험 이후 추가 전체 학습은 계획하지 않는다.

### 다음 계획

1. 검증한 두 제출 파일을 새 릴리스로 게시하고 공개 자산을 확인한다.
2. 최종 태그와 완료 결과를 반영한 Long report PDF를 전달한다.

## 2026-11-10 track-b-3 최종 게시 확인

- 학생이 릴리스 제목으로 `MobileNetV3-Large at 448, balanced sampling`을 선택했다.
- 같은 제목의 `track-b-3`를 **21시 00분 46초 KST**에 게시했다.
  태그 대상 commit은 `595003fe99618621e28181bf2a176dd5be6e54a1`이다.
  공개 주소는 [최종 Track B
  ↪  릴리스](https://github.com/jellykeeng/mas1004-assignment2/releases/tag/track-b-3)다.
- 21시 01분에 첨부 파일 두 개를 비로그인 상태로 HTTP 200으로 내려받았다.
  두 파일 모두 공식 전체 검증에 사용한 로컬 제출 파일과 바이트가 일치했다.
- 모델 SHA-256은 `e18718be94887a770658f32c5af64f84b9a43018ae601bd6ad7a0b7d6e999dd0`,
  메타데이터 SHA-256은 `fef09ffebc7e6386435ac730873f884704b7a10ea0fd6d4bb43494b3e9d9ed0a`다.
- 최종 GitHub 제출은 Track A `track-a-2`, Track B `track-b-3`다.
  A의 공개 점수 41.06%와 B2의 공개 점수 42.03%를, B3의 로컬 검증 점수
  57.94%와 구분해 보고한다. B3의 공개 점수는 새 채점 결과에서 확인한다.
- 원본 API 응답, 태그 commit, 내려받은 자산과 검증 결과를
  `results/mobilenet_20261110_checks/`에 보관했다.
- 학생 요청에 따라 최종 Long report를 영어 PDF로 갱신한다.

### 최종 제출 계획

1. 완료된 12개 전체 학습 결과와 최종 릴리스 정보를 Long report에 반영한다.
2. 학생은 최종 Long report PDF로 LMS의 기존 파일을 교체해 22시 전에 제출한다.

## 2026-11-10 최종 B 공개 채점 반영

최종 보고서 확인 중 학생이 다음과 같이 말했다.

> 3등했어 track b

- 21시 07분 33초 KST에 공개 JSON을 받아 확인했다. 갱신 시각은 21시 04분이며,
  학생의 Track B 태그가 최종 `track-b-3`로 반영됐다.
- 최종 B 공개 점수는 **45.02%, 채점 모델 28개 중 3위**다.
  이전 B2의 42.03%보다 **2.99%p**, 표시된 스타터 모델 기준 40.3%보다
  약 **4.72%p** 높다. B3의 로컬 ONNX/CPU 검증 57.94%와 구분한다.
- 같은 갱신본의 A는 **41.06%, 채점 레시피 29개 중 11위**다.
  A의 세 seed 평균 검증 점수는 50.2233%이며, 공개 점수는 40.19~42.22% 범위다.

| 도시 | B2 공개 점수 | B3 공개 점수 | 차이 |
| --- | ---: | ---: | ---: |
| Seoul | 62.3% | 63.8% | +1.5%p |
| Busan | 30.9% | 30.4% | -0.5%p |
| Tokyo | 61.8% | 76.3% | +14.5%p |
| Osaka | 30.0% | 34.8% | +4.8%p |
| Taipei | 25.1% | 19.8% | -5.3%p |
| 공개된 전체 점수 | 42.03% | 45.02% | +2.99%p |

- 에이전트의 분석으로는 다섯 도시 모두에서 로컬 검증 정확도가 올랐지만,
  공개 사진에서는 Busan과 Taipei가 내려갔다. 전체 평균 개선과 도시별 개선을
  구분하고, 서로 다른 사진 집합에 대한 결과를 함께 살펴볼 필요가 있다.
  이 비교 역시 모델, 사전학습 가중치, 해상도와 batch size가 함께 바뀐 설정의 결과다.
- 새 공개 점수와 순위까지 최종 Long report에 반영한다. 원본과 상태 추출 파일은
  `results/mobilenet_20261110_checks/leaderboard_b3_scored.json` 및
  `leaderboard_b3_scored_status.json`에 보관했다.
- 최종 계획은 학생이 새 공개 결과까지 반영한 Long report PDF로 LMS의 기존 파일을
  교체 제출하는 것이다. 최종 릴리스는 Track A `track-a-2`, Track B `track-b-3`다.